

Universitat de Barcelona

Escola de Noves Technologies Interactives

*Grau en Continguts Digitals Interactius / Grau en Creació Artística per a Videojocs i
Jocs Aplicats*

Tanks Machine Learning

Marcos Ruiz Muñoz

Projecte Aplicat de Videojoc

Curs 2025-2026

Nom Alumne

Marcos Ruiz Muñoz

Nom Tutor

Lluís Gómez Bigorda

Abstract

This project presents the design, implementation and training of an autonomous agent for a combat simulation environment developed in Unity using the ML-Agents framework. The agent, modelled as a tank, was trained through a reinforcement learning approach based on Proximal Policy Optimization (PPO), progressively acquiring a set of complex behaviours including target pursuit, rotational alignment, distance management, obstacle avoidance and predictive shooting. A structured curriculum learning strategy was employed to incrementally introduce environmental complexity, starting from a static target scenario and advancing through dynamic obstacle navigation and moving target tracking, ensuring stable policy convergence at each stage before increasing difficulty.

Keywords

Reinforcement Learning, Proximal Policy Optimization, ML-Agents, Unity, Curriculum Learning, Self-Play, Autonomous Agent, Neural Network, ELO Rating, Combat Simulation, Obstacle Avoidance, Reward Shaping

Contenido

Abstract.....	2
Keywords.....	2
Contenido.....	3
1.Introducción y estado del Arte.....	5
1.1. Introducción.....	5
1.2. Marco Teórico.....	5
1.2.1. Aprendizaje por Refuerzo.....	5
1.2.2. Policy.....	6
1.2.3. Recompensas y Función de Recompensa.....	6
1.2.4. Observaciones y Espacio de Observación.....	6
1.2.5. Acciones y Espacio de Acción.....	6
1.2.6. Red neuronal y Deep Learning.....	7
1.2.7. Gamma.....	7
1.2.8. Curriculum Learning.....	7
1.2.9. Self-play.....	7
1.2.10. Sistema de ELO.....	7
1.2.11. Normalización de Observaciones.....	8
1.3. Estado del Arte.....	8
2.Objetivos.....	10
3.Diseño de la Solución.....	11
3.1. Definición del Problema.....	11
3.2. Elección del Motor y la Plataforma de Entrenamiento.....	11
3.3. Elección del Algoritmo de Aprendizaje.....	12
3.4. Diseño del Espacio de Observación.....	12
3.5. Diseño del Espacio de Acción.....	13
3.6. Diseño del Sistema de Recompensas.....	13
3.7. Estrategia de Entrenamiento por Fases.....	14
4.Desarrollo.....	15
4.1. Arquitectura del Sistema.....	15
4.2. Implementación del Entorno de Entrenamiento.....	17
4.3. Implementación del Agente.....	19
4.3.1. Sistema de Movimiento.....	20
4.3.2. Sistema de Rotación.....	20
4.3.3. Sistema de Observaciones.....	21
4.3.4. Sistema de Disparo.....	23
4.4. Diseño y Evolución del Sistema de Recompensas.....	24
4.5. Configuración del entrenamiento.....	27
4.5.1. Hiperparámetros PPO.....	27
4.5.2. Señales de recompensa adicionales.....	29

4.5.3. Sistema de Curriculum Learning.....	30
4.5.4. Inicialización entre Fases.....	32
4.6. Resultado por Fase de Entrenamiento.....	33
4.6.1. Fase 1: Objetivo Estático sin Obstáculo (Modelo mental 24).....	33
4.6.2. Fase 2: Objetivo Estático con Obstáculo (Modelo mental 25).....	34
4.6.3. Fase 3: Objetivo en Movimiento sin Obstáculo (Modelo mental 26).....	35
4.6.4. Fase 4: Objetivo en Movimiento con Obstáculo (Modelo mental 27).....	36
4.6.5. Fase 5: SelfPlay (Modelo mental 30).....	37
4.6.5.1. Mecánica del SelfPlay en ML-Agents.....	37
4.6.5.2. Sistema de ELO.....	38
4.6.5.3. Análisis de la curva de ELO.....	38
4.7. Análisis de Comportamientos Emergentes.....	40
4.7.1. Comportamientos emergentes en las fases de curriculum.....	40
4.7.2. Comportamientos emergentes en la fase de SelfPlay.....	40
5.Conclusiones y Líneas a Futuro.....	42
5.1. Análisis Crítico del Grado de Consecución de los Objetivos.....	42
5.2. Principales Aprendizajes del Proyecto.....	42
5.3. Líneas a Futuro.....	43
6.Bibliografía.....	45
7.Anexo.....	47

1.Introducción y estado del Arte

1.1. Introducción

El sector de los videojuegos ha experimentado una transformación profunda en las últimas décadas, impulsada en gran medida por el avance de la inteligencia artificial aplicada en su desarrollo. La demanda de comportamientos autónomos cada vez más sofisticados en personajes no jugadores ha llevado a la adopción de técnicas de aprendizaje automático que van más allá de los sistemas basados en reglas tradicionales. En este contexto, el aprendizaje por refuerzo profundo (Deep Reinforcement Learning, DRL) se ha consolidado como una de las disciplinas más relevantes, tanto en el ámbito académico como en la industria del videojuego, al permitir que los agentes aprendan comportamientos complejos a través de la interacción con su entorno sin necesidad de programación explícita.

Este proyecto aborda el diseño, la implementación y el entrenamiento de un agente autónomo en un entorno de simulación de combate desarrollado con el motor Unity y el toolkit de ML-Agents (Juliani et al., 2020). El agente, modelado como un tanque, adquiere de forma progresiva un conjunto de comportamientos que incluyen la persecución de objetivos, la gestión de distancias de combate, la evasión de obstáculos y el disparo predictivo. El proceso de aprendizaje se articula a través de una estrategia de curriculum learning (Bengio et al., 2009) que introduce complejidad de forma incremental, culminando en un sistema de self-play en el que dos instancias del mismo agente compiten entre sí, monitorizadas mediante un sistema de puntuación ELO que permite cuantificar el progreso competitivo del modelo a lo largo del entrenamiento.

1.2. Marco Teórico

El desarrollo de agentes autónomos mediante técnicas de aprendizaje automático requiere el conocimiento de un conjunto de conceptos fundamentales que constituyen la base teórica sobre la que se sustenta el proyecto. A continuación se definen los términos más relevantes en el ámbito del *Machine Learning* aplicado al desarrollo de inteligencias artificiales.

1.2.1. Aprendizaje por Refuerzo

El aprendizaje por refuerzo es una rama del aprendizaje automático en la que un agente aprende a tomar decisiones mediante la interacción con un entorno. A diferencia del aprendizaje supervisado, donde el modelo aprende a raíz de ejemplos etiquetados, en el aprendizaje por refuerzo el agente no recibe instrucciones explícitas sobre qué acción ejecutar, sino que descubre por sí mismo qué comportamientos maximizan una señal de recompensa acumulada a lo largo del tiempo. Este paradigma se formaliza habitualmente mediante el marco teórico de los Procesos de Decisión de Markov (Markov Decision Process, MDP), que define el entorno como un conjunto de estados, acciones, transiciones y recompensas.

1.2.2. Policy

La Policy es la función que determina qué acción ejecuta el agente en función del estado observado del entorno. Esta puede ser determinista, asignando una única acción a cada estado, o estocástica, definiendo una distribución de probabilidad sobre las posibles acciones. En el contexto del aprendizaje por refuerzo profundo, la política se representa mediante una red neuronal cuyos pesos se ajustan durante el entrenamiento para maximizar la recompensa esperada. El objetivo central del proceso de entrenamiento es, precisamente, encontrar la política óptima que maximice la recompensa acumulada a largo plazo.

1.2.3. Recompensas y Función de Recompensa

La recompensa es la señal numérica que el entorno proporciona al agente como retroalimentación tras cada acción ejecutada. Puede ser positiva, negativa o nula, y su diseño es uno de los aspectos más críticos del proceso de entrenamiento, ya que determina directamente qué comportamientos el agente aprende a favorecer o evitar. La función de recompensa acumulada, pondera las recompensas futuras mediante un factor gamma, que controla el horizonte temporal del agente, valores de gamma próximos a 1 llevan al agente a considerar recompensas lejanas como casi tan valiosas como las inmediatas, mientras que valores bajos incentivan comportamientos a corto plazo.

1.2.4. Observaciones y Espacio de Observación

Las observaciones son los datos que el agente percibe del entorno en cada instante de tiempo y que utiliza como entrada para calcular las acciones a ejecutar. El conjunto de todas las posibles observaciones define el espacio de observación, cuya dimensionalidad debe ser suficientemente rica para que el agente pueda tomar decisiones informadas, pero no tan elevada que dificulte innecesariamente el proceso de aprendizaje. En los proyectos de ML, las observaciones incluyen variables como la dirección y la distancia al objetivo, la orientación propia, la velocidad del agente, la disponibilidad de los sistemas y la existencia de línea de visión directa.

1.2.5. Acciones y Espacio de Acción

Las acciones son las decisiones que el agente puede ejecutar en cada paso temporal. El espacio de acción puede ser discreto, cuando el número de acciones posibles es finito y numerable, o continuo, cuando las acciones toman valores en un rango real. Normalmente en proyectos se emplea un espacio de acción híbrido donde las acciones de movimiento y rotación son continuas, lo que permite un control fluido del agente en el entorno tridimensional, mientras que la acción directa como un disparo o dar un golpe son discretas, con un único valor binario que indica si el agente puede ejecutar o no en cada ciclo de decisión.

1.2.6. Red neuronal y Deep Learning

Una red neuronal artificial es un modelo computacional inspirado en la estructura del sistema nervioso biológico, compuesto por capas de unidades de cómputo interconectadas denominadas neuronas. El Deep Learning hace referencia al uso de redes neuronales con múltiples capas ocultas, capaces de aprender representaciones jerárquicas de los datos de entrada. En el contexto del aprendizaje por refuerzo, la red neuronal actúa como aproximador de la función de política, transformando las observaciones del entorno en probabilidades de acción.

1.2.7. Gamma

Gamma es un hiperparámetro comprendido entre 0 y 1 que pondera la importancia de las recompensas futuras respecto a las inmediatas en el cálculo del retorno esperado. Un valor de $\gamma = 0$ lleva al agente a optimizar únicamente la recompensa inmediata, mientras que $\gamma = 1$ otorga igual peso a todas las recompensas futuras independientemente de su distancia temporal.

1.2.8. Curriculum Learning

El curriculum learning es una estrategia de entrenamiento que organiza las experiencias de aprendizaje en orden creciente de dificultad, de forma análoga a como los sistemas educativos humanos introducen los conceptos más simples antes de los más complejos. Formalizado por Bengio et al. (2009), este enfoque permite que el agente consolide comportamientos fundamentales en entornos controlados antes de enfrentarse a situaciones más exigentes, mejorando tanto la velocidad de convergencia como la robustez de la política aprendida.

1.2.9. Self-play

El self-play es una técnica de entrenamiento multiagente en la que el agente aprende enfrentándose a versiones de sí mismo. Este mecanismo genera un proceso de coevolución en el que cada mejora de un agente actúa como un nuevo reto para su oponente, impulsando un ciclo continuo de perfeccionamiento mutuo. Para evitar la sobrespecialización frente a un único oponente, se mantiene una pool de políticas contra las que el agente en entrenamiento compite de forma aleatoria, garantizando la diversidad de los oponentes y la generalidad de la política resultante.

1.2.10. Sistema de ELO

El sistema de ELO es un método de valoración de la habilidad relativa entre competidores, originalmente diseñado para el ajedrez por Arpad Elo (1978) y posteriormente adoptado de forma generalizada en sistemas de clasificación competitiva. En el contexto del aprendizaje por refuerzo con self-play, el ELO proporciona una métrica objetiva del progreso del agente que no

depende de la variabilidad de la recompensa media, ya que cuantifica directamente la capacidad del agente para derrotar a oponentes de niveles de habilidad conocidos. Un incremento sostenido del ELO a lo largo del entrenamiento es la evidencia más fiable de que el agente está desarrollando estrategias genuinamente mejores.

1.2.11. Normalización de Observaciones

La normalización de observaciones es un proceso mediante el cual los valores de entrada a la red neuronal se transforman para que tengan media cero y varianza unitaria. En entornos donde las observaciones presentan escalas muy distintas, como distancias en metros junto a vectores normalizados o valores binarios, la normalización es esencial para evitar que las variables de mayor magnitud dominen el gradiente de entrenamiento y distorsionen el proceso de aprendizaje. En ML-Agents, esta operación se realiza de forma automática y acumulativa durante el entrenamiento mediante el parámetro `normalize: true`

1.3. Estado del Arte

La inteligencia artificial aplicada a los videojuegos ha experimentado una evolución significativa desde los primeros sistemas basados en reglas estáticas hasta los enfoques modernos de aprendizaje automático. Durante décadas, el comportamiento de los NPC se articuló principalmente a través de máquinas de estados finitos (Finite State Machines, FSM) y árboles de comportamiento (Behaviour Trees), técnicas que, si bien permiten definir comportamientos complejos de forma estructurada, presentan una limitación fundamental ya que requieren que el diseñador anticipe y codifique manualmente cada situación posible, lo que dificulta la adaptación del agente a entornos dinámicos o imprevistos.

Un hito relevante en la historia de la IA para videojuegos fue la implementación del sistema de Goal Oriented Action Planning (GOAP) en F.E.A.R. (Monolith Productions, 2005), descrita en detalle por su diseñador Jeff Orkin en la Game Developers Conference de 2006 (Orkin, 2006). Este sistema permitía a los agentes enemigos planificar secuencias de acciones de forma autónoma para alcanzar objetivos de alto nivel, como flanquear al jugador o buscar cobertura, combinando técnicas de búsqueda A* con una representación del estado del mundo. El resultado fue un comportamiento táctico que, más de dos décadas después, sigue siendo referenciado como uno de los ejemplos más sólidos de IA de combate en videojuegos comerciales. Sin embargo, el sistema seguía siendo determinista y dependiente del conocimiento explícito del diseñador, sin capacidad de aprendizaje autónomo.

La irrupción del aprendizaje por refuerzo profundo (Deep Reinforcement Learning, DRL) abrió la posibilidad de que los agentes aprendieran comportamientos complejos directamente a partir de la interacción con el entorno, sin necesidad de programación explícita de cada conducta. En este ámbito, los trabajos más influyentes han sido los desarrollados por DeepMind y OpenAI en entornos de juego de alta complejidad. AlphaStar (Vinyals et al., 2019) demostró que un agente entrenado mediante aprendizaje por refuerzo y self-play podía alcanzar el nivel Grandmaster en StarCraft II, un juego de estrategia en tiempo real que requiere toma de decisiones a múltiples

escalas temporales, gestión de recursos y combate táctico simultáneo. De forma paralela, OpenAI Five (OpenAI, 2019) logró superar a equipos profesionales en Dota 2, un entorno multiagente de información imperfecta con un espacio de acción de elevada dimensionalidad. Estos trabajos, aunque de una escala computacional inaccesible para la mayoría de proyectos individuales, establecieron el marco metodológico sobre el que se sustenta el presente proyecto, la combinación de aprendizaje por refuerzo, curriculum learning y self-play como estrategia para el desarrollo de agentes competitivos en entornos de combate.

2.Objetivos

El objetivo de este proyecto es el de desarrollar un agente capaz de dominar las mecánicas de un simple juego de tanques 3D mediante la herramienta de ML-Agent. El reto reside en que el agente adquiera habilidades competitivas de forma autónoma, sin la necesidad de programar comportamientos lógicos manuales o sistemas basados en reglas.

A su vez se pretende investigar como el Self-Play permite la emergencia de estrategias tácticas complejas en el entorno que serían complejas de codificar de manera tradicional. Enfatizando en una IA que evoluciona adaptándose durante el proceso de entrenamiento

3. Diseño de la Solución

Este apartado describe las decisiones de diseño adoptadas al inicio del proyecto para estructurar el desarrollo del agente autónomo, justificando las elecciones tecnológicas, arquitectónicas y metodológicas que determinaron el enfoque del trabajo.

3.1. Definición del Problema

El punto de partida del proyecto fue la definición clara del problema a resolver el cual era entrenar un agente autónomo capaz de comportarse de forma competitiva en un entorno de combate tridimensional, sin recurrir a sistemas de reglas explícitas ni a comportamientos codificados manualmente. Este objetivo se descompuso en una serie de subobjetivos ordenados por complejidad creciente

- El agente debía ser capaz de localizar un objetivo estático, acercarse a él y disparar con precisión dentro de un rango de distancia definido
- El agente debía gestionar la distancia de combate, manteniéndose en una zona de tiro óptima sin acercarse en exceso al objetivo a la vez que gestionar la recarga del disparo
- El agente debía ser capaz de rodear obstáculos que bloquean la línea de visión directa al objetivo.
- El agente debía adaptarse a comportamientos de objetivos en movimiento, anticipando su posición futura
- Dos instancias del agente debían ser capaces de competir entre sí en un escenario de combate simétrico, desarrollando táctica emergentes

Esta descomposición jerárquica de objetivos no fue arbitraria, sino que respondió a una decisión de diseño fundamental la cual era estructurar el entrenamiento como un proceso de curriculum learning en el que cada subobjetivo se consolidara antes de introducir el siguiente, evitando así la sobrecarga del espacio de aprendizaje desde las primeras fases del entrenamiento

3.2. Elección del Motor y la Plataforma de Entrenamiento

Dentro de los diferentes motores de entrenamiento posibles a escoger, Unity ML-Agents fue la opción seleccionada por las siguientes razones, la integración nativa de los ML Agents con el motor Unity permite construir entornos tridimensionales con física realista de forma ágil, a su vez proporciona una implementación consolidada de PPO optimizada para entornos de simulación incluyendo herramientas específicas como el Ray Perception Sensor 3D para la percepción del entorno, ofreciendo soporte nativo para curriculum learning y self-play, ambos necesarios para los objetivos del proyecto (Juliani et al., 2020).

3.3. Elección del Algoritmo de Aprendizaje

Dentro de las opciones disponibles en ML-Agents, se evaluaron dos algoritmos principales, PPO y SAC (Soft Actor-Critic).

SAC es un algoritmo de tipo off-policy que maximiza simultáneamente la recompensa acumulada y la entropía de la política, lo que favorece la exploración. Sin embargo, su naturaleza off-policy lo hace más complejo de combinar con técnicas de curriculum learning basadas en cambios dinámicos del entorno, ya que el replay buffer puede contener experiencias generadas bajo condiciones de dificultad distintas a las actuales.

PPO, por el contrario, es un algoritmo on-policy que garantiza que todas las experiencias utilizadas en cada actualización fueron generadas bajo la política actual, lo que lo hace especialmente adecuado para entornos donde las condiciones cambian progresivamente. Su estabilidad demostrada en entornos continuos complejos (Schulman et al., 2017) y su amplio uso en sistemas de self-play como OpenAI Five (OpenAI, 2019) lo convirtieron en la opción natural para este proyecto.

3.4. Diseño del Espacio de Observación

Una de las decisiones de diseño con mayor impacto en el rendimiento del agente fue la definición del espacio de observación, a su vez tuvo gran peso ya que su cambio durante el Curriculum Learning hubiese implicado tener que volver a iniciar de 0 las enseñanzas del agente, ya que las observaciones cambiarían y generarían conflictos con las anteriores. Se adoptó un enfoque híbrido que combina dos tipos de sensores complementarios

- Observaciones vectoriales (Space Size = 21), implementadas en el método CollectObservations del script del agente, codificarían información semántica de alto nivel como dirección y distancia al objetivo, orientación propia, alineación con el objetivo, estado del cooldown de disparo, velocidad del objetivo. Adicionalmente, se incorporaron dos observaciones específicas para la detección de línea de visión, un valor binario que indica si existe visión directa al objetivo y la distancia normalizada al primer obstáculo interceptado por el rayo.
- Ray Perception Sensor 3D, configurado como componente independiente de Unity ML-Agents, lanza rayos en un semicírculo de 90° frente al agente para detectar la presencia y distancia de paredes y obstáculos. Al ser un sensor gestionado automáticamente por el framework, sus observaciones se añaden al vector de entrada de la red sin modificar el Space Size vectorial, lo que permite modificar su configuración entre fases de entrenamiento sin invalidar el modelo previamente entrenado.

Esta separación entre observaciones semánticas y perceptuales respondió a una decisión de diseño deliberada ya que las observaciones vectoriales proporcionan al agente el conocimiento necesario para razonar sobre el objetivo, mientras que el sensor de rayos le proporciona la conciencia espacial necesaria para navegar el entorno sin colisionar con obstáculos.

3.5. Diseño del Espacio de Acción

El espacio de acción del agente se diseñó como un espacio híbrido que combina acciones continuas y discretas, reflejando la naturaleza física del sistema de control de un vehículo de combate

- ContinuousActions[0]: valor en el rango $[-1, 1]$ que controla el movimiento de avance y retroceso del tanque.
- ContinuousActions[1]: valor en el rango $[-1, 1]$ que controla la velocidad y dirección de rotación.
- DiscreteActions[0]: valor binario (0 o 1) que determina si el agente dispara en el ciclo de decisión actual.

La decisión de implementar la rotación como acción continua en lugar de discreta responde a la necesidad de obtener un control fluido y preciso en la alineación con objetivos en movimiento. Un espacio de rotación discreto habría forzado al agente a alternar entre rotación máxima y ninguna rotación, generando oscilaciones en la alineación que dificultarían el aprendizaje del disparo predictivo.

3.6. Diseño del Sistema de Recompensas

El diseño de la función de recompensa fue el aspecto de mayor complejidad y mayor impacto en la convergencia del entrenamiento. Se adoptó una arquitectura de recompensas jerárquica en la que cada señal tiene un propósito específico y una magnitud calibrada para reflejar su importancia relativa, sobre todo dotando de mayor recompensa a aquellas acciones que se esperaban conseguir, como lograr disparar de manera correcta al objetivo.

Es importante el trabajo tras esta calibración ya que un desbalance en el puntaje puede llevar a la supresión de acciones del agente o la aparición de comportamientos no deseados por este

SEÑAL	VALOR	PROPOSITO
Impacto al Objetivo	+10	Recompensa terminal, objetivo principal
Disparo bien alineado	+1	Refuerzo inmediato del disparo correcto
Posición perfecta con LOS	+0.002/paso	Incentivar el posicionamiento de combate
Alineación con LOS	+0.003/paso	Guiar la rotación hacia el objetivo
Recuperación de LOS	+0.05	Reforzar el rodeo de obstáculos
Penalización de tiempo	-0.5/episodio	Presión para resolver el episodio eficientemente
Disparo sin LOS	-0.05	Desincentivar disparos a través de paredes
Colisión con borde	-0.3	Evitar salir del área de combate

Tabla 1. Relación de recompensas y acciones

Una decisión crítica fue no penalizar el cooldown de disparo como acción ya que si el agente intenta disparar durante el período de recarga, simplemente no ocurre nada. Esta decisión evitó que el agente aprendiera a suprimir la acción de disparo por miedo a penalizaciones, manteniendo activa la exploración del comportamiento de tiro.

3.7. Estrategia de Entrenamiento por Fases

La estrategia de entrenamiento se diseñó como una secuencia de cinco fases de complejidad creciente, gestionadas mediante el sistema de curriculum learning de ML-Agents a través de parámetros de entorno dinámicos.

- Fase 1: Objetivo estático sin obstáculos, el agente aprende los comportamientos fundamentales de aproximación, alineación y disparo en un entorno sin elementos perturbadores.
- Fase 2: Objetivo estático con obstáculos, se introduce una pared posicionada entre el agente y el objetivo, con dificultad progresiva controlada por el parámetro `obstacle_offset`. El agente aprende a detectar el bloqueo de la línea de visión y a reposicionarse para obtener un ángulo de tiro libre.
- Fase 3: Objetivo en movimiento sin obstáculos, se activa el movimiento del objetivo, obligando al agente a desarrollar capacidad de seguimiento y disparo predictivo.
- Fase 4: Objetivo en movimiento con obstáculos, se activan tanto la aparición de obstáculos como el movimiento del target, buscando combinar ambos conocimientos adquiridos.
- Fase 5: Self-play, dos instancias del agente compiten entre sí en un escenario simétrico 1 contra 1, con pared de aparición aleatoria. El progreso se monitoriza mediante el sistema ELO.

Cada fase se inicia a partir del modelo entrenado en la fase anterior mediante el parámetro `--initialize-from` del trainer, preservando el conocimiento adquirido y reduciendo el tiempo de convergencia en cada nueva etapa.

4.Desarrollo

4.1. Arquitectura del Sistema




Figura 1. Diagrama de clases del proyecto

El sistema se articula en torno a cinco componentes principales que interactúan mediante referencias directas y eventos de física, todos ellos coordinados por el framework ML-Agents a través de un canal de comunicación TCP entre Unity y el trainer de Python.

- TankMLAgent es el componente central del sistema. Hereda de Unity.MLAgents.Agent e implementa los tres métodos fundamentales del ciclo de aprendizaje, CollectObservations, que construye el vector de 21 observaciones enviado a la red neuronal, OnActionReceived, que recibe las acciones calculadas por la política y las aplica sobre el Rigidbody y OnEpisodeBegin, que gestiona el reinicio del entorno al inicio de cada episodio. Mantiene referencias directas a TargetMovePosition y SelfPlayAreaManager para coordinar el estado del entorno, y crea instancias de BulletDetection en cada disparo ejecutado.

```

public override void CollectObservations(VectorSensor sensor)
{
    Vector3 toTarget = _target.transform.position - transform.position;
    float dist = toTarget.magnitude;
    Vector3 dirToTarget = dist > 0.001f ? toTarget / dist : transform.forward;

    sensor.AddObservation(dirToTarget); // 1-3
    sensor.AddObservation(Mathf.Log(1 + dist) / 10f); // 4
    sensor.AddObservation(transform.forward); // 5-7

    float alignment = Vector3.Dot(transform.forward, dirToTarget);
    sensor.AddObservation(alignment); // 8

    bool isReady = (StepCount - _lastShotStep) >= _shotCooldownSteps;
    sensor.AddObservation(isReady ? 1f : 0f); // 9
    sensor.AddObservation(Mathf.Clamp01(dist / _maxShootDistance)); // 10

    Vector3 targetVel = _targetRb != null ? _targetRb.velocity : Vector3.zero;
    Vector3 targetVelDir = targetVel.magnitude > 0.001f
        ? targetVel.normalized : Vector3.zero;
    sensor.AddObservation(targetVelDir); // 11-13
    sensor.AddObservation(Mathf.Log(1 + targetVel.magnitude) / 5f); // 14

    sensor.AddObservation(_rb.velocity.magnitude / 10f); // 15

    Vector3 agentVelDir = _rb.velocity.magnitude > 0.001f
        ? _rb.velocity.normalized : Vector3.zero;
    sensor.AddObservation(agentVelDir); // 16-18

    float maxLevel = Academy.Instance.EnvironmentParameters
        .GetWithDefault("max_level", 3f);
    sensor.AddObservation(_currentLevel / maxLevel); // 19

    // LOS con LayerMask - solo detecta Obstacle y Border
    Vector3 rayOrigin = transform.position + Vector3.up * 0.5f;
    _hasLineOfSight = false;
    float wallDist = 0f;

    if (Physics.Raycast(rayOrigin, dirToTarget, out RaycastHit hit, dist, _losBlockingLayers))
    {
        _hasLineOfSight = false;
        wallDist = Mathf.Clamp01(hit.distance / dist);
    }
    else
    {
        _hasLineOfSight = true;
        wallDist = 1f;
    }

    sensor.AddObservation(_hasLineOfSight ? 1f : 0f); // 20
    sensor.AddObservation(wallDist); // 21
    // TOTAL: 21 - Space Size no cambia
}

```

Figura 2. Función CollectObservation Nativa de MLAgent con las 21 observaciones

- BulletDetection gestiona el ciclo de vida de cada proyectil. Mantiene una referencia al agente propietario para reportar recompensas cuando el proyectil impacta al objetivo, al borde de la arena o a un obstáculo. Implementa un flag `_hasHit` para garantizar que cada proyectil reporta recompensa como máximo una vez, evitando colisiones múltiples en el mismo frame.
- TargetMovePosition controla el comportamiento cinemático del objetivo. En fases avanzadas del entrenamiento, este se mueve mediante `Rigidbody.MovePosition` para que su velocidad sea observable por el agente a través de `_targetRb.velocity`.
- ObstacleSpawner posiciona dinámicamente la pared de obstáculo al inicio de cada episodio, calculando una posición aleatoria en el punto medio entre el tanque y el objetivo mediante el parámetro `obstacle_offset` recibido del trainer de Python.
- SelfPlayAreaManager coordina el reinicio de ambos tanques en la fase de self-play, gestionando el posicionamiento simétrico izquierda-derecha y el spawn aleatorio de la pared de combate.




Figura 3. Diagrama de comunicación entre Unity y Python

Respecto al flujo de comunicación, ML-Agents establece un canal TCP en el puerto 5004 entre Unity y el trainer Python. En cada Decision Period, la Academy solicita una decisión al agente, que construye el vector de observaciones y lo envía al trainer. El trainer ejecuta la inferencia de la red neuronal y devuelve el vector de acciones, que Unity aplica sobre la física del agente. La recompensa acumulada durante los pasos intermedios se envía a Python al finalizar el Decision Period, donde se almacena en el experience buffer para la siguiente actualización de los pesos de la red mediante PPO.

4.2. Implementación del Entorno de Entrenamiento

El entorno de entrenamiento fue diseñado con el objetivo de proporcionar condiciones de simulación físicamente coherentes que permitieran al agente desarrollar comportamientos de control motor estables antes de enfrentarse a los retos de mayor complejidad del curriculum.

La arena de entrenamiento consiste en una superficie plana delimitada por paredes de borde etiquetadas con el tag border, con una escala de 50×1×50 unidades en Unity, lo que proporciona un área de juego de 25 unidades de radio desde el centro. Esta dimensión fue elegida deliberadamente para que el rango máximo de disparo del agente de 10 unidades represente aproximadamente el 40% del radio de la arena, garantizando que el agente deba desplazarse activamente para alcanzar al objetivo en lugar de poder disparar desde su posición inicial.

La configuración del Rigidbody fue uno de los aspectos más determinantes para la estabilidad del entrenamiento ya que el tanque debía de rotar y moverse dependiendo de las condiciones del nivel. Los parámetros definitivos adoptados fueron

Parámetro	Valor	Justificación
Masa	1	Masa normalizada para simplificar el cálculo de fuerzas
Drag	3	Frenado lineal suficiente para detener el tanque sin input
Angular Drag	10	Amortigua las oscilaciones de rotación generadas por AddTorque
Use Gravity	✓	Mantiene el tanque anclado al suelo de forma natural
Freeze Position Y	✓	Evita desplazamientos verticales por colisiones
Freeze Rotation X, Z	✓	Impide volcamientos por colisiones con obstáculos
Collision Detection	Continuous Speculative	Evita que las balas atraviesen el tanque a alta velocidad

Tabla 2. Relación parámetros del Rigidbody y su valor

El valor de Angular Drag = 10 fue especialmente crítico. Con el sistema de rotación basado en AddTorque, un angular drag bajo producía oscilaciones en la orientación del tanque que generaban señales de alineación inconsistentes, dificultando que el agente aprendiera a mantener el forward apuntando al objetivo de forma estable.

El componente DecisionRequester se configuró con un Decision Period de 5 frames físicos. Con un Fixed Timestep de Unity de 0.02 segundos, cada ciclo de decisión del agente corresponde a 0.1 segundos de tiempo de simulación. Esta frecuencia representa un equilibrio entre la reactividad del control y la eficiencia del entrenamiento. El parámetro Take Actions Between Decisions se mantuvo activo para que la física del agente continuara aplicando las últimas acciones recibidas entre ciclos de decisión, evitando movimientos entrecortados.




Figura 4. Componente Decision Requester

Para acabar, para agilizar los entrenamientos, se duplicaron en muchas zonas, cada zona de entrenamiento para que hubiese muchos más tanques aprendiendo a la vez el mismo comportamiento, de esta manera se logra agilizar y obtener resultados de manera más rápida lo que permite de manera más rápida saber si el entrenamiento está siendo próspero o no, pero con la contraparte que igual que tener más zonas de entrenamiento permite mayor variación de aprendizaje y mayor velocidad, también puede afectar en este, ya que si tenemos por ejemplo 12 zonas de entrenamiento, 2 de ellas pueden fallar a la hora de aprender y debido a que la mente es compartida, esto afecta directamente al entrenamiento mismo. Aún así dentro de la práctica esta es la manera de encarar los entrenamientos ya que lo más importante de estos es empezar a desarrollar comportamientos para evaluar la efectividad temprana del entrenamiento y saber si hace falta pararlo y reformular los valores y código o por otra parte merece la pena seguir entrenando.

4.3. Implementación del Agente

```
0 referencias
public override void OnActionReceived(ActionBuffers actions)
{
    if (_reseting) return;

    if (MaxStep > 0)
        AddReward(-0.5f / MaxStep);

    _distance = Vector3.Distance(transform.position, _target.transform.position);
    _alignment = Vector3.Dot(
        transform.forward,
        (_target.transform.position - transform.position).normalized
    );

    float moveInput = actions.ContinuousActions[0];
    float rotateInput = actions.ContinuousActions[1];
    bool shootInput = actions.DiscreteActions[0] == 1;

    ApplyRotation(rotateInput);
    ApplyMovement(moveInput);
    RewardAlignment(rotateInput);
    RewardAnticipation();
    HandleShoot(shootInput);
    RewardDistance();

    // Actualizar LOS del frame anterior AL FINAL del step
    _hadLineOfSightLastStep = _hasLineOfSight;
}
```

Figura 5. Función OnActionReceived Nativa de MAgent con las funciones de movimiento y recompensas

4.3.1. Sistema de Movimiento

El movimiento del tanque se implementa mediante manipulación directa de la propiedad velocity del Rigidbody, proyectando la fuerza únicamente sobre el eje forward del agente para garantizar que el tanque solo pueda avanzar o retroceder en la dirección en que está orientado, simulando el comportamiento real de un vehículo de cadenas:

```
1 referencia
private void ApplyMovement(float moveInput)
{
    if (Mathf.Abs(moveInput) < 0.05f)
    {
        _rb.velocity = Vector3.Lerp(
            _rb.velocity,
            new Vector3(0, _rb.velocity.y, 0),
            Time.deltaTime * 4f
        );
        return;
    }

    Vector3 targetVelocity = transform.forward * moveInput * _movementForce * Time.deltaTime;
    Vector3 verticalVel = Vector3.up * _rb.velocity.y;
    _rb.velocity = Vector3.Lerp(
        _rb.velocity, targetVelocity + verticalVel, Time.deltaTime * 8f
    );
}
```

Figura 6. Función ApplyMovement donde se ejerce el movimiento del tanque

La interpolación mediante Lerp con factor $\text{Time.deltaTime} * 8f$ introduce una inercia artificial que suaviza los cambios bruscos de velocidad, produciendo un movimiento más orgánico y reduciendo las oscilaciones físicas que dificultaban el aprendizaje del control de distancia. Cuando el input de movimiento cae por debajo de 0.05, se aplica un frenado progresivo que decae la velocidad horizontal hacia cero preservando la componente vertical, evitando que el tanque flote sobre el suelo

4.3.2. Sistema de Rotación

La rotación fue el aspecto de mayor complejidad en la implementación del control físico. El sistema original utilizaba `transform.Rotate()` combinado con el reseteo manual de `angularVelocity`, generando conflictos entre el sistema de transformación de Unity y el motor de físicas del Rigidbody. La solución implementada rota mediante `AddTorque` con un sistema de control proporcional implícito

```

// Referencia
private void ApplyRotation(float rotateInput)
{
    float threshold = _alignment > _desireRotation ? 0.15f : 0.05f;
    if (Mathf.Abs(rotateInput) < threshold) rotateInput = 0f;

    float targetAngularVel = rotateInput * _rotateSpeed * Mathf.Deg2Rad;
    float torque = (targetAngularVel - _rb.angularVelocity.y) * _angularDrag;
    _rb.AddTorque(Vector3.up * torque, ForceMode.Acceleration);
}

```

Figura 7. Función ApplyRotation donde se ejerce la rotación del tanque

Este enfoque calcula el error entre la velocidad angular deseada y la actual, y aplica un torque proporcional a ese error escalado por el `_angularDrag`. El resultado es un controlador proporcional que acelera la rotación cuando está por debajo del objetivo y la frena cuando la supera, eliminando las oscilaciones del sistema anterior sin comprometer la naturaleza física del movimiento.

Se implementó además una zona muerta dinámica sobre el input de rotación cuando el agente ya está bien alineado con el objetivo (`_alignment > _desireRotation`), el umbral de zona muerta se eleva de 0.05 a 0.15, reduciendo las correcciones innecesarias de orientación una vez alcanzada la alineación deseada.

4.3.3. Sistema de Observaciones

Como se ha comentado anteriormente el vector de observaciones del agente tiene un tamaño fijo de 21 valores (Space Size = 21), diseñado para permanecer invariante a lo largo de todas las fases del curriculum y del self-play.

Obs	Dimensión	Contenido	Propósito
1-3	Vector3	Dirección normalizada al objetivo	Guiar la aproximación
4	Float	$\log(1 + \text{dist}) / 10$	Distancia suavizada
5-7	Vector3	<code>transform.forward</code>	Orientación propia
8	Float	<code>Dot(forward, dirToTarget)</code>	Alineación con el objetivo
9	Float	Cooldown listo (0/1)	Estado del sistema de disparo
10	Float	$\text{dist} / \text{maxShootDistance}$	Distancia relativa al rango
11-13	Vector3	Velocidad normalizada del objetivo	Anticipar trayectoria
14	Float	$\log(1 + \text{targetVel.magnitude}) / 5$	Rapidez del objetivo

15	Float	rb.velocity.magnitude / 10	Velocidad propia
16-18	Vector3	Dirección de velocidad propia	Detectar movimiento hacia pared
19	Float	currentLevel / maxLevel	Fase del curriculum activa
20	Float	LOS libre (0/1)	Línea de visión al objetivo
21	Float	Distancia normalizada al obstáculo	Posición del bloqueo

Tabla 3. Relación observaciones y sus variables internas guardadas

Las distancias se transforman mediante logaritmo natural para suavizar la escala de valores, evitando que distancias grandes dominen el gradiente de entrenamiento. Todos los vectores se normalizan antes de ser añadidos al sensor para garantizar que sus componentes permanezcan en el rango $[-1, 1]$.

Complementariamente al vector de observaciones, se añadió un componente Ray Perception Sensor 3D como sensor independiente, configurado con 4 rayos por dirección en un arco de 90° y un alcance de 8 unidades. Al ser gestionado automáticamente por ML-Agents como un sensor separado, sus observaciones se concatenan al vector principal sin modificar el Space Size de 21, permitiendo modificar su configuración entre fases de entrenamiento sin invalidar el modelo previamente entrenado.




Figura 8. Componente Ray Perception Sensor 3D preparado para la detección de paredes

4.3.4. Sistema de Disparo

El sistema de disparo incorpora varios mecanismos de seguridad para garantizar la coherencia de la señal de recompensa. Las balas se instancian con un desplazamiento de 0.5 unidades sobre el `_shootPoint.forward` respecto al punto de disparo, evitando que el proyectil nazca dentro del collider del tanque

```
private void ExecuteShoot()
{
    Vector3 spawnPos = _shootPoint.position + _shootPoint.forward * 0.5f;
    GameObject bullet = Instantiate(_bulletPrefab, spawnPos, _shootPoint.rotation);

    Rigidbody bulletRb = bullet.GetComponent<Rigidbody>();
    bulletRb.velocity = _shootPoint.forward * _bulletSpeed;

    BulletDetection bd = bullet.GetComponent<BulletDetection>();
    bd.SetOwner(this);
    bd.ExecuteDestroy();
}
```

Figura 9. Función `ExecuteShoot` donde se genera la bala del tanque

El cooldown de disparo se implementa en espacio de steps de decisión en lugar de tiempo real, mediante la variable `_lastShotStep`. Con `_shotCooldownSteps = 150` y `Decision Period = 5`, el intervalo entre disparos equivale a 15 segundos de simulación. Cuando el agente intenta disparar sin cumplir las condiciones necesarias, la acción se descarta sin consumir el cooldown, evitando que el agente aprenda a suprimir la acción de disparo por miedo a malgastar la recarga.

La recompensa por disparo se recalcula en el momento exacto de la ejecución, no en el momento de la decisión, para compensar el desfase temporal entre ambos instantes

```
private void HandleShoot(bool wantsShoot)
{
    bool cooldownOk = (StepCount - _lastShotStep) >= _shotCooldownSteps;
    bool inRange = _distance <= _maxShootDistance;
    bool inZone = _distance < _maxShootDistance * 0.6f;
    bool aligned = _alignment > _desireRotation;

    if (_hasLineOfSight && !_hadLineOfSightLastStep && inRange)
        AddReward(0.05f);

    if (inRange && !inZone && aligned && cooldownOk && _hasLineOfSight)
        AddReward(0.002f);

    if (!_hasLineOfSight && inRange)
        AddReward(-0.003f);

    if (!wantsShoot) return;
    if (!cooldownOk) return;

    if (!inRange)
    {
        AddReward(-0.01f);
        return;
    }
}
```

Figura 10. Función HandleShoot donde se gestiona la visibilidad y rango del tanque antes de disparar

4.3.4. Detección de Línea de Visión

La detección de línea de visión (Line of Sight, LOS) se implementa mediante un raycast con máscara de capas que ignora el suelo, el propio tanque y cualquier geometría no relevante

```
if (Physics.Raycast(rayOrigin, dirToTarget, out RaycastHit hit, dist, _losBlockingLayers))
{
    _hasLineOfSight = false;
    wallDist = Mathf.Clamp01(hit.distance / dist);
}
else
{
    _hasLineOfSight = true;
    wallDist = 1f;
}
```

Figura 11. Extracto de la función CollectObservation que gestiona paralelamente el Ray Perception la línea de visión del tanque

La variable `_losBlockingLayers` se asigna en el Inspector de Unity incluyendo únicamente las layers Obstacle y Border, garantizando que el rayo no sea interceptado por el suelo ni por otros elementos de la escena. La distancia normalizada al primer obstáculo interceptado proporciona al agente información sobre la proximidad del bloqueo, permitiéndole estimar cuánto necesita desplazarse lateralmente para recuperar la visión directa al objetivo.

4.4. Diseño y Evolución del Sistema de Recompensas

El diseño de la función de recompensa fue el aspecto de mayor iteración a lo largo del proyecto. A diferencia de los componentes de código, cuya corrección es verificable de forma determinista, el sistema de recompensas requirió múltiples ciclos de entrenamiento, observación del comportamiento emergente y ajuste de valores antes de obtener una señal que produjera los comportamientos deseados de forma consistente. Partes de estas recompensas vienen ligadas por un nivel de dificultad las cuales aumentan cuanto mayor control tiene el agente al comportamiento deseado, aumentado en muchos casos las recompensas negativas para acabar de evitar comportamientos no deseados.

El sistema de recompensas se diseñó siguiendo tres principios fundamentales. En primer lugar, la jerarquía de objetivos, la magnitud de cada señal debe reflejar su importancia relativa en la estrategia global del agente, de forma que el comportamiento óptimo sea siempre aquel que maximiza las recompensas de mayor magnitud. En segundo lugar, la condicionalidad, una recompensa por un comportamiento intermedio solo debe activarse si ese comportamiento es realmente útil en el contexto actual, recompensar la alineación cuando no existe línea de visión, por ejemplo, incentiva al agente a apuntar a las paredes en lugar de rodearlas. En tercer lugar, la proporcionalidad temporal, las recompensas acumuladas por comportamientos sostenidos como alineación o distancia deben ser suficientemente pequeñas para no competir con la

recompensa terminal del impacto, evitando que el agente aprenda a quedarse inmóvil en posición perfecta sin disparar nunca.

Señal	Valor	Condición de Activación
Impacto al objetivo	+10.0	Bala contacta con el objetivo (BulletDetection)
Disparo bien alineado	+1.0	alignedNow && !inZoneNow en el momento del disparo
Recuperación de LOS	+0.05	_hasLineOfSight && !_hadLineOfSightLastStep
Posición perfecta con LOS	+0.002/paso	inRange && !inZone && aligned && cooldownOk && hasLOS
Alineación con LOS	+0.003/paso	alignment > _desireRotation && hasLineOfSight
Distancia ideal con LOS	+0.003/paso	minIdeal $\leq$ dist $\leq$ maxIdeal && alignment > 0 && hasLOS
Velocidad de acercamiento	+0.001·v/paso	Agente fuera de rango moviéndose hacia el objetivo
Penalización de tiempo	-0.5/episodio	Constante, distribuida en -0.5/MaxStep por paso
Disparo sin LOS	-0.05	Intento de disparo con línea de visión bloqueada
Sin LOS en rango	-0.003/paso	!hasLineOfSight && inRange
Distancia sin LOS	-0.003/paso	Distancia ideal pero sin línea de visión
Colisión con borde	-0.3	OnCollisionEnter con tag border
Colisión con obstáculo	-0.15	OnCollisionEnter con tag obstacle
Bala expirada en vuelo	-0.1	BulletExpired() tras 3 segundos sin impacto
Bala impacta borde	-1.0·(1+nivel·0.2)	Bala contacta con border
Bala impacta obstáculo	-0.5	Bala contacta con obstacle

Tabla 4. Relación entre acciones y recompensas finales

A lo largo del proceso de entrenamiento se identificaron tres problemas recurrentes que exigieron modificaciones sustanciales del sistema de recompensas.

El primero fue el mínimo local de oscilación. En las primeras versiones, el agente desarrollaba el comportamiento de avanzar y retroceder en el centro de la arena sin aproximarse al objetivo ni disparar. El análisis de las recompensas reveló que las señales de alineación y distancia acumuladas durante 800 decisiones por episodio superaban la recompensa terminal del impacto

```
800 decisiones × 0.016 (recompensas por paso) = 12.8
Penalización de tiempo                        = -0.5
Balance sin disparar                          = +12.3 > +10 (impacto)
```

Figura 12. Cálculo que muestra el problema de unas recompensas desniveladas

La solución fue reducir las recompensas por paso en un orden de magnitud de 0.003 a 0.0005 y añadir el bonus de posición perfecta condicionado a la disponibilidad del cooldown, convirtiendo el estado estático sin disparar en una estrategia no rentable.

El segundo problema fue la parálisis ante obstáculos. Cuando se introdujo la pared en la fase 2 del currículum, el agente dejaba de moverse, apuntando permanentemente a la pared. El diagnóstico identificó dos causas, la recompensa de alineación compensaba exactamente la penalización por ausencia de LOS $+0.003 - 0.003 = 0$, haciendo que quedarse inmóvil fuera equivalente a moverse y el raycast de LOS sin máscara de capas interceptaba el suelo, haciendo que `_hasLineOfSight` fuera casi siempre false incluso sin obstáculo real. Las soluciones fueron desactivar la recompensa de alineación cuando no existe LOS y añadir `_losBlockingLayers` al raycast.

El tercer problema fue la dificultad de disparar tras rodear un obstáculo. Una vez que el agente aprendía a rodear la pared, le costaba completar el disparo porque tras el rodeo quedaba en una posición oblicua respecto al objetivo con el cooldown potencialmente agotado. Se añadió el bonus de recuperación de LOS $+0.05$ para reforzar de forma inmediata el comportamiento de rodeo.

La tabla siguiente resume la evolución de los parámetros más relevantes a lo largo de las distintas iteraciones del proyecto

Parámetro	v1 (original)	v2 (mínimo local)	v3 (parálisis)	v4 (final)
Impacto objetivo	+10.0	+10.0	+10.0	+10.0
Disparo alineado	+1.0	+1.0	+1.0	+1.0
Alineación/paso	+0.003	+0.0005	+0 sin LOS	+0.003 con LOS
Distancia/paso	+0.008	+0.0005	+0 sin LOS	+0.003 con LOS
Posición perfecta	+0.01	+0.002	+0.002	+0.002 con LOS
Recuperación LOS	—	—	+0.05	+0.05

Penalización tiempo	-1/MaxStep	-0.5/MaxStep	-0.5/MaxStep	-0.5/MaxStep
Disparo sin LOS	—	-0.15 ejecuta	-0.05 no ejecuta	-0.05 sin cooldown

Tabla 5. Relación entre los cambios en las recompensas durante el desarrollo

4.5. Configuración del entrenamiento

La configuración del entrenamiento se articuló en dos elementos principales, los hiperparámetros del algoritmo PPO definidos en el archivo YAML, y el sistema de curriculum learning implementado mediante parámetros de entorno dinámicos gestionados desde el trainer de Python

4.5.1. Hiperparámetros PPO

Igual que las recompensas, los hiperparámetros son unas variables que requirieron mucho trabajo y testeo durante el desarrollo del proyecto para adecuar lo mayor posible los parámetros encontrados en Unity y los parámetros que obtendría el trainer. A su vez dentro de las diferentes fases se optaron por pequeñas modificaciones para beneficiar el entrenamiento. Aún así muchos de los valores quedaron igual en todas las fases.

Parámetro	Valor	Justificación
batch_size	1024	Lotes suficientemente grandes para estimaciones de gradiente estables con 21 observaciones
buffer_size	40960	Buffer amplio para garantizar diversidad de experiencias en entornos con curriculum
learning_rate	0.0001	Tasa conservadora que preserva el conocimiento adquirido entre fases del curriculum
beta	0.005	Coeficiente de entropía moderado que mantiene exploración sin desestabilizar la política
epsilon	0.2	Clipping estándar de PPO: la política no puede cambiar más de un 20% por actualización
lambd	0.95	Factor GAE que equilibra sesgo y varianza en la estimación de ventaja
num_epoch	3	Número de épocas por buffer; valores más altos incrementan el riesgo de sobreajuste
gamma	0.995	Factor de descuento largo para conectar el posicionamiento con el

		disparo futuro
time_horizon	128	Horizonte temporal suficiente para cubrir el ciclo rodeo-reposicionamiento-disparo
hidden_units	256	Capacidad de red suficiente para la complejidad del espacio de observación
num_layers	3	Profundidad necesaria para aprender relaciones no lineales entre observaciones
normalize	true	Normalización de observaciones imprescindible dada la disparidad de escalas

Tabla 6. Hiperparámetros del YMAL finales

La elección de $\gamma = 0.995$ merece una justificación específica. Con un cooldown de 150 pasos de decisión entre disparos, la recompensa del impacto puede producirse hasta 150 pasos después de la decisión de posicionamiento que la hizo posible. Con $\gamma = 0.99$, esa recompensa futura vale $0.99^{150} \approx 0.22$ en el momento de la decisión, lo que la hace prácticamente invisible para el agente. Con $\gamma = 0.995$, el mismo retorno vale $0.995^{150} \approx 0.47$, otorgándole suficiente peso para que el agente aprenda a planificar el posicionamiento con antelación.

De forma análoga, $\text{time_horizon} = 128$ garantiza que en cada ventana de experiencia el agente pueda observar las consecuencias completas del ciclo de rodeo de un obstáculo, que en condiciones normales ocupa entre 60 y 100 pasos de decisión.

```

behaviors:
  Testml:
    trainer_type: ppo
    hyperparameters:
      batch_size: 1024
      buffer_size: 40960
      learning_rate: 0.0001
      beta: 0.005
      epsilon: 0.2
      lambda: 0.95
      num_epoch: 3
      learning_rate_schedule: linear
    network_settings:
      normalize: true
      hidden_units: 256
      num_layers: 3
      vis_encode_type: simple
    reward_signals:
      extrinsic:
        gamma: 0.95
        strength: 1.0
      curiosity:
        gamma: 0.99
        strength: 0.001
        network_settings:
          hidden_units: 64
          learning_rate: 0.0001
    self_play:
      save_steps: 50000
      team_change: 100000
      swap_steps: 2000
      window: 10
      play_against_latest_model_ratio: 0.5
      initial_elo: 1200
    keep_checkpoints: 10
    max_steps: 10000000
    time_horizon: 128
    summary_freq: 12000
    threaded: true

```

Figura 13. Hiperparámetros del YMAL completo

4.5.2. Señales de recompensa adicionales

Además de la recompensa extrínseca, se utilizó la señal de curiosity durante las fases de entrenamiento con objetivo en movimiento y obstáculos dinámicos.

```

curiosity:
  gamma: 0.99
  strength: 0.001
  network_settings:
    hidden_units: 64
    learning_rate: 0.0001

```

Figura 14. Parámetros de Curiosity del YMAL

La señal de curiosity implementa un modelo de predicción del siguiente estado, el agente recibe una recompensa intrínseca proporcional al error de predicción de su propio modelo interno, incentivando la exploración de transiciones de estado que no ha visto con frecuencia. Con strength 0.001, esta señal es suficientemente débil para no interferir con la recompensa extrínseca, pero suficiente para evitar que el agente quede atrapado en estados repetitivos cuando el entorno introduce nuevas condiciones.

4.5.3. Sistema de Curriculum Learning

El curriculum learning se implementó mediante dos parámetros de entorno dinámicos gestionados por el trainer de Python, `current_level`, que controla que tanto se ha avanzado en el entrenamiento y en que nivel se encuentra de dificultad, y `obstacle_offset`, que regula la dificultad de posicionamiento de la pared.

El parámetro `obstacle_offset` controla la desviación máxima de la pared respecto al punto medio exacto entre el tanque y el objetivo. Con value 1.5, la pared puede aparecer hasta 1.5 metros desplazada del centro, lo que en algunos episodios no bloquea completamente la línea de visión. Con value 0.8, la pared aparece prácticamente en el punto medio exacto, garantizando que el bloqueo sea total en todos los episodios.

El campo `signal_smoothing` true aplica una media móvil sobre la recompensa antes de compararla con el umbral, evitando que episodios excepcionalmente buenos provoquen subidas de nivel prematuras antes de que el comportamiento esté realmente consolidado. El campo `min_lesson_length` establece el número mínimo de episodios que deben transcurrir en cada lección antes de evaluar si se supera el umbral, garantizando que el agente haya tenido suficiente exposición a cada nivel de dificultad.

```

environment_parameters:
  max_level:
    sampler_type: constant
    sampler_parameters:
      value: 3

  obstacle_offset:
    curriculum:
      - name: WallEasy
        completion_criteria:
          measure: reward
          behavior: Testml
          signal_smoothing: true
          min_lesson_length: 200
          threshold: 7.0
        value: 1.5 # pared casi siempre en medio, pequeña variación
      - name: WallMedium
        completion_criteria:
          measure: reward
          behavior: Testml
          signal_smoothing: true
          min_lesson_length: 200
          threshold: 6.0
        value: 0.8 # pared muy centrada entre tanque y target
      - name: WallHard
        completion_criteria:
          measure: reward
          behavior: Testml
          signal_smoothing: true
          min_lesson_length: 200
          threshold: 5.0
        value: 0.3 # pared prácticamente exacta en el centro
      - name: WallFull
        value: 0.1

```

Figura 15. Parámetros de Environment del YMAL que controla el valor de distancia del muro

Mientras que `current_level` se aplica igual que los obstáculos solo que leyendo valores del 1-3 para ir aumentando la dificultad y el impacto en las recompensas cuando el agente empieza a comprender los comportamientos del entrenamiento.

Son luego en los script del Agente y los muros que ambos parámetros son leídos desde la Academia al inicio de cada episodio.

```
_currentLevel = Mathf.RoundToInt(  
    Academy.Instance.EnvironmentParameters.GetWithDefault("current_level", 0f)  
);
```

Figura 16. Lectura del Academy en el script del tanque para conocer en que nivel de dificultad se encuentra

```
_obstacleOffsetFromCenter = Academy.Instance.EnvironmentParameters  
    .GetWithDefault("obstacle_offset", 4f);
```

Figura 17. Lectura del Academy en el script del muro para conocer en que nivel de proximidad de muro se encuentra

4.5.4. Inicialización entre Fases

Cada fase de entrenamiento se inicializó a partir del modelo entrenado en la fase anterior mediante el parámetro `--initialize-from` del trainer

```
magents-learn config.yaml --run-id test_N --initialize-from test_{N-1}
```

Figura 18. Línea de ejecución de entrenamiento que permite partir desde un modelo mental entrenado anterior

Esta estrategia preserva los pesos de la red neuronal aprendidos en la fase anterior, reduciendo significativamente el tiempo de convergencia en cada nueva etapa. Más allá de la eficiencia computacional, este enfoque responde a una decisión metodológica deliberada, dividir un problema de aprendizaje complejo en subproblemas verificables de forma independiente evita comprometer recursos de cómputo en entrenamientos de larga duración cuya convergencia no está garantizada. Cada fase genera un modelo consolidado que actúa como checkpoint conceptual, un punto de partida cuya validez ha sido verificada empíricamente antes de introducir nueva complejidad. De este modo, cuando una fase posterior presenta dificultades de convergencia, es posible diagnosticar el problema de forma aislada sin descartar el conocimiento acumulado en las fases previas.

A su vez, inicializar desde un modelo previamente entrenado implica que el agente parte de comportamientos ya establecidos y de una distribución de recompensas positiva, en lugar de explorar aleatoriamente desde cero. Esto acelera la fase de exploración inicial y reduce el riesgo de que el agente quede atrapado en mínimos locales tempranos, ya que los comportamientos fundamentales como la aproximación al objetivo o la alineación básica están ya consolidados en los pesos de la red y no necesitan ser redescubiertos en cada nueva fase.

4.6. Resultado por Fase de Entrenamiento

Este apartado presenta y analiza los aprendizajes obtenidos en cada fase del curriculum, describiendo los comportamientos emergentes observados y los indicadores de convergencia utilizados para validar el avance entre fases

4.6.1. Fase 1: Objetivo Estático sin Obstáculo (Modelo mental 1-24)

La primera fase constituye la base del aprendizaje. El agente parte de pesos aleatorios y debe descubrir por sí mismo la estrategia de aproximación, alineación y disparo en un entorno sin elementos perturbadores.

La curva de recompensa mostró tres etapas claramente diferenciadas. Durante los primeros 150.000 pasos, la recompensa media se mantuvo en valores negativos pronunciados -22/-15, correspondientes a episodios en los que el agente no disparaba nunca o disparaba de forma completamente aleatoria. Entre los pasos 150.000 y 400.000 se produjo una recuperación progresiva hasta valores cercanos a 0, indicando que el agente había aprendido a aproximarse al objetivo pero aún fallaba frecuentemente el disparo. A partir del paso 400.000, la recompensa superó consistentemente valores positivos y siguió una tendencia ascendente hasta estabilizarse en torno a +11 con una desviación estándar inferior a 1, indicando convergencia a una política estable, teniendo en cuenta que en este entrenamiento las recompensas negativas aumentan a raíz del valor `current_level`, el puntaje muestra cómo logra evitar con mayor rigor aquellas acciones no deseadas.

Los comportamientos observados al finalizar esta fase fueron, aproximación directa al objetivo desde cualquier posición inicial, rotación hacia el objetivo con correcciones suaves, mantenimiento de la distancia de combate y disparo preciso una vez alcanzada la alineación deseada. La recompensa media de +11 correspondía aproximadamente a un impacto por episodio más las recompensas acumuladas de posicionamiento, validando que el agente disparaba y acertaba de forma consistente.




Figura 19. Gráfica de recompensas obtenidas durante el entrenamiento del modelo mental 24




Figura 20. Gráfica de duración por episodio y aumento de dificultad durante el entrenamiento del modelo mental 24

4.6.2. Fase 2: Objetivo Estático con Obstáculo (Modelo mental 25)

La introducción de una pared entre el agente y el objetivo supuso la caída más pronunciada de recompensa de todo el proyecto. Al inicializar desde el modelo mental 24 el agente partía de una recompensa media de +11, que cayó hasta valores entre -39 y -12 durante los primeros 300.000 pasos, evidenciando el fenómeno de catastrophic forgetting parcial, los comportamientos aprendidos en la fase anterior resultaban contraproducentes en el nuevo entorno porque apuntar directamente al objetivo ya no garantizaba línea de visión.

La recuperación siguió un patrón gradual correlacionado con la progresión del curriculum de obstacle_offset. Con WallEasy, offset = 1.5, el agente comenzó a recuperar valores positivos hacia el paso 500.000. La transición a WallMedium offset = 0.8 y posteriormente a WallHard offset = 0.3 produjo caídas temporales de la recompensa que se recuperaban en períodos cada vez más cortos, evidenciando una transferencia progresiva del comportamiento de rodeo. Al alcanzar WallFull offset = 0.1 en el paso 1.200.000, la recompensa media se estabilizó entre +9 y +10 con una desviación estándar de 3 a 5, validando que el agente era capaz de rodear la pared y completar el disparo de forma consistente incluso cuando el obstáculo bloqueaba completamente la línea de visión directa.

Los comportamientos emergentes más relevantes observados en esta fase fueron la detección proactiva del bloqueo de LOS antes de intentar disparar y el reposicionamiento lateral para buscar ángulos de tiro libres.




Figura 21. Gráfica de recompensas obtenidas durante el entrenamiento del modelo mental 25, donde se rompen los comportamientos del modelo mental 24




Figura 22. Gráfica de duración por episodio y aumento de dificultad durante el entrenamiento del modelo mental 25

4.6.3. Fase 3: Objetivo en Movimiento sin Obstáculo (Modelo mental 26)

La fase 3 introdujo el movimiento del objetivo, eliminando temporalmente los obstáculos para aislar el problema del seguimiento y el disparo predictivo. Al inicializar desde el modelo mental 25, la transición fue notablemente más suave que en la fase anterior, la recompensa media arrancó directamente en +11 y subió a WallHard y WallFull del curriculum de obstacle_offset en los primeros 36.000 pasos, evidenciando que los comportamientos de posicionamiento y disparo estaban suficientemente consolidados para transferirse sin degradación significativa al nuevo entorno.

La recompensa se estabilizó en torno a +11.25 con una desviación estándar excepcionalmente baja de 0.5 a 0.8, el valor más bajo registrado en todo el proyecto. Este resultado indica que el

agente desarrolló una política extremadamente consistente para el seguimiento del objetivo en movimiento, con una variabilidad mínima entre episodios. La observación de la velocidad del objetivo, observaciones 11-14 del vector, resultó determinante para este resultado, permitiendo al agente anticipar la posición futura del objetivo en lugar de reaccionar únicamente a su posición actual.




Figura 23. Gráfica de recompensas obtenidas durante el entrenamiento del modelo mental 26, partiendo de unos valores altos del modelo mental 25

4.6.4. Fase 4: Objetivo en Movimiento con Obstáculo (Modelo mental 27)

Esta fase combinó a la vez los dos elementos de dificultad trabajados de forma independiente en las fases anteriores, el objetivo en movimiento y la pared de obstáculo. Al inicializar desde el modelo mental 26, el agente partía de una política consolidada para ambos problemas por separado, pero su combinación exigió desarrollar una nueva capacidad, gestionar simultáneamente la predicción de la trayectoria del objetivo y la detección de la línea de visión bloqueada.

El comportamiento más destacado emergido en esta fase fue la espera táctica en cobertura. Cuando el objetivo se encontraba al otro lado de la pared y se aproximaba hacia el agente, este aprendió a mantenerse inmóvil en su posición en lugar de intentar rodear el obstáculo, esperando a que el objetivo apareciera por uno de los flancos de la pared para redirigir el movimiento en el momento en que la línea de visión quedará libre. Este comportamiento no fue programado explícitamente, emergió como consecuencia directa de la combinación de la penalización por disparar sin LOS, el bonus por recuperación de LOS y la observación de la velocidad del objetivo, que permitía al agente inferir que el objetivo estaba en movimiento hacia su posición aunque no pudiera verlo directamente.

La recompensa se estabilizó en torno a +10 con una desviación estándar de 3 a 5, validando que el agente era capaz de resolver el problema combinado de forma consistente antes de avanzar a la fase de self-play.




Figura 24. Gráfica de recompensas obtenidas durante el entrenamiento del modelo mental 27, partiendo de unos valores altos del modelo mental 26

4.6.5. Fase 5: SelfPlay (Modelo mental 30)

La fase de self-play introdujo la mayor complejidad del proyecto al convertir al propio agente en el oponente. A diferencia de las fases anteriores, en las que el objetivo era un elemento pasivo o con comportamiento predefinido, en esta fase ambos agentes aprenden simultáneamente el uno del otro, generando un proceso de coevolución en el que cada mejora de uno actúa como un nuevo reto para el otro.

4.6.5.1. Mecánica del SelfPlay en ML-Agents

El sistema de self-play de ML-Agents se articula en torno a cuatro parámetros configurados en el YAML, cada uno con un rol específico en la dinámica del entrenamiento.

- **save_steps:** 50000 determina cada cuántos pasos de entrenamiento el trainer guarda una instantánea del modelo actual como archivo .onnx y la añade al pool de oponentes históricos. Este pool actúa como una biblioteca de versiones pasadas del agente, con un máximo de 10 modelos almacenados simultáneamente. Cuando el pool está lleno y se añade un nuevo modelo, el más antiguo es descartado.
- **swap_steps:** 2000 determina con qué frecuencia el trainer selecciona un nuevo oponente del pool para el equipo que está congelado. En cada intercambio, **play_against_latest_model_ratio:** 0.5 establece que el 50% de las veces el oponente será la versión más reciente del modelo en entrenamiento, y el otro 50% será una versión histórica seleccionada aleatoriamente del pool. Este mecanismo garantiza la diversidad de los oponentes y evita que el agente se especialice únicamente en contrarrestar su versión más reciente, lo que llevaría a estrategias frágiles fácilmente explotables por versiones anteriores.

- `team_change`: 100000 es el parámetro que genera el patrón de dientes de sierra observable en la curva de recompensa. Cada 100.000 pasos, los roles de los dos equipos se intercambian: el equipo que estaba aprendiendo pasa a ser el oponente congelado, y el equipo que era oponente empieza a actualizar sus pesos. Durante los primeros pasos tras el cambio, el equipo que acaba de empezar a aprender pierde sistemáticamente contra el oponente congelado, lo que provoca la caída de recompensa y ELO característica de cada valle. Conforme el nuevo equipo mejora, la recompensa se recupera hasta superar el máximo del ciclo anterior.

```
learning_rate: 0.0001
self_play:
  save_steps: 50000
  team_change: 100000
  swap_steps: 2000
  window: 10
  play_against_latest_model_ratio: 0.5
  initial_elo: 1200
```

Figura 25. Configuración del SelfPlay en el YMAL

4.6.5.2. Sistema de ELO

El progreso del self-play se monitorizó mediante el sistema ELO, un método de valoración de habilidad relativa originalmente diseñado para el ajedrez (Elo, 1978) y ampliamente adoptado en sistemas de clasificación competitiva. En ML-Agents, el ELO se inicializa en `initial_elo`: 1200 y se actualiza tras cada episodio de la siguiente forma, si el agente gana, su ELO aumenta en proporción a cuánto mejor era su oponente, si pierde, disminuye en proporción a cuánto peor era el oponente. Un agente que gana consistentemente contra oponentes de ELO superior acumula puntos rápidamente, mientras que las victorias contra oponentes de ELO inferior producen incrementos mínimos.

A diferencia de la recompensa media, el ELO es una métrica robusta para el self-play porque no depende de la magnitud absoluta de las recompensas sino de los resultados relativos entre oponentes. En un escenario simétrico de suma cero, la recompensa media oscila necesariamente cerca de cero cuando ambos agentes tienen un nivel similar, lo que la hace poco informativa como indicador de progreso. El ELO, por el contrario, sube de forma acumulativa cada vez que el agente aprende a superar consistentemente versiones anteriores de sí mismo.

4.6.5.3. Análisis de la curva de ELO

La curva de ELO mostró el patrón de dientes de sierra característico del self-play con `team_change`, con picos crecientes y valles cada vez menos profundo.

Ciclo	Pasos	ELO Pico	ELO Valle	Observación
1	0-100k	1270	-	Team 0 aprende desde test_27
2	100k-200k	-	1190	Team 1 empieza a aprender
3	200k-300k	1306	-	Supera el pico anterior
4	300k-400k	-	1228	Valle menos profundo
5	400k-500k	1332	-	Nuevo máximo
6	500k-600k	-	1207	Valle mínimo del proyecto
7	600k-700k	1403	-	Primer ELO > 1400
8	700k-800k	-	1265	Valle estabilizado
9	800k-900k	1435	-	Nuevo máximo absoluto
10+	1200k+	1611	1527	Convergencia a nivel alto

Figura 7. Relación entre los pasos realizados durante el entrenamiento y la obtención de ELO del agente

Dos tendencias son especialmente relevantes en este análisis. En primer lugar, los picos de ELO crecen de forma consistente ciclo a ciclo, 1270 → 1306 → 1332 → 1403 → 1435 → 1611, evidenciando que cada ciclo de aprendizaje produce un agente genuinamente superior al anterior. En segundo lugar, los valles se vuelven progresivamente menos profundos, 1190 → 1228 → 1207 → 1265 → 1527, lo que indica que el equipo que empieza a aprender en cada ciclo parte de una base más sólida y tarda menos en alcanzar el nivel del oponente congelado. A partir del paso 1.200.000, los valles no bajaron de 1527, lo que significa que incluso en la peor fase de cada ciclo el agente mantenía un nivel notablemente superior al punto de partida. La tendencia alcista del ELO, con el techo subiendo de 1270 a 1611 en 1.6 millones de pasos, validó que el mecanismo de self-play estaba funcionando correctamente, cada ciclo de entrenamiento producía un agente marginalmente mejor que el anterior, y los valles se volvían cada vez menos profundos conforme el modelo base era más sólido.

Los tres comportamientos tácticos más relevantes emergidos durante esta fase incluyeron, conocimiento del entorno y comportamiento del rival, retroceder y engañar al rival y precisión en el disparo.




Figura 26. Gráfica de recompensas obtenidas durante el entrenamiento del modelo mental 30, donde lo logra percibir en forma de sierra debido al ELO Valle y el ELO Pico

4.7. Análisis de Comportamientos Emergentes

4.7.1. Comportamientos emergentes en las fases de curriculum

Durante la fase 4, con la introducción de la pared y el target en movimiento a la vez, el agente desarrolló la capacidad de esperar en cobertura cuando el objetivo se aproximaba. En lugar de rodear activamente el obstáculo para buscar al objetivo, el agente aprendió a mantenerse en posición cuando detectaba que el objetivo estaba en movimiento hacia su lado de la pared, esperando a que apareciera por uno de los flancos para redirigir el movimiento de manera más ágil cuando este dejase de estar cubierto. Este comportamiento emergió de la combinación de tres señales, la penalización por disparar sin LOS, el bonus por recuperación de LOS, y la observación de la velocidad del objetivo, que permitía al agente inferir el movimiento del objetivo aunque no pudiera verlo directamente

4.7.2. Comportamientos emergentes en la fase de SelfPlay

La fase competitiva produjo los comportamientos de mayor sofisticación táctica del proyecto. A diferencia de los comportamientos de las fases anteriores, estos no pueden atribuirse a señales de recompensa individuales sino a la interacción entre dos políticas que coevolucionan simultáneamente.

- Comprensión de la economía del disparo. El agente internalizó que tanto él como el oponente disponen de un único proyectil en vuelo simultáneo y que fallarlo implica un período de inactividad de disparo determinado por el cooldown. Esta comprensión se manifestó en un comportamiento observable, el agente raramente desperdicia el disparo en situaciones de baja probabilidad de impacto, esperando condiciones favorables de alineación y distancia antes de ejecutarlo. La consecuencia directa es que cuando el oponente acaba de disparar y su cooldown está activo, el agente aprovecha esa

ventana de vulnerabilidad para avanzar o reposicionarse con menor riesgo, comportamiento que no fue en ningún momento codificado explícitamente en el sistema de recompensas.

- Engaño mediante movimiento dirigido. El comportamiento tácticamente más sofisticado observado en el agente fue el uso deliberado de su propia trayectoria de movimiento para inducir al rival a tomar decisiones erróneas. El agente aprendió a orientar su desplazamiento en una dirección aparente durante el movimiento, generando en el oponente una predicción incorrecta sobre su posición futura. A continuación, el agente corregía bruscamente su dirección real, logrando que el disparo del rival fallara mientras él alcanzaba una posición de ventaja para disparar. Este comportamiento implica un nivel de planificación a varios pasos vista que va más allá de la optimización local de recompensas inmediatas, y constituye la evidencia más clara de que el self-play indujo el desarrollo de un modelo implícito del comportamiento adversario dentro de la red neuronal del agente.
- Precisión selectiva del disparo. A diferencia de comportamientos observados en modelos entrenados sin self-play, donde el agente tendía a disparar con frecuencia independientemente de las condiciones, el modelo final mostró una estrategia de disparo altamente selectiva. Cuando ambos tanques disponían simultáneamente de proyectil, el agente solo disparaba si la alineación era suficientemente elevada para que el fallo fuera prácticamente improbable. Esta selectividad emergió como consecuencia de la asimetría competitiva que introduce el cooldown, un disparo fallado no solo desperdicia el proyectil sino que deja al agente en posición de desventaja durante el período de recarga, mientras el oponente puede moverse libremente o reposicionarse para el contraataque. La red neuronal aprendió a valorar la conservación del proyectil como ventaja táctica, resultando en un agente que dispara menos pero con una tasa de acierto notablemente superior a la de versiones anteriores del modelo.

5. Conclusiones y Líneas a Futuro

5.1. Análisis Crítico del Grado de Consecución de los Objetivos

El proyecto planteaba como objetivo principal el desarrollo de un agente autónomo de combate capaz de adquirir comportamientos complejos mediante aprendizaje por refuerzo, articulado en una secuencia de subobjetivos de complejidad creciente. A continuación se evalúa el grado de consecución de cada uno de ellos.

La aproximación, alineación y disparo sobre objetivo estático se alcanzó de forma completa y satisfactoria en la primera fase de entrenamiento. El agente convergió a una política estable con recompensa media de +11 y desviación estándar inferior a 1, demostrando un comportamiento consistente y robusto en el entorno más simple.

La evasión de obstáculos y recuperación de línea de visión se alcanzó de forma funcional, aunque con mayor dificultad de la esperada. El proceso de entrenamiento reveló que el diseño inicial del sistema de recompensas incentivaba inadvertidamente la parálisis del agente frente a la pared, requiriendo múltiples iteraciones de rediseño hasta obtener una señal que produjera el comportamiento de rodeo deseado. El objetivo se considera alcanzado, con la matización de que el comportamiento de evasión presentaba cierta variabilidad en función de la posición relativa del obstáculo respecto al objetivo.

El seguimiento de objetivo en movimiento se alcanzó con los mejores resultados del proyecto. La convergencia fue rápida gracias a la transferencia desde la fase anterior, y la desviación estándar excepcionalmente baja de la fase 3 evidenció que el agente desarrolló una política de seguimiento y disparo predictivo altamente consistente.

El self-play competitivo se alcanzó parcialmente. El sistema funcionó correctamente desde el punto de vista técnico, con el ELO alcanzando 1611 puntos y mostrando una tendencia alcista sostenida a lo largo de 1.6 millones de pasos. Sin embargo, la complejidad del entorno de combate presentaba limitaciones inherentes que condicionaron el nivel de sofisticación táctica alcanzable. La arena simétrica con una única pared de posición aleatoria y dos tanques con las mismas capacidades constituye un entorno de complejidad moderada que, si bien fue suficiente para que emergieran comportamientos tácticos genuinos como el engaño mediante movimiento y la gestión del cooldown, no ofrecía la variedad situacional necesaria para desarrollar estrategias de mayor profundidad. En entornos más complejos, con múltiples obstáculos, diferentes configuraciones de arena o agentes con capacidades asimétricas, la presión selectiva del self-play habría sido sensiblemente mayor, potencialmente produciendo comportamientos de nivel superior.

5.2. Principales Aprendizajes del Proyecto

Más allá de los resultados técnicos obtenidos, el desarrollo del proyecto ha generado un conjunto de aprendizajes metodológicos de valor significativo.

El primero y más relevante es que el diseño de la función de recompensa es el componente más crítico y más difícil del aprendizaje por refuerzo aplicado. A diferencia del código convencional, cuya corrección es verificable de forma determinista, una función de recompensa

incorrecta puede producir comportamientos aparentemente razonables que en realidad corresponden a mínimos locales explotados por el agente. La única forma de validarla es observar el comportamiento emergente durante el entrenamiento e iterar, lo que exige una comprensión profunda de la dinámica de optimización del algoritmo.

El segundo aprendizaje es la importancia de separar los problemas antes de combinarlos. La estrategia de curriculum learning por fases independientes no solo aceleró la convergencia sino que facilitó el diagnóstico de problemas, cuando una fase presentaba dificultades, era posible identificar exactamente qué nueva variable introducida era la responsable, sin ambigüedad. Este enfoque contrasta con la alternativa de entrenar directamente en el entorno completo, donde la atribución de los problemas de convergencia es considerablemente más difícil.

El tercer aprendizaje es que la física del entorno y los parámetros del motor de juego tienen un impacto directo en la calidad del aprendizaje. El conflicto entre transform.Rotate y el Rigidbody, la configuración del Angular Drag, la orientación incorrecta del modelo 3D o la ausencia de Layer Collision Matrix fueron factores que produjeron comportamientos erráticos cuya causa no era evidente a primera vista. La depuración de estos problemas requirió un análisis sistemático que puso de manifiesto que en proyectos de aprendizaje por refuerzo en motores de juego, la correcta configuración del entorno físico es tan importante como el diseño del algoritmo de aprendizaje.

El cuarto aprendizaje es la naturaleza fundamentalmente empírica e iterativa del proceso de entrenamiento. Los valores de hiperparámetros, magnitudes de recompensa y parámetros de curriculum que resultaron efectivos no fueron derivados analíticamente sino a través de múltiples ciclos de entrenamiento, observación y ajuste. Esta característica implica que la experiencia acumulada en proyectos anteriores es un activo fundamental en este dominio, y que la documentación detallada de cada decisión y su justificación tiene un valor práctico directo.

5.3. Líneas a Futuro

El trabajo realizado establece una base técnica sólida sobre la que es posible avanzar en varias direcciones de machine learning de interés creciente pero también deja abierta diferentes puertas a mejoras al futuro como.

- Incremento de la complejidad del entorno de combate. La limitación más significativa del self-play desarrollado en este proyecto fue la simplicidad del entorno, una arena abierta con una única pared de posición aleatoria ofrece un espacio de situaciones tácticas reducido. Una línea de continuación directa sería el diseño de arenas con múltiples obstáculos de geometría variable, zonas de cobertura estructuradas y configuraciones asimétricas que obliguen al agente a desarrollar estrategias adaptativas en lugar de políticas fijas. Un entorno de mayor riqueza situacional sometería al self-play a una presión selectiva más intensa, potencialmente produciendo comportamientos tácticos de nivel superior a los observados en este proyecto.
- Diferenciación de tipos de agentes. El proyecto utilizó dos instancias del mismo agente con las mismas capacidades físicas. Una extensión natural sería introducir agentes con perfiles asimétricos como un tanque de mayor velocidad pero menor precisión frente a

uno más lento pero con mayor rango de disparo, por ejemplo. Esta asimetría obligaría a cada agente a explotar sus ventajas específicas y a mitigar sus debilidades frente a un oponente con capacidades diferentes, un problema significativamente más complejo que el abordado en este proyecto y más representativo de los escenarios de combate reales en videojuegos.

- Self-play de mayor rigor competitivo. Los parámetros de self-play utilizados, con `window: 10` y `play_against_latest_model_ratio: 0.5`, constituyen una configuración moderada. Una línea de mejora sería aumentar el pool de modelos históricos, reducir el ratio de juego contra el modelo actual para forzar mayor diversidad de oponentes, y aumentar el `team_change` para dar más tiempo a cada equipo de desarrollar estrategias profundas antes del intercambio. Combinado con un entorno de mayor complejidad, esta configuración podría producir una coevolución de políticas significativamente más rica.
- Introducción de escenarios multiagente cooperativos. El framework ML-Agents soporta escenarios con más de dos agentes y distintos esquemas de recompensa compartida. Una extensión ambiciosa del proyecto sería entrenar equipos de dos o tres tanques con objetivos cooperativos, donde la recompensa del equipo dependa de la coordinación entre sus miembros. Este tipo de escenario introduciría una capa adicional de complejidad en el espacio de comportamientos emergentes, abriendo la posibilidad de observar tácticas de equipo como el flanqueo coordinado o la distracción deliberada del oponente.
- Transferencia a entornos de producción. Los modelos entrenados en este proyecto operan en un entorno de simulación controlado. Una línea de trabajo de interés aplicado sería evaluar la robustez de las políticas aprendidas ante perturbaciones no presentes durante el entrenamiento, variaciones en la geometría de la arena, cambios en la velocidad de los agentes o introducción de ruido en las observaciones. Este tipo de evaluación permitiría determinar en qué medida las estrategias emergentes son genuinamente generalizables o están sobreajustadas a las condiciones específicas del entorno de entrenamiento.

6. Bibliografía

Bengio, Y., Louradour, J., Collobert, R., & Weston, J. (2009). Curriculum learning. Proceedings of the 26th Annual International Conference on Machine Learning (ICML), 41–48. <https://dl.acm.org/doi/10.1145/1553374.1553380>

Juliani, A., Berges, V. P., Teng, E., Cohen, A., Harper, J., Elion, C., Goy, C., Gao, Y., Henry, H., Mattar, M., & Lange, D. (2020). Unity: A general platform for intelligent agents. arXiv preprint arXiv:1809.02627. <https://arxiv.org/abs/1809.02627>

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533. <https://www.nature.com/articles/nature14236>

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347. <https://arxiv.org/abs/1707.06347>

Silver, D., Schrittwieser, J., Simonyan, K., Antonoglou, I., Huang, A., Guez, A., Hubert, T., Baker, L., Lai, M., Bolton, A., Chen, Y., Lillicrap, T., Hui, F., Sifre, L., van den Driessche, G., Graepel, T., & Hassabis, D. (2017). Mastering the game of Go without human knowledge. *Nature*, 550(7676), 354–359. https://discovery.ucl.ac.uk/id/eprint/10045895/1/agz_unformatted_nature.pdf

Vinyals, O., Babuschkin, I., Czarnecki, W. M., Mathieu, M., Dudzik, A., Choi, J., Powell, R., Ewalds, T., Georgiev, P., Oh, J., Horgan, D., Kroiss, M., Danihelka, I., Huang, A., Sifre, L., Cai, T., Agapiou, J. P., Jaderberg, M., Vezhnevets, A. S., ... Silver, D. (2019). Grandmaster level in StarCraft II using multi-agent reinforcement learning. *Nature*, 575(7782), 350–354. <https://www.nature.com/articles/s41586-019-1724-z>

Almón-Manzano, L., Pastor-Vargas, R., & Troncoso, J. M. C. (2022). Deep reinforcement learning in agents' training: Unity ML-Agents. *Lecture Notes in Computer Science*, 13259, 389–398. <https://portalcientifico.uned.es/documentos/6532bf8dc0b4af7ce4e86c8e>

Brockman, G., Cheung, V., Pettersson, L., Schneider, J., Schulman, J., Tang, J., & Zaremba, W. (2016). OpenAI Gym. arXiv preprint arXiv:1606.01540.

OpenAI. (2019). Dota 2 with large scale deep reinforcement learning. arXiv preprint arXiv:1912.06680. <https://arxiv.org/abs/1912.06680>

Orkin, J. (2006). Three states and a plan: The AI of F.E.A.R. Proceedings of the Game Developers Conference (GDC 2006). <https://www.gamedevs.org/uploads/three-states-plan-ai-of-fear.pdf>

Zhang, D., & Bailey, C. P. (2020). Obstacle avoidance and navigation utilizing reinforcement learning with reward shaping. arXiv preprint arXiv:2003.12863. <https://arxiv.org/abs/2003.12863>

7.Anexo

Datos extraídos del ELO del SelfPlay que muestra el avance del aprendizaje del agente y la tendencia de sierra comentada durante el desarrollo:

[INFO] Testml. Step: 12000. Time Elapsed: 23.996 s. Mean Reward: 24.484. Std of Reward: 7.039. Training. ELO: 1209.971.
[INFO] Testml. Step: 24000. Time Elapsed: 43.709 s. Mean Reward: 23.397. Std of Reward: 9.390. Training. ELO: 1216.743.
[INFO] Testml. Step: 36000. Time Elapsed: 63.464 s. Mean Reward: 24.789. Std of Reward: 10.877. Training. ELO: 1226.769.
[INFO] Parameter 'current_level' is in lesson 'LevelOne' and has value 'Float: value=1'.
[INFO] Testml. Step: 48000. Time Elapsed: 92.007 s. Mean Reward: 23.235. Std of Reward: 11.223. Training. ELO: 1234.585.
[INFO] Testml. Step: 60000. Time Elapsed: 111.781 s. Mean Reward: 21.243. Std of Reward: 10.065. Training. ELO: 1251.890.
[INFO] Testml. Step: 72000. Time Elapsed: 131.607 s. Mean Reward: 20.593. Std of Reward: 14.897. Training. ELO: 1261.453.
[INFO] Testml. Step: 84000. Time Elapsed: 160.640 s. Mean Reward: 24.587. Std of Reward: 8.595. Training. ELO: 1266.721.
[INFO] Testml. Step: 96000. Time Elapsed: 180.233 s. Mean Reward: 21.846. Std of Reward: 9.510. Training. ELO: 1270.208.
[INFO] Testml. Step: 108000. Time Elapsed: 199.952 s. Mean Reward: 6.014. Std of Reward: 15.405. Training. ELO: 1271.206.
[INFO] Testml. Step: 120000. Time Elapsed: 219.706 s. Mean Reward: -1.156. Std of Reward: 8.137. Training. ELO: 1262.958.
[INFO] Testml. Step: 132000. Time Elapsed: 248.039 s. Mean Reward: 1.688. Std of Reward: 10.718. Training. ELO: 1247.217.
[INFO] Testml. Step: 144000. Time Elapsed: 267.713 s. Mean Reward: -0.107. Std of Reward: 10.962. Training. ELO: 1236.753.
[INFO] Testml. Step: 156000. Time Elapsed: 287.411 s. Mean Reward: -0.096. Std of Reward: 9.745. Training. ELO: 1233.775.
[INFO] Testml. Step: 168000. Time Elapsed: 315.052 s. Mean Reward: -1.157. Std of Reward: 8.974. Training. ELO: 1221.299.
[INFO] Testml. Step: 180000. Time Elapsed: 335.800 s. Mean Reward: 2.521. Std of Reward: 11.566. Training. ELO: 1207.988.
[INFO] Testml. Step: 192000. Time Elapsed: 355.981 s. Mean Reward: 3.942. Std of Reward: 11.647. Training. ELO: 1199.635.
[INFO] Testml. Step: 204000. Time Elapsed: 375.985 s. Mean Reward: 4.971. Std of Reward: 12.755. Training. ELO: 1189.766.
[INFO] Testml. Step: 216000. Time Elapsed: 402.011 s. Mean Reward: 16.470. Std of Reward: 13.434. Training. ELO: 1190.444.
[INFO] Testml. Step: 228000. Time Elapsed: 421.141 s. Mean Reward: 21.014. Std of Reward: 9.467. Training. ELO: 1209.203.

[INFO] Testml. Step: 240000. Time Elapsed: 440.575 s. Mean Reward: 21.258. Std of Reward: 11.529. Training. ELO: 1228.125.

[INFO] Testml. Step: 252000. Time Elapsed: 467.120 s. Mean Reward: 18.788. Std of Reward: 12.550. Training. ELO: 1239.433.

[INFO] Testml. Step: 264000. Time Elapsed: 486.478 s. Mean Reward: 19.771. Std of Reward: 8.911. Training. ELO: 1256.091.

[INFO] Testml. Step: 276000. Time Elapsed: 506.600 s. Mean Reward: 20.169. Std of Reward: 7.996. Training. ELO: 1267.704.

[INFO] Testml. Step: 288000. Time Elapsed: 537.152 s. Mean Reward: 20.251. Std of Reward: 7.943. Training. ELO: 1286.064.

[INFO] Testml. Step: 300000. Time Elapsed: 554.596 s. Mean Reward: 20.630. Std of Reward: 6.178. Training. ELO: 1306.414.

[INFO] Testml. Step: 312000. Time Elapsed: 573.791 s. Mean Reward: 0.642. Std of Reward: 8.286. Training. ELO: 1299.228.

[INFO] Testml. Step: 324000. Time Elapsed: 592.297 s. Mean Reward: 1.488. Std of Reward: 9.424. Training. ELO: 1287.208.

[INFO] Testml. Step: 336000. Time Elapsed: 620.183 s. Mean Reward: 1.457. Std of Reward: 9.226. Training. ELO: 1270.583.

[INFO] Testml. Step: 348000. Time Elapsed: 639.135 s. Mean Reward: 2.651. Std of Reward: 9.944. Training. ELO: 1259.423.

[INFO] Testml. Step: 360000. Time Elapsed: 657.636 s. Mean Reward: 2.075. Std of Reward: 9.243. Training. ELO: 1249.946.

[INFO] Testml. Step: 372000. Time Elapsed: 685.910 s. Mean Reward: 1.723. Std of Reward: 9.865. Training. ELO: 1235.873.

[INFO] Testml. Step: 384000. Time Elapsed: 704.357 s. Mean Reward: 4.797. Std of Reward: 11.518. Training. ELO: 1228.091.

[INFO] Testml. Step: 396000. Time Elapsed: 723.215 s. Mean Reward: 2.331. Std of Reward: 10.273. Training. ELO: 1223.204.

[INFO] Testml. Step: 408000. Time Elapsed: 742.471 s. Mean Reward: 12.811. Std of Reward: 11.201. Training. ELO: 1225.943.

[INFO] Testml. Step: 420000. Time Elapsed: 770.284 s. Mean Reward: 18.652. Std of Reward: 5.366. Training. ELO: 1249.286.

[INFO] Testml. Step: 432000. Time Elapsed: 788.834 s. Mean Reward: 18.709. Std of Reward: 6.201. Training. ELO: 1265.617.

[INFO] Testml. Step: 444000. Time Elapsed: 807.645 s. Mean Reward: 18.986. Std of Reward: 5.229. Training. ELO: 1281.697.

[INFO] Testml. Step: 456000. Time Elapsed: 835.776 s. Mean Reward: 18.679. Std of Reward: 5.569. Training. ELO: 1289.854.

[INFO] Testml. Step: 468000. Time Elapsed: 855.555 s. Mean Reward: 18.967. Std of Reward: 4.247. Training. ELO: 1300.210.

[INFO] Testml. Step: 480000. Time Elapsed: 873.890 s. Mean Reward: 19.063. Std of Reward: 4.036. Training. ELO: 1317.617.

[INFO] Testml. Step: 492000. Time Elapsed: 891.790 s. Mean Reward: 19.167. Std of Reward: 4.032. Training. ELO: 1332.688.

[INFO] Exported results\test_30\Testml\Testml-499912.onnx
[INFO] Testml. Step: 504000. Time Elapsed: 919.719 s. Mean Reward: 15.037. Std of Reward: 9.327. Training. ELO: 1333.419.
[INFO] Testml. Step: 516000. Time Elapsed: 938.032 s. Mean Reward: 0.759. Std of Reward: 8.962. Training. ELO: 1320.972.
[INFO] Testml. Step: 528000. Time Elapsed: 956.054 s. Mean Reward: -0.698. Std of Reward: 7.793. Training. ELO: 1306.878.
[INFO] Testml. Step: 540000. Time Elapsed: 983.698 s. Mean Reward: 2.754. Std of Reward: 9.904. Training. ELO: 1299.659.
[INFO] Testml. Step: 552000. Time Elapsed: 1001.946 s. Mean Reward: 0.279. Std of Reward: 8.651. Training. ELO: 1288.613.
[INFO] Testml. Step: 564000. Time Elapsed: 1019.994 s. Mean Reward: 1.474. Std of Reward: 9.461. Training. ELO: 1259.845.
[INFO] Testml. Step: 576000. Time Elapsed: 1048.231 s. Mean Reward: -0.842. Std of Reward: 7.540. Training. ELO: 1240.394.
[INFO] Testml. Step: 588000. Time Elapsed: 1067.242 s. Mean Reward: -1.923. Std of Reward: 5.403. Training. ELO: 1223.950.
[INFO] Testml. Step: 600000. Time Elapsed: 1085.446 s. Mean Reward: -0.461. Std of Reward: 7.595. Training. ELO: 1207.542.
[INFO] Testml. Step: 612000. Time Elapsed: 1103.933 s. Mean Reward: 18.557. Std of Reward: 5.263. Training. ELO: 1221.165.
[INFO] Testml. Step: 624000. Time Elapsed: 1130.553 s. Mean Reward: 19.039. Std of Reward: 3.926. Training. ELO: 1236.292.
[INFO] Testml. Step: 636000. Time Elapsed: 1148.819 s. Mean Reward: 19.389. Std of Reward: 3.970. Training. ELO: 1254.089.
[INFO] Testml. Step: 648000. Time Elapsed: 1167.866 s. Mean Reward: 19.738. Std of Reward: 3.115. Training. ELO: 1276.690.
[INFO] Testml. Step: 660000. Time Elapsed: 1195.759 s. Mean Reward: 19.916. Std of Reward: 2.713. Training. ELO: 1301.888.
[INFO] Testml. Step: 672000. Time Elapsed: 1215.165 s. Mean Reward: 19.737. Std of Reward: 2.362. Training. ELO: 1345.059.
[INFO] Testml. Step: 684000. Time Elapsed: 1233.713 s. Mean Reward: 18.918. Std of Reward: 4.629. Training. ELO: 1377.153.
[INFO] Testml. Step: 696000. Time Elapsed: 1251.679 s. Mean Reward: 19.039. Std of Reward: 4.308. Training. ELO: 1403.312.
[INFO] Testml. Step: 708000. Time Elapsed: 1280.207 s. Mean Reward: 5.068. Std of Reward: 10.949. Training. ELO: 1412.366.
[INFO] Testml. Step: 720000. Time Elapsed: 1299.685 s. Mean Reward: 0.007. Std of Reward: 8.780. Training. ELO: 1371.762.
[INFO] Testml. Step: 732000. Time Elapsed: 1319.056 s. Mean Reward: -0.313. Std of Reward: 7.780. Training. ELO: 1352.186.
[INFO] Testml. Step: 744000. Time Elapsed: 1347.724 s. Mean Reward: -2.169. Std of Reward: 5.054. Training. ELO: 1327.629.

[INFO] Testml. Step: 756000. Time Elapsed: 1368.057 s. Mean Reward: -0.175. Std of Reward: 8.573. Training. ELO: 1297.863.

[INFO] Testml. Step: 768000. Time Elapsed: 1388.104 s. Mean Reward: -1.486. Std of Reward: 6.532. Training. ELO: 1272.537.

[INFO] Testml. Step: 780000. Time Elapsed: 1419.199 s. Mean Reward: 0.527. Std of Reward: 9.377. Training. ELO: 1265.094.

[INFO] Testml. Step: 792000. Time Elapsed: 1436.602 s. Mean Reward: -1.491. Std of Reward: 5.767. Training. ELO: 1241.294.

[INFO] Testml. Step: 804000. Time Elapsed: 1457.698 s. Mean Reward: 5.170. Std of Reward: 10.929. Training. ELO: 1235.175.

[INFO] Testml. Step: 816000. Time Elapsed: 1477.330 s. Mean Reward: 19.377. Std of Reward: 3.332. Training. ELO: 1269.685.

[INFO] Testml. Step: 828000. Time Elapsed: 1506.804 s. Mean Reward: 19.388. Std of Reward: 3.223. Training. ELO: 1300.291.

[INFO] Testml. Step: 840000. Time Elapsed: 1526.791 s. Mean Reward: 19.137. Std of Reward: 4.284. Training. ELO: 1331.668.

[INFO] Testml. Step: 852000. Time Elapsed: 1546.117 s. Mean Reward: 19.540. Std of Reward: 3.284. Training. ELO: 1357.538.

[INFO] Testml. Step: 864000. Time Elapsed: 1575.745 s. Mean Reward: 18.884. Std of Reward: 4.806. Training. ELO: 1370.650.

[INFO] Testml. Step: 876000. Time Elapsed: 1595.988 s. Mean Reward: 19.105. Std of Reward: 3.855. Training. ELO: 1399.657.

[INFO] Testml. Step: 888000. Time Elapsed: 1616.061 s. Mean Reward: 18.573. Std of Reward: 5.430. Training. ELO: 1422.302.

[INFO] Testml. Step: 900000. Time Elapsed: 1635.795 s. Mean Reward: 18.876. Std of Reward: 4.470. Training. ELO: 1435.068.

[INFO] Testml. Step: 912000. Time Elapsed: 1666.124 s. Mean Reward: 0.772. Std of Reward: 8.628. Training. ELO: 1407.662.

[INFO] Testml. Step: 924000. Time Elapsed: 1687.000 s. Mean Reward: -1.306. Std of Reward: 6.335. Training. ELO: 1356.563.

[INFO] Testml. Step: 936000. Time Elapsed: 1711.025 s. Mean Reward: -0.536. Std of Reward: 7.188. Training. ELO: 1326.268.

[INFO] Testml. Step: 948000. Time Elapsed: 1744.699 s. Mean Reward: -0.478. Std of Reward: 7.979. Training. ELO: 1307.562.

[INFO] Testml. Step: 960000. Time Elapsed: 1769.158 s. Mean Reward: 0.404. Std of Reward: 8.192. Training. ELO: 1285.811.

[INFO] Testml. Step: 972000. Time Elapsed: 1793.173 s. Mean Reward: 0.606. Std of Reward: 8.163. Training. ELO: 1270.208.

[INFO] Testml. Step: 984000. Time Elapsed: 1816.239 s. Mean Reward: -0.433. Std of Reward: 7.079. Training. ELO: 1251.018.

[INFO] Testml. Step: 996000. Time Elapsed: 1850.553 s. Mean Reward: 1.728. Std of Reward: 9.085. Training. ELO: 1249.222.

[INFO] Exported results\test_30\Testml\Testml-999986.onnx

[INFO] Testml. Step: 1008000. Time Elapsed: 1874.585 s. Mean Reward: 12.788. Std of Reward: 10.708. Training. ELO: 1253.785.

[INFO] Testml. Step: 1020000. Time Elapsed: 1893.793 s. Mean Reward: 18.126. Std of Reward: 6.148. Training. ELO: 1285.273.

[INFO] Testml. Step: 1032000. Time Elapsed: 1923.703 s. Mean Reward: 16.937. Std of Reward: 7.308. Training. ELO: 1305.385.

[INFO] Testml. Step: 1044000. Time Elapsed: 1944.237 s. Mean Reward: 16.611. Std of Reward: 7.602. Training. ELO: 1318.774.

[INFO] Testml. Step: 1056000. Time Elapsed: 1964.906 s. Mean Reward: 16.322. Std of Reward: 7.775. Training. ELO: 1335.383.

[INFO] Testml. Step: 1068000. Time Elapsed: 1994.724 s. Mean Reward: 15.967. Std of Reward: 7.780. Training. ELO: 1348.885.

[INFO] Testml. Step: 1080000. Time Elapsed: 2018.129 s. Mean Reward: 17.597. Std of Reward: 6.839. Training. ELO: 1360.393.

[INFO] Testml. Step: 1092000. Time Elapsed: 2042.221 s. Mean Reward: 17.903. Std of Reward: 5.991. Training. ELO: 1385.561.

[INFO] Testml. Step: 1104000. Time Elapsed: 2065.952 s. Mean Reward: 15.206. Std of Reward: 9.616. Training. ELO: 1416.023.

[INFO] Testml. Step: 1116000. Time Elapsed: 2098.150 s. Mean Reward: 7.448. Std of Reward: 12.458. Training. ELO: 1422.360.

[INFO] Testml. Step: 1128000. Time Elapsed: 2119.907 s. Mean Reward: 9.008. Std of Reward: 12.522. Training. ELO: 1418.290.

[INFO] Testml. Step: 1140000. Time Elapsed: 2140.202 s. Mean Reward: 7.034. Std of Reward: 12.224. Training. ELO: 1407.445.

[INFO] Testml. Step: 1152000. Time Elapsed: 2168.016 s. Mean Reward: 8.644. Std of Reward: 13.032. Training. ELO: 1402.520.

[INFO] Testml. Step: 1164000. Time Elapsed: 2187.151 s. Mean Reward: 12.230. Std of Reward: 12.747. Training. ELO: 1398.925.

[INFO] Testml. Step: 1176000. Time Elapsed: 2206.386 s. Mean Reward: 14.626. Std of Reward: 11.097. Training. ELO: 1404.046.

[INFO] Testml. Step: 1188000. Time Elapsed: 2225.952 s. Mean Reward: 12.091. Std of Reward: 11.891. Training. ELO: 1403.089.

[INFO] Testml. Step: 1200000. Time Elapsed: 2255.102 s. Mean Reward: 14.344. Std of Reward: 11.265. Training. ELO: 1403.061.

[INFO] Testml. Step: 1212000. Time Elapsed: 2275.573 s. Mean Reward: 10.876. Std of Reward: 10.039. Training. ELO: 1407.077.

[INFO] Testml. Step: 1224000. Time Elapsed: 2294.854 s. Mean Reward: 10.219. Std of Reward: 10.556. Training. ELO: 1408.012.

[INFO] Testml. Step: 1236000. Time Elapsed: 2324.130 s. Mean Reward: 11.071. Std of Reward: 10.360. Training. ELO: 1419.164.

[INFO] Testml. Step: 1248000. Time Elapsed: 2344.540 s. Mean Reward: 8.840. Std of Reward: 10.047. Training. ELO: 1423.303.

[INFO] Testml. Step: 1260000. Time Elapsed: 2365.742 s. Mean Reward: 12.490. Std of Reward: 9.677. Training. ELO: 1431.237.

[INFO] Testml. Step: 1272000. Time Elapsed: 2396.602 s. Mean Reward: 13.749. Std of Reward: 9.236. Training. ELO: 1438.937.

[INFO] Testml. Step: 1284000. Time Elapsed: 2414.615 s. Mean Reward: 12.173. Std of Reward: 10.064. Training. ELO: 1449.005.

[INFO] Testml. Step: 1296000. Time Elapsed: 2438.821 s. Mean Reward: 10.682. Std of Reward: 10.335. Training. ELO: 1455.631.

[INFO] Testml. Step: 1308000. Time Elapsed: 2462.269 s. Mean Reward: 16.153. Std of Reward: 9.941. Training. ELO: 1465.083.

[INFO] Testml. Step: 1320000. Time Elapsed: 2496.491 s. Mean Reward: 13.244. Std of Reward: 11.220. Training. ELO: 1475.165.

[INFO] Testml. Step: 1332000. Time Elapsed: 2520.401 s. Mean Reward: 17.298. Std of Reward: 9.939. Training. ELO: 1482.975.

[INFO] Testml. Step: 1344000. Time Elapsed: 2543.409 s. Mean Reward: 14.029. Std of Reward: 11.295. Training. ELO: 1489.210.

[INFO] Testml. Step: 1356000. Time Elapsed: 2575.104 s. Mean Reward: 17.167. Std of Reward: 10.000. Training. ELO: 1498.212.

[INFO] Testml. Step: 1368000. Time Elapsed: 2597.414 s. Mean Reward: 18.291. Std of Reward: 8.700. Training. ELO: 1511.451.

[INFO] Testml. Step: 1380000. Time Elapsed: 2615.804 s. Mean Reward: 14.273. Std of Reward: 11.164. Training. ELO: 1517.508.

[INFO] Testml. Step: 1392000. Time Elapsed: 2636.061 s. Mean Reward: 17.915. Std of Reward: 9.934. Training. ELO: 1520.542.

[INFO] Testml. Step: 1404000. Time Elapsed: 2667.140 s. Mean Reward: 12.945. Std of Reward: 10.919. Training. ELO: 1529.516.

[INFO] Testml. Step: 1416000. Time Elapsed: 2686.132 s. Mean Reward: 10.130. Std of Reward: 10.081. Training. ELO: 1533.124.

[INFO] Testml. Step: 1428000. Time Elapsed: 2705.238 s. Mean Reward: 8.423. Std of Reward: 10.131. Training. ELO: 1528.635.

[INFO] Testml. Step: 1440000. Time Elapsed: 2734.449 s. Mean Reward: 9.646. Std of Reward: 10.408. Training. ELO: 1529.819.

[INFO] Testml. Step: 1452000. Time Elapsed: 2754.078 s. Mean Reward: 9.134. Std of Reward: 10.535. Training. ELO: 1526.867.

[INFO] Testml. Step: 1464000. Time Elapsed: 2773.944 s. Mean Reward: 14.449. Std of Reward: 9.018. Training. ELO: 1535.198.

[INFO] Testml. Step: 1476000. Time Elapsed: 2793.136 s. Mean Reward: 11.633. Std of Reward: 10.079. Training. ELO: 1535.164.

[INFO] Testml. Step: 1488000. Time Elapsed: 2820.935 s. Mean Reward: 9.012. Std of Reward: 10.585. Training. ELO: 1531.528.

[INFO] Testml. Step: 1500000. Time Elapsed: 2840.381 s. Mean Reward: 11.078. Std of Reward: 10.421. Training. ELO: 1527.866.

[INFO] Exported results\test_30\Testml\Testml-1499940.onnx

[INFO] Testml. Step: 1512000. Time Elapsed: 2859.591 s. Mean Reward: 18.129. Std of Reward: 8.366. Training. ELO: 1541.187.

[INFO] Testml. Step: 1524000. Time Elapsed: 2887.849 s. Mean Reward: 17.689. Std of Reward: 9.484. Training. ELO: 1559.953.

[INFO] Testml. Step: 1536000. Time Elapsed: 2907.628 s. Mean Reward: 14.745. Std of Reward: 11.308. Training. ELO: 1570.281.

[INFO] Testml. Step: 1548000. Time Elapsed: 2929.357 s. Mean Reward: 15.824. Std of Reward: 10.677. Training. ELO: 1581.011.

[INFO] Testml. Step: 1560000. Time Elapsed: 2958.307 s. Mean Reward: 15.099. Std of Reward: 10.706. Training. ELO: 1586.940.

[INFO] Testml. Step: 1572000. Time Elapsed: 2978.648 s. Mean Reward: 16.262. Std of Reward: 10.721. Training. ELO: 1596.084.

[INFO] Testml. Step: 1584000. Time Elapsed: 2998.243 s. Mean Reward: 14.433. Std of Reward: 11.020. Training. ELO: 1601.305.

[INFO] Testml. Step: 1596000. Time Elapsed: 3017.222 s. Mean Reward: 16.183. Std of Reward: 10.132. Training. ELO: 1609.520.

[INFO] Testml. Step: 1608000. Time Elapsed: 3045.520 s. Mean Reward: 11.105. Std of Reward: 11.292. Training. ELO: 1611.123.

[INFO] Testml. Step: 1620000. Time Elapsed: 3065.829 s. Mean Reward: 9.707. Std of Reward: 10.390. Training. ELO: 1607.763.

[INFO] Testml. Step: 1632000. Time Elapsed: 3087.391 s. Mean Reward: 7.462. Std of Reward: 10.370. Training. ELO: 1607.388.

[INFO] Testml. Step: 1644000. Time Elapsed: 3117.052 s. Mean Reward: 6.389. Std of Reward: 9.980. Training. ELO: 1603.513.

[INFO] Testml. Step: 1656000. Time Elapsed: 3136.991 s. Mean Reward: 8.798. Std of Reward: 10.275. Training. ELO: 1599.954.

[INFO] Testml. Step: 1668000. Time Elapsed: 3156.527 s. Mean Reward: 12.901. Std of Reward: 10.016. Training. ELO: 1602.197.

[INFO] Testml. Step: 1680000. Time Elapsed: 3176.004 s. Mean Reward: 8.553. Std of Reward: 10.808. Training. ELO: 1600.478.

[INFO] Testml. Step: 1692000. Time Elapsed: 3206.764 s. Mean Reward: 10.340. Std of Reward: 10.120. Training. ELO: 1598.411.

[INFO] Testml. Step: 1704000. Time Elapsed: 3226.247 s. Mean Reward: 7.393. Std of Reward: 10.297. Training. ELO: 1597.229.

[INFO] Testml. Step: 1716000. Time Elapsed: 3245.413 s. Mean Reward: 17.220. Std of Reward: 9.825. Training. ELO: 1603.978.

[INFO] Testml. Step: 1728000. Time Elapsed: 3273.679 s. Mean Reward: 15.925. Std of Reward: 10.333. Training. ELO: 1617.880.

[INFO] Testml. Step: 1740000. Time Elapsed: 3291.925 s. Mean Reward: 18.052. Std of Reward: 9.088. Training. ELO: 1634.046.

[INFO] Testml. Step: 1752000. Time Elapsed: 3311.007 s. Mean Reward: 17.737. Std of Reward: 9.195. Training. ELO: 1644.002.

[INFO] Testml. Step: 1764000. Time Elapsed: 3341.943 s. Mean Reward: 15.464. Std of Reward: 10.349. Training. ELO: 1657.791.

[INFO] Testml. Step: 1776000. Time Elapsed: 3358.194 s. Mean Reward: 17.117. Std of Reward: 9.538. Training. ELO: 1670.430.

[INFO] Testml. Step: 1788000. Time Elapsed: 3377.744 s. Mean Reward: 16.914. Std of Reward: 9.947. Training. ELO: 1683.094.

[INFO] Testml. Step: 1800000. Time Elapsed: 3396.108 s. Mean Reward: 15.281. Std of Reward: 10.953. Training. ELO: 1686.826.

[INFO] Testml. Step: 1812000. Time Elapsed: 3421.857 s. Mean Reward: 9.450. Std of Reward: 10.448. Training. ELO: 1689.954.

[INFO] Testml. Step: 1824000. Time Elapsed: 3439.664 s. Mean Reward: 10.903. Std of Reward: 10.325. Training. ELO: 1686.508.

[INFO] Testml. Step: 1836000. Time Elapsed: 3457.602 s. Mean Reward: 7.168. Std of Reward: 10.210. Training. ELO: 1683.759.

[INFO] Testml. Step: 1848000. Time Elapsed: 3482.909 s. Mean Reward: 7.484. Std of Reward: 10.356. Training. ELO: 1677.286.

[INFO] Testml. Step: 1860000. Time Elapsed: 3500.618 s. Mean Reward: 6.738. Std of Reward: 10.405. Training. ELO: 1673.032.

[INFO] Testml. Step: 1872000. Time Elapsed: 3519.730 s. Mean Reward: 9.408. Std of Reward: 10.468. Training. ELO: 1666.009.

[INFO] Testml. Step: 1884000. Time Elapsed: 3539.304 s. Mean Reward: 6.560. Std of Reward: 10.437. Training. ELO: 1658.758.

[INFO] Testml. Step: 1896000. Time Elapsed: 3568.924 s. Mean Reward: 10.032. Std of Reward: 10.463. Training. ELO: 1651.914.

[INFO] Testml. Step: 1908000. Time Elapsed: 3589.691 s. Mean Reward: 12.307. Std of Reward: 10.944. Training. ELO: 1657.571.

[INFO] Testml. Step: 1920000. Time Elapsed: 3609.527 s. Mean Reward: 12.486. Std of Reward: 11.253. Training. ELO: 1668.479.

[INFO] Testml. Step: 1932000. Time Elapsed: 3639.530 s. Mean Reward: 9.275. Std of Reward: 11.315. Training. ELO: 1671.262.

[INFO] Testml. Step: 1944000. Time Elapsed: 3659.279 s. Mean Reward: 16.102. Std of Reward: 9.722. Training. ELO: 1681.984.

[INFO] Testml. Step: 1956000. Time Elapsed: 3678.356 s. Mean Reward: 13.455. Std of Reward: 10.867. Training. ELO: 1693.659.

[INFO] Testml. Step: 1968000. Time Elapsed: 3697.344 s. Mean Reward: 14.633. Std of Reward: 10.440. Training. ELO: 1700.480.

[INFO] Testml. Step: 1980000. Time Elapsed: 3725.078 s. Mean Reward: 14.984. Std of Reward: 10.441. Training. ELO: 1713.545.

[INFO] Testml. Step: 1992000. Time Elapsed: 3743.537 s. Mean Reward: 15.642. Std of Reward: 10.115. Training. ELO: 1722.383.

[INFO] Exported results\test_30\Testml\Testml-1999930.onnx

[INFO] Testml. Step: 2004000. Time Elapsed: 3762.432 s. Mean Reward: 14.732. Std of Reward: 10.436. Training. ELO: 1732.673.

[INFO] Testml. Step: 2016000. Time Elapsed: 3791.317 s. Mean Reward: 10.978. Std of Reward: 10.525. Training. ELO: 1738.153.

[INFO] Testml. Step: 2028000. Time Elapsed: 3809.441 s. Mean Reward: 6.359. Std of Reward: 10.194. Training. ELO: 1732.393.

[INFO] Testml. Step: 2040000. Time Elapsed: 3828.380 s. Mean Reward: 10.034. Std of Reward: 10.882. Training. ELO: 1729.954.

[INFO] Testml. Step: 2052000. Time Elapsed: 3856.594 s. Mean Reward: 6.629. Std of Reward: 10.625. Training. ELO: 1726.863.

[INFO] Testml. Step: 2064000. Time Elapsed: 3873.858 s. Mean Reward: 6.277. Std of Reward: 10.451. Training. ELO: 1723.295.

[INFO] Testml. Step: 2076000. Time Elapsed: 3890.860 s. Mean Reward: 7.294. Std of Reward: 10.512. Training. ELO: 1719.821.

[INFO] Testml. Step: 2088000. Time Elapsed: 3908.027 s. Mean Reward: 7.528. Std of Reward: 10.922. Training. ELO: 1716.637.

[INFO] Testml. Step: 2100000. Time Elapsed: 3932.539 s. Mean Reward: 13.069. Std of Reward: 9.907. Training. ELO: 1716.053.

[INFO] Testml. Step: 2112000. Time Elapsed: 3950.216 s. Mean Reward: 15.506. Std of Reward: 9.451. Training. ELO: 1732.446.

[INFO] Testml. Step: 2124000. Time Elapsed: 3967.225 s. Mean Reward: 14.043. Std of Reward: 10.828. Training. ELO: 1748.473.

[INFO] Testml. Step: 2136000. Time Elapsed: 3991.842 s. Mean Reward: 12.391. Std of Reward: 10.983. Training. ELO: 1753.061.

[INFO] Testml. Step: 2148000. Time Elapsed: 4008.920 s. Mean Reward: 17.428. Std of Reward: 8.718. Training. ELO: 1766.018.

[INFO] Testml. Step: 2160000. Time Elapsed: 4027.272 s. Mean Reward: 15.520. Std of Reward: 9.866. Training. ELO: 1781.652.

[INFO] Testml. Step: 2172000. Time Elapsed: 4045.095 s. Mean Reward: 14.700. Std of Reward: 10.027. Training. ELO: 1793.499.

[INFO] Testml. Step: 2184000. Time Elapsed: 4071.841 s. Mean Reward: 16.170. Std of Reward: 9.038. Training. ELO: 1806.620.

[INFO] Testml. Step: 2196000. Time Elapsed: 4089.841 s. Mean Reward: 15.845. Std of Reward: 9.042. Training. ELO: 1820.176.

[INFO] Testml. Step: 2208000. Time Elapsed: 4107.496 s. Mean Reward: 9.057. Std of Reward: 11.506. Training. ELO: 1827.389.

[INFO] Testml. Step: 2220000. Time Elapsed: 4134.000 s. Mean Reward: 3.608. Std of Reward: 9.847. Training. ELO: 1819.515.

[INFO] Testml. Step: 2232000. Time Elapsed: 4151.612 s. Mean Reward: 5.387. Std of Reward: 10.593. Training. ELO: 1810.804.

[INFO] Testml. Step: 2244000. Time Elapsed: 4169.349 s. Mean Reward: 5.230. Std of Reward: 10.569. Training. ELO: 1806.392.

[INFO] Testml. Step: 2256000. Time Elapsed: 4198.045 s. Mean Reward: 6.166. Std of Reward: 10.446. Training. ELO: 1801.038.

[INFO] Testml. Step: 2268000. Time Elapsed: 4213.119 s. Mean Reward: 6.528. Std of Reward: 10.874. Training. ELO: 1794.630.

[INFO] Testml. Step: 2280000. Time Elapsed: 4230.771 s. Mean Reward: 6.409. Std of Reward: 10.743. Training. ELO: 1790.365.

[INFO] Testml. Step: 2292000. Time Elapsed: 4248.603 s. Mean Reward: 5.517. Std of Reward: 10.523. Training. ELO: 1785.694.

[INFO] Testml. Step: 2304000. Time Elapsed: 4275.470 s. Mean Reward: 7.835. Std of Reward: 11.137. Training. ELO: 1783.595.

[INFO] Testml. Step: 2316000. Time Elapsed: 4292.773 s. Mean Reward: 15.931. Std of Reward: 8.936. Training. ELO: 1787.333.

[INFO] Testml. Step: 2328000. Time Elapsed: 4311.556 s. Mean Reward: 17.320. Std of Reward: 8.049. Training. ELO: 1802.679.

[INFO] Testml. Step: 2340000. Time Elapsed: 4341.223 s. Mean Reward: 18.355. Std of Reward: 6.562. Training. ELO: 1825.267.

[INFO] Testml. Step: 2352000. Time Elapsed: 4361.728 s. Mean Reward: 16.976. Std of Reward: 7.839. Training. ELO: 1838.341.

[INFO] Testml. Step: 2364000. Time Elapsed: 4382.317 s. Mean Reward: 17.586. Std of Reward: 7.494. Training. ELO: 1861.171.

[INFO] Testml. Step: 2376000. Time Elapsed: 4403.231 s. Mean Reward: 16.690. Std of Reward: 8.148. Training. ELO: 1877.085.

[INFO] Testml. Step: 2388000. Time Elapsed: 4432.690 s. Mean Reward: 17.034. Std of Reward: 8.180. Training. ELO: 1886.568.

[INFO] Testml. Step: 2400000. Time Elapsed: 4452.772 s. Mean Reward: 17.613. Std of Reward: 7.077. Training. ELO: 1899.222.

[INFO] Testml. Step: 2412000. Time Elapsed: 4473.547 s. Mean Reward: 5.275. Std of Reward: 10.841. Training. ELO: 1913.607.

[INFO] Testml. Step: 2424000. Time Elapsed: 4504.958 s. Mean Reward: 4.098. Std of Reward: 10.061. Training. ELO: 1890.811.

[INFO] Testml. Step: 2436000. Time Elapsed: 4525.898 s. Mean Reward: 3.457. Std of Reward: 9.940. Training. ELO: 1869.645.

[INFO] Testml. Step: 2448000. Time Elapsed: 4547.022 s. Mean Reward: 2.749. Std of Reward: 9.327. Training. ELO: 1846.421.

[INFO] Testml. Step: 2460000. Time Elapsed: 4568.985 s. Mean Reward: 0.991. Std of Reward: 8.442. Training. ELO: 1829.523.

[INFO] Testml. Step: 2472000. Time Elapsed: 4600.179 s. Mean Reward: 4.045. Std of Reward: 10.288. Training. ELO: 1811.065.

[INFO] Testml. Step: 2484000. Time Elapsed: 4619.942 s. Mean Reward: -0.007. Std of Reward: 7.460. Training. ELO: 1797.848.

[INFO] Testml. Step: 2496000. Time Elapsed: 4640.876 s. Mean Reward: 4.326. Std of Reward: 10.287. Training. ELO: 1778.546.

[INFO] Exported results\test_30\Testml\Testml-2499937.onnx

[INFO] Testml. Step: 2508000. Time Elapsed: 4672.034 s. Mean Reward: 9.013. Std of Reward: 11.110. Training. ELO: 1776.907.

[INFO] Testml. Step: 2520000. Time Elapsed: 4693.379 s. Mean Reward: 17.219. Std of Reward: 6.768. Training. ELO: 1817.581.

[INFO] Testml. Step: 2532000. Time Elapsed: 4713.422 s. Mean Reward: 17.555. Std of Reward: 7.111. Training. ELO: 1841.264.

[INFO] Testml. Step: 2544000. Time Elapsed: 4744.133 s. Mean Reward: 18.199. Std of Reward: 5.394. Training. ELO: 1865.291.

[INFO] Testml. Step: 2556000. Time Elapsed: 4761.070 s. Mean Reward: 17.902. Std of Reward: 5.894. Training. ELO: 1879.255.

[INFO] Testml. Step: 2568000. Time Elapsed: 4782.145 s. Mean Reward: 16.772. Std of Reward: 7.543. Training. ELO: 1909.171.

[INFO] Testml. Step: 2580000. Time Elapsed: 4800.873 s. Mean Reward: 17.942. Std of Reward: 6.172. Training. ELO: 1937.665.

[INFO] Testml. Step: 2592000. Time Elapsed: 4828.396 s. Mean Reward: 17.586. Std of Reward: 6.107. Training. ELO: 1958.849.

[INFO] Testml. Step: 2604000. Time Elapsed: 4847.521 s. Mean Reward: 17.866. Std of Reward: 6.323. Training. ELO: 1968.807.

[INFO] Testml. Step: 2616000. Time Elapsed: 4865.994 s. Mean Reward: -0.246. Std of Reward: 7.057. Training. ELO: 1954.852.

[INFO] Testml. Step: 2628000. Time Elapsed: 4893.277 s. Mean Reward: 0.450. Std of Reward: 7.917. Training. ELO: 1936.212.

[INFO] Testml. Step: 2640000. Time Elapsed: 4911.507 s. Mean Reward: 1.920. Std of Reward: 9.014. Training. ELO: 1913.268.

[INFO] Testml. Step: 2652000. Time Elapsed: 4929.627 s. Mean Reward: 0.916. Std of Reward: 8.140. Training. ELO: 1885.114.

[INFO] Testml. Step: 2664000. Time Elapsed: 4949.036 s. Mean Reward: 1.524. Std of Reward: 8.712. Training. ELO: 1856.408.

[INFO] Testml. Step: 2676000. Time Elapsed: 4977.249 s. Mean Reward: -0.558. Std of Reward: 6.966. Training. ELO: 1834.814.

[INFO] Testml. Step: 2688000. Time Elapsed: 4995.706 s. Mean Reward: -0.841. Std of Reward: 6.481. Training. ELO: 1819.385.

[INFO] Testml. Step: 2700000. Time Elapsed: 5013.992 s. Mean Reward: -0.090. Std of Reward: 7.379. Training. ELO: 1801.394.

[INFO] Testml. Step: 2712000. Time Elapsed: 5041.219 s. Mean Reward: 11.963. Std of Reward: 10.534. Training. ELO: 1797.702.

[INFO] Testml. Step: 2724000. Time Elapsed: 5058.815 s. Mean Reward: 18.577. Std of Reward: 5.147. Training. ELO: 1842.531.

[INFO] Testml. Step: 2736000. Time Elapsed: 5076.462 s. Mean Reward: 18.660. Std of Reward: 4.916. Training. ELO: 1869.487.

[INFO] Testml. Step: 2748000. Time Elapsed: 5105.890 s. Mean Reward: 18.729. Std of Reward: 4.934. Training. ELO: 1901.597.

[INFO] Testml. Step: 2760000. Time Elapsed: 5121.359 s. Mean Reward: 19.170. Std of Reward: 4.099. Training. ELO: 1918.919.

[INFO] Testml. Step: 2772000. Time Elapsed: 5139.115 s. Mean Reward: 19.030. Std of Reward: 4.356. Training. ELO: 1925.373.

[INFO] Testml. Step: 2784000. Time Elapsed: 5156.808 s. Mean Reward: 19.204. Std of Reward: 3.626. Training. ELO: 1946.866.

[INFO] Testml. Step: 2796000. Time Elapsed: 5183.985 s. Mean Reward: 18.176. Std of Reward: 5.697. Training. ELO: 1971.940.

[INFO] Testml. Step: 2808000. Time Elapsed: 5201.653 s. Mean Reward: 12.407. Std of Reward: 10.696. Training. ELO: 1989.657.

[INFO] Testml. Step: 2820000. Time Elapsed: 5219.362 s. Mean Reward: -0.939. Std of Reward: 6.945. Training. ELO: 1983.307.

[INFO] Testml. Step: 2832000. Time Elapsed: 5246.271 s. Mean Reward: 1.468. Std of Reward: 8.882. Training. ELO: 1951.516.

[INFO] Testml. Step: 2844000. Time Elapsed: 5264.196 s. Mean Reward: -0.968. Std of Reward: 6.470. Training. ELO: 1925.252.

[INFO] Testml. Step: 2856000. Time Elapsed: 5281.862 s. Mean Reward: -1.153. Std of Reward: 5.869. Training. ELO: 1903.856.

[INFO] Testml. Step: 2868000. Time Elapsed: 5299.557 s. Mean Reward: -1.682. Std of Reward: 5.002. Training. ELO: 1878.055.

[INFO] Testml. Step: 2880000. Time Elapsed: 5326.573 s. Mean Reward: 0.120. Std of Reward: 7.621. Training. ELO: 1851.318.

[INFO] Testml. Step: 2892000. Time Elapsed: 5344.605 s. Mean Reward: -1.445. Std of Reward: 5.495. Training. ELO: 1826.194.

[INFO] Testml. Step: 2904000. Time Elapsed: 5362.490 s. Mean Reward: -1.058. Std of Reward: 6.148. Training. ELO: 1808.058.

[INFO] Testml. Step: 2916000. Time Elapsed: 5389.516 s. Mean Reward: 19.223. Std of Reward: 3.310. Training. ELO: 1831.648.

[INFO] Testml. Step: 2928000. Time Elapsed: 5407.385 s. Mean Reward: 17.994. Std of Reward: 5.734. Training. ELO: 1859.819.

[INFO] Testml. Step: 2940000. Time Elapsed: 5425.232 s. Mean Reward: 19.125. Std of Reward: 4.033. Training. ELO: 1877.657.

[INFO] Testml. Step: 2952000. Time Elapsed: 5442.914 s. Mean Reward: 19.051. Std of Reward: 4.028. Training. ELO: 1916.276.

[INFO] Testml. Step: 2964000. Time Elapsed: 5470.452 s. Mean Reward: 17.994. Std of Reward: 6.295. Training. ELO: 1940.550.

[INFO] Testml. Step: 2976000. Time Elapsed: 5488.270 s. Mean Reward: 18.656. Std of Reward: 5.258. Training. ELO: 1963.728.

[INFO] Testml. Step: 2988000. Time Elapsed: 5511.799 s. Mean Reward: 18.420. Std of Reward: 5.270. Training. ELO: 1972.772.

[INFO] Testml. Step: 3000000. Time Elapsed: 5545.041 s. Mean Reward: 19.383. Std of Reward: 3.092. Training. ELO: 1994.798.

[INFO] Exported results\test_30\Testml\Testml-2999999.onnx

[INFO] Testml. Step: 3012000. Time Elapsed: 5568.311 s. Mean Reward: 5.873. Std of Reward: 10.782. Training. ELO: 2004.936.

[INFO] Testml. Step: 3024000. Time Elapsed: 5591.708 s. Mean Reward: -1.949. Std of Reward: 4.452. Training. ELO: 1974.831.

[INFO] Testml. Step: 3036000. Time Elapsed: 5626.401 s. Mean Reward: -1.114. Std of Reward: 5.918. Training. ELO: 1954.300.

[INFO] Testml. Step: 3048000. Time Elapsed: 5648.946 s. Mean Reward: -1.415. Std of Reward: 5.282. Training. ELO: 1930.509.

[INFO] Testml. Step: 3060000. Time Elapsed: 5672.575 s. Mean Reward: -0.976. Std of Reward: 6.115. Training. ELO: 1902.400.

[INFO] Testml. Step: 3072000. Time Elapsed: 5696.235 s. Mean Reward: -1.693. Std of Reward: 5.226. Training. ELO: 1870.773.

[INFO] Testml. Step: 3084000. Time Elapsed: 5730.400 s. Mean Reward: -1.031. Std of Reward: 6.204. Training. ELO: 1845.833.

[INFO] Testml. Step: 3096000. Time Elapsed: 5753.945 s. Mean Reward: -1.178. Std of Reward: 6.030. Training. ELO: 1819.889.

[INFO] Testml. Step: 3108000. Time Elapsed: 5777.619 s. Mean Reward: 5.235. Std of Reward: 10.641. Training. ELO: 1796.416.

[INFO] Testml. Step: 3120000. Time Elapsed: 5809.355 s. Mean Reward: 19.348. Std of Reward: 3.800. Training. ELO: 1813.162.

[INFO] Testml. Step: 3132000. Time Elapsed: 5827.413 s. Mean Reward: 19.495. Std of Reward: 2.898. Training. ELO: 1866.722.

[INFO] Testml. Step: 3144000. Time Elapsed: 5845.629 s. Mean Reward: 19.583. Std of Reward: 2.004. Training. ELO: 1912.505.

[INFO] Testml. Step: 3156000. Time Elapsed: 5863.843 s. Mean Reward: 18.987. Std of Reward: 4.035. Training. ELO: 1954.811.

[INFO] Testml. Step: 3168000. Time Elapsed: 5891.418 s. Mean Reward: 18.452. Std of Reward: 5.544. Training. ELO: 1976.601.

[INFO] Testml. Step: 3180000. Time Elapsed: 5909.997 s. Mean Reward: 19.732. Std of Reward: 1.850. Training. ELO: 1995.593.

[INFO] Testml. Step: 3192000. Time Elapsed: 5928.972 s. Mean Reward: 19.515. Std of Reward: 3.982. Training. ELO: 2017.964.

[INFO] Testml. Step: 3204000. Time Elapsed: 5957.565 s. Mean Reward: 19.574. Std of Reward: 2.616. Training. ELO: 2038.611.

[INFO] Testml. Step: 3216000. Time Elapsed: 5976.370 s. Mean Reward: -1.563. Std of Reward: 5.204. Training. ELO: 2027.077.

[INFO] Testml. Step: 3228000. Time Elapsed: 5995.502 s. Mean Reward: -2.673. Std of Reward: 2.032. Training. ELO: 1995.942.

[INFO] Testml. Step: 3240000. Time Elapsed: 6028.821 s. Mean Reward: -2.004. Std of Reward: 4.744. Training. ELO: 1975.910.

[INFO] Testml. Step: 3252000. Time Elapsed: 6046.631 s. Mean Reward: -2.111. Std of Reward: 3.813. Training. ELO: 1953.833.

[INFO] Testml. Step: 3264000. Time Elapsed: 6067.081 s. Mean Reward: -1.607. Std of Reward: 5.003. Training. ELO: 1918.124.

[INFO] Testml. Step: 3276000. Time Elapsed: 6087.218 s. Mean Reward: -2.491. Std of Reward: 2.837. Training. ELO: 1890.647.

[INFO] Testml. Step: 3288000. Time Elapsed: 6117.427 s. Mean Reward: -2.331. Std of Reward: 3.248. Training. ELO: 1870.624.

[INFO] Testml. Step: 3300000. Time Elapsed: 6138.107 s. Mean Reward: -2.168. Std of Reward: 3.437. Training. ELO: 1853.874.

[INFO] Testml. Step: 3312000. Time Elapsed: 6158.863 s. Mean Reward: 12.183. Std of Reward: 10.737. Training. ELO: 1826.169.

[INFO] Testml. Step: 3324000. Time Elapsed: 6188.370 s. Mean Reward: 19.429. Std of Reward: 3.104. Training. ELO: 1857.423.

[INFO] Testml. Step: 3336000. Time Elapsed: 6208.631 s. Mean Reward: 19.781. Std of Reward: 3.757. Training. ELO: 1900.226.

[INFO] Testml. Step: 3348000. Time Elapsed: 16.280 s. Mean Reward: 19.980. Std of Reward: 1.220. Training. ELO: 1941.062.

[INFO] Testml. Step: 3360000. Time Elapsed: 35.224 s. Mean Reward: 17.851. Std of Reward: 6.497. Training. ELO: 1963.365.

[INFO] Testml. Step: 3372000. Time Elapsed: 52.633 s. Mean Reward: 16.909. Std of Reward: 7.710. Training. ELO: 1983.084.

[INFO] Testml. Step: 3384000. Time Elapsed: 79.053 s. Mean Reward: 18.994. Std of Reward: 5.808. Training. ELO: 2002.073.

[INFO] Testml. Step: 3396000. Time Elapsed: 96.583 s. Mean Reward: 18.638. Std of Reward: 5.895. Training. ELO: 2017.862.

[INFO] Testml. Step: 3408000. Time Elapsed: 114.005 s. Mean Reward: 19.471. Std of Reward: 3.953. Training. ELO: 2033.306.

[INFO] Testml. Step: 3420000. Time Elapsed: 131.210 s. Mean Reward: 18.038. Std of Reward: 6.263. Training. ELO: 2066.548.

[INFO] Testml. Step: 3432000. Time Elapsed: 160.724 s. Mean Reward: 18.593. Std of Reward: 5.478. Training. ELO: 2075.595.

[INFO] Testml. Step: 3444000. Time Elapsed: 182.033 s. Mean Reward: 11.474. Std of Reward: 11.530. Training. ELO: 2080.426.

[INFO] Testml. Step: 3456000. Time Elapsed: 203.308 s. Mean Reward: -0.902. Std of Reward: 6.310. Training. ELO: 2043.723.

[INFO] Testml. Step: 3468000. Time Elapsed: 234.699 s. Mean Reward: -1.402. Std of Reward: 5.620. Training. ELO: 2014.499.

[INFO] Testml. Step: 3480000. Time Elapsed: 255.555 s. Mean Reward: -0.230. Std of Reward: 7.249. Training. ELO: 1983.612.

[INFO] Testml. Step: 3492000. Time Elapsed: 276.713 s. Mean Reward: -1.652. Std of Reward: 5.174. Training. ELO: 1953.577.

[INFO] Exported results\test_30\Testml\Testml-3499936.onnx

[INFO] Testml. Step: 3504000. Time Elapsed: 310.275 s. Mean Reward: -1.607. Std of Reward: 6.165. Training. ELO: 1921.487.

[INFO] Testml. Step: 3516000. Time Elapsed: 328.873 s. Mean Reward: -1.283. Std of Reward: 5.776. Training. ELO: 1899.015.

[INFO] Testml. Step: 3528000. Time Elapsed: 349.707 s. Mean Reward: -0.855. Std of Reward: 6.181. Training. ELO: 1881.308.

[INFO] Testml. Step: 3540000. Time Elapsed: 371.242 s. Mean Reward: 0.399. Std of Reward: 7.814. Training. ELO: 1855.946.

[INFO] Testml. Step: 3552000. Time Elapsed: 398.679 s. Mean Reward: 19.548. Std of Reward: 3.810. Training. ELO: 1879.369.

[INFO] Testml. Step: 3564000. Time Elapsed: 420.083 s. Mean Reward: 17.508. Std of Reward: 6.704. Training. ELO: 1917.402.

[INFO] Testml. Step: 3576000. Time Elapsed: 440.985 s. Mean Reward: 18.457. Std of Reward: 5.495. Training. ELO: 1933.611.

[INFO] Testml. Step: 3588000. Time Elapsed: 471.473 s. Mean Reward: 18.582. Std of Reward: 5.914. Training. ELO: 1966.035.

[INFO] Testml. Step: 3600000. Time Elapsed: 492.336 s. Mean Reward: 18.114. Std of Reward: 6.472. Training. ELO: 1994.137.

[INFO] Testml. Step: 3612000. Time Elapsed: 511.762 s. Mean Reward: 18.251. Std of Reward: 6.021. Training. ELO: 2018.707.

[INFO] Testml. Step: 3624000. Time Elapsed: 531.868 s. Mean Reward: 18.665. Std of Reward: 4.862. Training. ELO: 2037.088.

[INFO] Testml. Step: 3636000. Time Elapsed: 568.373 s. Mean Reward: 19.466. Std of Reward: 4.060. Training. ELO: 2054.617.

[INFO] Testml. Step: 3648000. Time Elapsed: 598.133 s. Mean Reward: 3.765. Std of Reward: 10.213. Training. ELO: 2060.217.

[INFO] Testml. Step: 3660000. Time Elapsed: 633.259 s. Mean Reward: -1.337. Std of Reward: 5.366. Training. ELO: 2053.821.

[INFO] Testml. Step: 3672000. Time Elapsed: 666.069 s. Mean Reward: -1.299. Std of Reward: 6.057. Training. ELO: 2010.363.

[INFO] Testml. Step: 3684000. Time Elapsed: 689.981 s. Mean Reward: -1.099. Std of Reward: 5.892. Training. ELO: 1978.638.

[INFO] Testml. Step: 3696000. Time Elapsed: 710.325 s. Mean Reward: -1.045. Std of Reward: 6.048. Training. ELO: 1943.008.

[INFO] Testml. Step: 3708000. Time Elapsed: 730.752 s. Mean Reward: -1.379. Std of Reward: 5.380. Training. ELO: 1923.221.

[INFO] Testml. Step: 3720000. Time Elapsed: 760.385 s. Mean Reward: -0.323. Std of Reward: 7.047. Training. ELO: 1900.531.

[INFO] Testml. Step: 3732000. Time Elapsed: 779.592 s. Mean Reward: -1.669. Std of Reward: 4.764. Training. ELO: 1882.798.

[INFO] Testml. Step: 3744000. Time Elapsed: 800.565 s. Mean Reward: 5.468. Std of Reward: 10.888. Training. ELO: 1876.915.

[INFO] Testml. Step: 3756000. Time Elapsed: 831.128 s. Mean Reward: 18.940. Std of Reward: 4.828. Training. ELO: 1899.172.

[INFO] Testml. Step: 3768000. Time Elapsed: 850.465 s. Mean Reward: 18.652. Std of Reward: 5.071. Training. ELO: 1931.671.

[INFO] Testml. Step: 3780000. Time Elapsed: 869.904 s. Mean Reward: 19.404. Std of Reward: 2.874. Training. ELO: 1951.158.

[INFO] Testml. Step: 3792000. Time Elapsed: 899.758 s. Mean Reward: 18.905. Std of Reward: 4.571. Training. ELO: 1992.552.

[INFO] Testml. Step: 3804000. Time Elapsed: 919.086 s. Mean Reward: 18.593. Std of Reward: 4.923. Training. ELO: 2038.223.

[INFO] Testml. Step: 3816000. Time Elapsed: 939.536 s. Mean Reward: 18.877. Std of Reward: 4.468. Training. ELO: 2065.011.

[INFO] Testml. Step: 3828000. Time Elapsed: 959.483 s. Mean Reward: 18.960. Std of Reward: 4.606. Training. ELO: 2086.252.

[INFO] Testml. Step: 3840000. Time Elapsed: 989.501 s. Mean Reward: 17.675. Std of Reward: 6.534. Training. ELO: 2109.454.

[INFO] Testml. Step: 3852000. Time Elapsed: 1009.982 s. Mean Reward: -1.069. Std of Reward: 6.225. Training. ELO: 2097.374.

[INFO] Testml. Step: 3864000. Time Elapsed: 1030.270 s. Mean Reward: -1.848. Std of Reward: 5.006. Training. ELO: 2079.071.

[INFO] Testml. Step: 3876000. Time Elapsed: 1060.962 s. Mean Reward: -0.542. Std of Reward: 6.629. Training. ELO: 2036.954.

[INFO] Testml. Step: 3888000. Time Elapsed: 1081.076 s. Mean Reward: -1.404. Std of Reward: 5.795. Training. ELO: 1982.596.

[INFO] Testml. Step: 3900000. Time Elapsed: 1101.483 s. Mean Reward: -1.169. Std of Reward: 6.055. Training. ELO: 1944.791.

[INFO] Testml. Step: 3912000. Time Elapsed: 1121.725 s. Mean Reward: -1.676. Std of Reward: 5.042. Training. ELO: 1907.258.

[INFO] Testml. Step: 3924000. Time Elapsed: 1152.221 s. Mean Reward: -1.083. Std of Reward: 6.285. Training. ELO: 1883.531.

[INFO] Testml. Step: 3936000. Time Elapsed: 1172.020 s. Mean Reward: -1.173. Std of Reward: 6.382. Training. ELO: 1869.027.

[INFO] Testml. Step: 3948000. Time Elapsed: 1192.342 s. Mean Reward: 12.694. Std of Reward: 10.749. Training. ELO: 1869.533.

[INFO] Testml. Step: 3960000. Time Elapsed: 1221.164 s. Mean Reward: 18.069. Std of Reward: 6.218. Training. ELO: 1903.119.

[INFO] Testml. Step: 3972000. Time Elapsed: 1240.501 s. Mean Reward: 18.586. Std of Reward: 5.213. Training. ELO: 1940.066.

[INFO] Testml. Step: 3984000. Time Elapsed: 1259.826 s. Mean Reward: 18.328. Std of Reward: 5.499. Training. ELO: 1987.794.

[INFO] Testml. Step: 3996000. Time Elapsed: 1290.944 s. Mean Reward: 18.577. Std of Reward: 5.034. Training. ELO: 2001.588.

[INFO] Exported results\test_30\Testml\Testml-3999941.onnx

[INFO] Testml. Step: 4008000. Time Elapsed: 1309.025 s. Mean Reward: 18.449. Std of Reward: 5.798. Training. ELO: 2022.923.

[INFO] Testml. Step: 4020000. Time Elapsed: 1329.153 s. Mean Reward: 18.197. Std of Reward: 5.855. Training. ELO: 2035.370.

[INFO] Testml. Step: 4032000. Time Elapsed: 1348.328 s. Mean Reward: 18.443. Std of Reward: 5.304. Training. ELO: 2054.326.

[INFO] Testml. Step: 4044000. Time Elapsed: 1376.766 s. Mean Reward: 11.724. Std of Reward: 10.822. Training. ELO: 2068.677.

[INFO] Testml. Step: 4056000. Time Elapsed: 1394.979 s. Mean Reward: -1.310. Std of Reward: 5.693. Training. ELO: 2063.150.

[INFO] Testml. Step: 4068000. Time Elapsed: 1413.268 s. Mean Reward: -1.658. Std of Reward: 5.609. Training. ELO: 2043.664.

[INFO] Testml. Step: 4080000. Time Elapsed: 1441.532 s. Mean Reward: -2.013. Std of Reward: 4.311. Training. ELO: 2025.497.

[INFO] Testml. Step: 4092000. Time Elapsed: 1459.682 s. Mean Reward: -1.169. Std of Reward: 6.124. Training. ELO: 1990.560.

[INFO] Testml. Step: 4104000. Time Elapsed: 1478.199 s. Mean Reward: -1.555. Std of Reward: 5.071. Training. ELO: 1964.237.

[INFO] Testml. Step: 4116000. Time Elapsed: 1497.141 s. Mean Reward: -1.329. Std of Reward: 5.487. Training. ELO: 1925.609.

[INFO] Testml. Step: 4128000. Time Elapsed: 1525.746 s. Mean Reward: -0.594. Std of Reward: 6.804. Training. ELO: 1900.969.

[INFO] Testml. Step: 4140000. Time Elapsed: 1544.041 s. Mean Reward: -0.648. Std of Reward: 7.070. Training. ELO: 1883.466.

[INFO] Testml. Step: 4152000. Time Elapsed: 1562.084 s. Mean Reward: 19.567. Std of Reward: 2.899. Training. ELO: 1888.343.

[INFO] Testml. Step: 4164000. Time Elapsed: 1590.398 s. Mean Reward: 19.136. Std of Reward: 4.359. Training. ELO: 1906.919.

[INFO] Testml. Step: 4176000. Time Elapsed: 1608.606 s. Mean Reward: 18.463. Std of Reward: 5.633. Training. ELO: 1941.809.

[INFO] Testml. Step: 4188000. Time Elapsed: 1626.766 s. Mean Reward: 18.940. Std of Reward: 4.616. Training. ELO: 1978.161.

[INFO] Testml. Step: 4200000. Time Elapsed: 1645.180 s. Mean Reward: 18.754. Std of Reward: 5.018. Training. ELO: 2003.492.

[INFO] Testml. Step: 4212000. Time Elapsed: 1672.569 s. Mean Reward: 18.615. Std of Reward: 5.355. Training. ELO: 2028.086.

[INFO] Testml. Step: 4224000. Time Elapsed: 1690.467 s. Mean Reward: 19.401. Std of Reward: 2.883. Training. ELO: 2055.416.

[INFO] Testml. Step: 4236000. Time Elapsed: 1709.200 s. Mean Reward: 18.862. Std of Reward: 4.822. Training. ELO: 2072.990.

[INFO] Testml. Step: 4248000. Time Elapsed: 1736.852 s. Mean Reward: 5.935. Std of Reward: 11.054. Training. ELO: 2089.927.

[INFO] Testml. Step: 4260000. Time Elapsed: 1755.172 s. Mean Reward: -0.742. Std of Reward: 6.392. Training. ELO: 2039.793.

[INFO] Testml. Step: 4272000. Time Elapsed: 1773.811 s. Mean Reward: -1.484. Std of Reward: 5.394. Training. ELO: 1998.711.

[INFO] Testml. Step: 4284000. Time Elapsed: 1802.177 s. Mean Reward: -1.386. Std of Reward: 6.131. Training. ELO: 1984.109.

[INFO] Testml. Step: 4296000. Time Elapsed: 1820.202 s. Mean Reward: -1.812. Std of Reward: 4.296. Training. ELO: 1968.409.

[INFO] Testml. Step: 4308000. Time Elapsed: 1837.824 s. Mean Reward: -0.721. Std of Reward: 6.196. Training. ELO: 1947.183.

[INFO] Testml. Step: 4320000. Time Elapsed: 1855.504 s. Mean Reward: -1.269. Std of Reward: 5.869. Training. ELO: 1925.593.

[INFO] Testml. Step: 4332000. Time Elapsed: 1882.786 s. Mean Reward: -0.176. Std of Reward: 6.735. Training. ELO: 1905.531.

[INFO] Testml. Step: 4344000. Time Elapsed: 1900.335 s. Mean Reward: 5.248. Std of Reward: 10.774. Training. ELO: 1892.432.

[INFO] Testml. Step: 4356000. Time Elapsed: 1918.095 s. Mean Reward: 18.759. Std of Reward: 5.067. Training. ELO: 1926.713.

[INFO] Testml. Step: 4368000. Time Elapsed: 1945.367 s. Mean Reward: 18.551. Std of Reward: 5.369. Training. ELO: 1956.347.

[INFO] Testml. Step: 4380000. Time Elapsed: 1963.037 s. Mean Reward: 18.711. Std of Reward: 4.862. Training. ELO: 1987.996.

[INFO] Testml. Step: 4392000. Time Elapsed: 1980.784 s. Mean Reward: 19.901. Std of Reward: 0.808. Training. ELO: 2036.153.

[INFO] Testml. Step: 4404000. Time Elapsed: 1998.488 s. Mean Reward: 19.465. Std of Reward: 2.884. Training. ELO: 2078.458.

[INFO] Testml. Step: 4416000. Time Elapsed: 2025.688 s. Mean Reward: 19.172. Std of Reward: 4.402. Training. ELO: 2103.937.

[INFO] Testml. Step: 4428000. Time Elapsed: 2043.415 s. Mean Reward: 19.136. Std of Reward: 3.722. Training. ELO: 2117.780.

[INFO] Testml. Step: 4440000. Time Elapsed: 2061.571 s. Mean Reward: 19.169. Std of Reward: 4.144. Training. ELO: 2128.229.

[INFO] Testml. Step: 4452000. Time Elapsed: 2089.238 s. Mean Reward: -1.055. Std of Reward: 5.802. Training. ELO: 2104.840.

[INFO] Testml. Step: 4464000. Time Elapsed: 2106.715 s. Mean Reward: -0.404. Std of Reward: 6.614. Training. ELO: 2063.481.

[INFO] Testml. Step: 4476000. Time Elapsed: 2124.559 s. Mean Reward: -0.442. Std of Reward: 6.252. Training. ELO: 2022.355.

[INFO] Testml. Step: 4488000. Time Elapsed: 2153.589 s. Mean Reward: -0.655. Std of Reward: 6.072. Training. ELO: 1994.329.

[INFO] Testml. Step: 4500000. Time Elapsed: 2169.640 s. Mean Reward: -0.632. Std of Reward: 5.817. Training. ELO: 1955.208.

[INFO] Exported results\test_30\Testml\Testml-4499997.onnx

[INFO] Testml. Step: 4512000. Time Elapsed: 2187.144 s. Mean Reward: -0.896. Std of Reward: 5.472. Training. ELO: 1926.500.

[INFO] Testml. Step: 4524000. Time Elapsed: 2204.972 s. Mean Reward: 0.042. Std of Reward: 6.712. Training. ELO: 1902.689.

[INFO] Testml. Step: 4536000. Time Elapsed: 2232.015 s. Mean Reward: -1.034. Std of Reward: 4.734. Training. ELO: 1873.215.

[INFO] Testml. Step: 4548000. Time Elapsed: 2250.336 s. Mean Reward: 12.744. Std of Reward: 10.184. Training. ELO: 1873.777.

[INFO] Testml. Step: 4560000. Time Elapsed: 2267.881 s. Mean Reward: 19.202. Std of Reward: 4.007. Training. ELO: 1934.669.

[INFO] Testml. Step: 4572000. Time Elapsed: 2295.020 s. Mean Reward: 18.676. Std of Reward: 5.173. Training. ELO: 1966.662.

[INFO] Testml. Step: 4584000. Time Elapsed: 2313.030 s. Mean Reward: 19.457. Std of Reward: 3.533. Training. ELO: 1990.646.

[INFO] Testml. Step: 4596000. Time Elapsed: 2330.722 s. Mean Reward: 18.542. Std of Reward: 4.938. Training. ELO: 2026.906.

[INFO] Testml. Step: 4608000. Time Elapsed: 2348.549 s. Mean Reward: 18.756. Std of Reward: 4.512. Training. ELO: 2049.360.

[INFO] Testml. Step: 4620000. Time Elapsed: 2375.564 s. Mean Reward: 19.553. Std of Reward: 3.086. Training. ELO: 2074.729.

[INFO] Testml. Step: 4632000. Time Elapsed: 2393.251 s. Mean Reward: 19.502. Std of Reward: 3.018. Training. ELO: 2102.188.

[INFO] Testml. Step: 4644000. Time Elapsed: 2411.242 s. Mean Reward: 12.771. Std of Reward: 10.335. Training. ELO: 2127.177.

[INFO] Testml. Step: 4656000. Time Elapsed: 2437.280 s. Mean Reward: -0.985. Std of Reward: 4.836. Training. ELO: 2084.097.

[INFO] Testml. Step: 4668000. Time Elapsed: 2454.259 s. Mean Reward: -0.430. Std of Reward: 5.298. Training. ELO: 2049.479.

[INFO] Testml. Step: 4680000. Time Elapsed: 2471.705 s. Mean Reward: -0.251. Std of Reward: 6.470. Training. ELO: 2021.509.

[INFO] Testml. Step: 4692000. Time Elapsed: 2488.571 s. Mean Reward: -0.203. Std of Reward: 5.787. Training. ELO: 2004.096.

[INFO] Testml. Step: 4704000. Time Elapsed: 2514.652 s. Mean Reward: -1.347. Std of Reward: 3.463. Training. ELO: 1984.447.

[INFO] Testml. Step: 4716000. Time Elapsed: 2532.022 s. Mean Reward: -0.256. Std of Reward: 5.220. Training. ELO: 1960.257.

[INFO] Testml. Step: 4728000. Time Elapsed: 2548.958 s. Mean Reward: -0.868. Std of Reward: 4.775. Training. ELO: 1934.301.

[INFO] Testml. Step: 4740000. Time Elapsed: 2574.951 s. Mean Reward: -0.915. Std of Reward: 4.124. Training. ELO: 1925.020.

[INFO] Testml. Step: 4752000. Time Elapsed: 2592.174 s. Mean Reward: 19.113. Std of Reward: 4.167. Training. ELO: 1943.437.

[INFO] Testml. Step: 4764000. Time Elapsed: 2613.490 s. Mean Reward: 19.332. Std of Reward: 3.639. Training. ELO: 1993.098.

[INFO] Testml. Step: 4776000. Time Elapsed: 2643.452 s. Mean Reward: 19.188. Std of Reward: 3.768. Training. ELO: 2018.305.

[INFO] Testml. Step: 4788000. Time Elapsed: 2661.872 s. Mean Reward: 19.899. Std of Reward: 1.836. Training. ELO: 2040.486.

[INFO] Testml. Step: 4800000. Time Elapsed: 2681.477 s. Mean Reward: 19.603. Std of Reward: 2.892. Training. ELO: 2063.530.

[INFO] Testml. Step: 4812000. Time Elapsed: 2702.259 s. Mean Reward: 19.713. Std of Reward: 2.496. Training. ELO: 2091.307.

[INFO] Testml. Step: 4824000. Time Elapsed: 2732.068 s. Mean Reward: 19.458. Std of Reward: 4.043. Training. ELO: 2111.314.

[INFO] Testml. Step: 4836000. Time Elapsed: 2750.191 s. Mean Reward: 19.638. Std of Reward: 3.855. Training. ELO: 2137.726.

[INFO] Testml. Step: 4848000. Time Elapsed: 2768.479 s. Mean Reward: 6.366. Std of Reward: 10.581. Training. ELO: 2141.458.

[INFO] Testml. Step: 4860000. Time Elapsed: 2796.706 s. Mean Reward: -0.569. Std of Reward: 4.429. Training. ELO: 2103.289.

[INFO] Testml. Step: 4872000. Time Elapsed: 2814.504 s. Mean Reward: -0.693. Std of Reward: 4.149. Training. ELO: 2037.019.

[INFO] Testml. Step: 4884000. Time Elapsed: 2832.630 s. Mean Reward: 0.069. Std of Reward: 5.309. Training. ELO: 1987.730.

[INFO] Testml. Step: 4896000. Time Elapsed: 2851.045 s. Mean Reward: -0.577. Std of Reward: 4.340. Training. ELO: 1964.510.

[INFO] Testml. Step: 4908000. Time Elapsed: 2878.974 s. Mean Reward: -0.308. Std of Reward: 4.656. Training. ELO: 1943.144.

[INFO] Testml. Step: 4920000. Time Elapsed: 2896.839 s. Mean Reward: -0.284. Std of Reward: 4.515. Training. ELO: 1930.614.

[INFO] Testml. Step: 4932000. Time Elapsed: 2915.335 s. Mean Reward: -0.424. Std of Reward: 4.636. Training. ELO: 1910.820.

[INFO] Testml. Step: 4944000. Time Elapsed: 2943.728 s. Mean Reward: 5.995. Std of Reward: 10.147. Training. ELO: 1898.012.

[INFO] Testml. Step: 4956000. Time Elapsed: 2962.631 s. Mean Reward: 19.130. Std of Reward: 4.581. Training. ELO: 1927.127.

[INFO] Testml. Step: 4968000. Time Elapsed: 2980.863 s. Mean Reward: 19.113. Std of Reward: 5.086. Training. ELO: 1968.076.

[INFO] Testml. Step: 4980000. Time Elapsed: 3011.032 s. Mean Reward: 19.032. Std of Reward: 5.162. Training. ELO: 1988.713.

[INFO] Testml. Step: 4992000. Time Elapsed: 3027.724 s. Mean Reward: 18.815. Std of Reward: 5.340. Training. ELO: 1995.400.

[INFO] Exported results\test_30\Testml\Testml-4999928.onnx

[INFO] Testml. Step: 5004000. Time Elapsed: 3046.220 s. Mean Reward: 19.484. Std of Reward: 3.519. Training. ELO: 2015.022.

[INFO] Testml. Step: 5016000. Time Elapsed: 3064.716 s. Mean Reward: 19.804. Std of Reward: 3.467. Training. ELO: 2050.275.

[INFO] Testml. Step: 5028000. Time Elapsed: 3092.576 s. Mean Reward: 19.488. Std of Reward: 3.743. Training. ELO: 2076.401.

[INFO] Testml. Step: 5040000. Time Elapsed: 3111.583 s. Mean Reward: 19.773. Std of Reward: 3.035. Training. ELO: 2097.339.

[INFO] Testml. Step: 5052000. Time Elapsed: 3129.848 s. Mean Reward: 0.987. Std of Reward: 6.752. Training. ELO: 2082.335.

[INFO] Testml. Step: 5064000. Time Elapsed: 3157.576 s. Mean Reward: -0.165. Std of Reward: 4.878. Training. ELO: 2053.907.

[INFO] Testml. Step: 5076000. Time Elapsed: 3175.569 s. Mean Reward: -0.214. Std of Reward: 4.557. Training. ELO: 2026.286.

[INFO] Testml. Step: 5088000. Time Elapsed: 3193.905 s. Mean Reward: 0.130. Std of Reward: 5.664. Training. ELO: 1983.187.

[INFO] Testml. Step: 5100000. Time Elapsed: 3212.079 s. Mean Reward: -0.176. Std of Reward: 4.311. Training. ELO: 1961.910.

[INFO] Testml. Step: 5112000. Time Elapsed: 3240.385 s. Mean Reward: -0.327. Std of Reward: 4.131. Training. ELO: 1943.257.

[INFO] Testml. Step: 5124000. Time Elapsed: 3259.531 s. Mean Reward: -0.206. Std of Reward: 4.466. Training. ELO: 1927.280.

[INFO] Testml. Step: 5136000. Time Elapsed: 3278.915 s. Mean Reward: 0.036. Std of Reward: 4.613. Training. ELO: 1913.062.

[INFO] Testml. Step: 5148000. Time Elapsed: 3306.305 s. Mean Reward: 12.488. Std of Reward: 10.186. Training. ELO: 1918.612.

[INFO] Testml. Step: 5160000. Time Elapsed: 3326.826 s. Mean Reward: 19.543. Std of Reward: 3.633. Training. ELO: 1974.474.

[INFO] Testml. Step: 5172000. Time Elapsed: 3346.789 s. Mean Reward: 19.037. Std of Reward: 4.894. Training. ELO: 2011.895.

[INFO] Testml. Step: 5184000. Time Elapsed: 3366.517 s. Mean Reward: 19.244. Std of Reward: 4.012. Training. ELO: 2033.638.

[INFO] Testml. Step: 5196000. Time Elapsed: 3394.975 s. Mean Reward: 19.576. Std of Reward: 3.781. Training. ELO: 2073.506.

[INFO] Testml. Step: 5208000. Time Elapsed: 3414.177 s. Mean Reward: 19.362. Std of Reward: 3.621. Training. ELO: 2103.344.

[INFO] Testml. Step: 5220000. Time Elapsed: 3433.365 s. Mean Reward: 19.451. Std of Reward: 3.337. Training. ELO: 2129.206.

[INFO] Testml. Step: 5232000. Time Elapsed: 3461.961 s. Mean Reward: 20.046. Std of Reward: 2.175. Training. ELO: 2155.869.

[INFO] Testml. Step: 5244000. Time Elapsed: 3481.426 s. Mean Reward: 13.530. Std of Reward: 9.623. Training. ELO: 2162.514.

[INFO] Testml. Step: 5256000. Time Elapsed: 3500.698 s. Mean Reward: -0.988. Std of Reward: 2.221. Training. ELO: 2141.036.

[INFO] Testml. Step: 5268000. Time Elapsed: 3529.422 s. Mean Reward: -0.220. Std of Reward: 3.894. Training. ELO: 2101.398.

[INFO] Testml. Step: 5280000. Time Elapsed: 3548.365 s. Mean Reward: -0.680. Std of Reward: 3.158. Training. ELO: 2048.723.

[INFO] Testml. Step: 5292000. Time Elapsed: 3567.497 s. Mean Reward: -0.056. Std of Reward: 4.730. Training. ELO: 2018.736.

[INFO] Testml. Step: 5304000. Time Elapsed: 3586.863 s. Mean Reward: -0.639. Std of Reward: 3.009. Training. ELO: 1988.442.

[INFO] Testml. Step: 5316000. Time Elapsed: 3615.238 s. Mean Reward: 0.263. Std of Reward: 5.210. Training. ELO: 1951.195.

[INFO] Testml. Step: 5328000. Time Elapsed: 3634.577 s. Mean Reward: -0.589. Std of Reward: 3.347. Training. ELO: 1938.602.

[INFO] Testml. Step: 5340000. Time Elapsed: 3653.674 s. Mean Reward: -0.502. Std of Reward: 3.133. Training. ELO: 1906.802.

[INFO] Testml. Step: 5352000. Time Elapsed: 3681.722 s. Mean Reward: 18.110. Std of Reward: 6.241. Training. ELO: 1901.316.

[INFO] Testml. Step: 5364000. Time Elapsed: 3698.878 s. Mean Reward: 19.318. Std of Reward: 3.660. Training. ELO: 1930.007.

[INFO] Testml. Step: 5376000. Time Elapsed: 3715.868 s. Mean Reward: 19.966. Std of Reward: 2.148. Training. ELO: 1967.761.

[INFO] Testml. Step: 5388000. Time Elapsed: 3732.680 s. Mean Reward: 19.282. Std of Reward: 3.607. Training. ELO: 2012.356.

[INFO] Testml. Step: 5400000. Time Elapsed: 3759.294 s. Mean Reward: 19.997. Std of Reward: 1.948. Training. ELO: 2032.738.

[INFO] Testml. Step: 5412000. Time Elapsed: 3776.424 s. Mean Reward: 19.106. Std of Reward: 4.026. Training. ELO: 2086.967.

[INFO] Testml. Step: 5424000. Time Elapsed: 3793.199 s. Mean Reward: 19.591. Std of Reward: 2.813. Training. ELO: 2110.487.

[INFO] Testml. Step: 5436000. Time Elapsed: 3819.426 s. Mean Reward: 19.440. Std of Reward: 3.624. Training. ELO: 2136.163.

[INFO] Testml. Step: 5448000. Time Elapsed: 3836.615 s. Mean Reward: 7.349. Std of Reward: 10.422. Training. ELO: 2134.180.

[INFO] Testml. Step: 5460000. Time Elapsed: 3853.456 s. Mean Reward: -0.832. Std of Reward: 3.254. Training. ELO: 2092.758.

[INFO] Testml. Step: 5472000. Time Elapsed: 3881.432 s. Mean Reward: -0.935. Std of Reward: 2.574. Training. ELO: 2062.087.

[INFO] Testml. Step: 5484000. Time Elapsed: 3896.696 s. Mean Reward: -0.744. Std of Reward: 4.181. Training. ELO: 2035.017.

[INFO] Testml. Step: 5496000. Time Elapsed: 3913.909 s. Mean Reward: -0.715. Std of Reward: 3.305. Training. ELO: 2008.866.

[INFO] Exported results\test_30\Testml\Testml-5499933.onnx

[INFO] Testml. Step: 5508000. Time Elapsed: 3930.985 s. Mean Reward: -0.312. Std of Reward: 4.237. Training. ELO: 1981.105.

[INFO] Testml. Step: 5520000. Time Elapsed: 3957.070 s. Mean Reward: -0.274. Std of Reward: 4.295. Training. ELO: 1945.662.

[INFO] Testml. Step: 5532000. Time Elapsed: 3974.159 s. Mean Reward: -0.435. Std of Reward: 4.116. Training. ELO: 1926.296.

[INFO] Testml. Step: 5544000. Time Elapsed: 3991.076 s. Mean Reward: 5.456. Std of Reward: 9.936. Training. ELO: 1908.435.

[INFO] Testml. Step: 5556000. Time Elapsed: 4017.538 s. Mean Reward: 19.819. Std of Reward: 2.517. Training. ELO: 1931.856.

[INFO] Testml. Step: 5568000. Time Elapsed: 4034.564 s. Mean Reward: 20.044. Std of Reward: 3.076. Training. ELO: 1970.527.

[INFO] Testml. Step: 5580000. Time Elapsed: 4051.652 s. Mean Reward: 19.732. Std of Reward: 3.088. Training. ELO: 2003.587.

[INFO] Testml. Step: 5592000. Time Elapsed: 4068.639 s. Mean Reward: 20.032. Std of Reward: 1.990. Training. ELO: 2042.785.

[INFO] Testml. Step: 5604000. Time Elapsed: 4094.951 s. Mean Reward: 19.065. Std of Reward: 4.281. Training. ELO: 2089.536.

[INFO] Testml. Step: 5616000. Time Elapsed: 4111.848 s. Mean Reward: 19.538. Std of Reward: 3.080. Training. ELO: 2118.564.

[INFO] Testml. Step: 5628000. Time Elapsed: 4128.852 s. Mean Reward: 19.956. Std of Reward: 1.924. Training. ELO: 2136.571.

[INFO] Testml. Step: 5640000. Time Elapsed: 4155.397 s. Mean Reward: 19.807. Std of Reward: 2.213. Training. ELO: 2158.489.

[INFO] Testml. Step: 5652000. Time Elapsed: 4172.576 s. Mean Reward: 0.560. Std of Reward: 5.665. Training. ELO: 2134.595.

[INFO] Testml. Step: 5664000. Time Elapsed: 4189.663 s. Mean Reward: -0.597. Std of Reward: 4.036. Training. ELO: 2073.758.

[INFO] Testml. Step: 5676000. Time Elapsed: 4206.600 s. Mean Reward: -0.664. Std of Reward: 3.441. Training. ELO: 2047.391.

[INFO] Testml. Step: 5688000. Time Elapsed: 4233.008 s. Mean Reward: -0.192. Std of Reward: 4.943. Training. ELO: 2005.355.

[INFO] Testml. Step: 5700000. Time Elapsed: 4249.831 s. Mean Reward: -1.254. Std of Reward: 3.267. Training. ELO: 1993.635.

[INFO] Testml. Step: 5712000. Time Elapsed: 4267.050 s. Mean Reward: -0.917. Std of Reward: 2.403. Training. ELO: 1974.455.

[INFO] Testml. Step: 5724000. Time Elapsed: 4293.411 s. Mean Reward: -0.775. Std of Reward: 3.507. Training. ELO: 1943.452.

[INFO] Testml. Step: 5736000. Time Elapsed: 4310.323 s. Mean Reward: -1.006. Std of Reward: 3.383. Training. ELO: 1914.665.

[INFO] Testml. Step: 5748000. Time Elapsed: 4327.339 s. Mean Reward: 11.835. Std of Reward: 10.310. Training. ELO: 1901.740.

[INFO] Testml. Step: 5760000. Time Elapsed: 4353.885 s. Mean Reward: 19.549. Std of Reward: 4.048. Training. ELO: 1945.737.

[INFO] Testml. Step: 5772000. Time Elapsed: 4370.444 s. Mean Reward: 19.509. Std of Reward: 3.865. Training. ELO: 1971.547.

[INFO] Testml. Step: 5784000. Time Elapsed: 4387.492 s. Mean Reward: 19.817. Std of Reward: 2.526. Training. ELO: 1994.235.

[INFO] Testml. Step: 5796000. Time Elapsed: 4404.350 s. Mean Reward: 19.947. Std of Reward: 2.708. Training. ELO: 2007.004.

[INFO] Testml. Step: 5808000. Time Elapsed: 4430.616 s. Mean Reward: 19.694. Std of Reward: 3.512. Training. ELO: 2032.945.

[INFO] Testml. Step: 5820000. Time Elapsed: 4447.720 s. Mean Reward: 19.158. Std of Reward: 4.333. Training. ELO: 2068.791.

[INFO] Testml. Step: 5832000. Time Elapsed: 4464.948 s. Mean Reward: 19.203. Std of Reward: 4.749. Training. ELO: 2099.546.

[INFO] Testml. Step: 5844000. Time Elapsed: 4491.068 s. Mean Reward: 16.604. Std of Reward: 8.022. Training. ELO: 2113.706.

[INFO] Testml. Step: 5856000. Time Elapsed: 4508.076 s. Mean Reward: -0.714. Std of Reward: 4.022. Training. ELO: 2089.506.

[INFO] Testml. Step: 5868000. Time Elapsed: 4525.364 s. Mean Reward: -0.604. Std of Reward: 3.297. Training. ELO: 2036.935.

[INFO] Testml. Step: 5880000. Time Elapsed: 4542.339 s. Mean Reward: -0.714. Std of Reward: 3.630. Training. ELO: 1992.057.

[INFO] Testml. Step: 5892000. Time Elapsed: 4568.711 s. Mean Reward: -0.481. Std of Reward: 4.052. Training. ELO: 1959.227.

[INFO] Testml. Step: 5904000. Time Elapsed: 4585.633 s. Mean Reward: -1.080. Std of Reward: 1.997. Training. ELO: 1930.524.

[INFO] Testml. Step: 5916000. Time Elapsed: 4602.551 s. Mean Reward: -0.708. Std of Reward: 3.786. Training. ELO: 1911.002.

[INFO] Testml. Step: 5928000. Time Elapsed: 4628.908 s. Mean Reward: -0.827. Std of Reward: 3.331. Training. ELO: 1901.381.

[INFO] Testml. Step: 5940000. Time Elapsed: 4645.898 s. Mean Reward: -0.711. Std of Reward: 3.610. Training. ELO: 1879.876.

[INFO] Testml. Step: 5952000. Time Elapsed: 4662.778 s. Mean Reward: 16.153. Std of Reward: 7.972. Training. ELO: 1901.977.

[INFO] Testml. Step: 5964000. Time Elapsed: 4690.480 s. Mean Reward: 19.347. Std of Reward: 3.885. Training. ELO: 1944.976.

[INFO] Testml. Step: 5976000. Time Elapsed: 4705.973 s. Mean Reward: 19.325. Std of Reward: 3.814. Training. ELO: 1973.740.

[INFO] Testml. Step: 5988000. Time Elapsed: 4722.763 s. Mean Reward: 19.777. Std of Reward: 2.575. Training. ELO: 2024.488.

[INFO] Testml. Step: 6000000. Time Elapsed: 4739.837 s. Mean Reward: 19.802. Std of Reward: 2.224. Training. ELO: 2059.153.

[INFO] Exported results\test_30\Testml\Testml-5999957.onnx

[INFO] Testml. Step: 6012000. Time Elapsed: 4766.325 s. Mean Reward: 19.636. Std of Reward: 3.489. Training. ELO: 2073.814.

[INFO] Testml. Step: 6024000. Time Elapsed: 4783.131 s. Mean Reward: 19.734. Std of Reward: 3.033. Training. ELO: 2081.763.

[INFO] Testml. Step: 6036000. Time Elapsed: 4800.028 s. Mean Reward: 19.518. Std of Reward: 3.810. Training. ELO: 2101.912.

[INFO] Testml. Step: 6048000. Time Elapsed: 4826.521 s. Mean Reward: 9.349. Std of Reward: 10.811. Training. ELO: 2128.899.

[INFO] Testml. Step: 6060000. Time Elapsed: 4843.519 s. Mean Reward: -0.277. Std of Reward: 4.591. Training. ELO: 2099.040.

[INFO] Testml. Step: 6072000. Time Elapsed: 4860.504 s. Mean Reward: -0.845. Std of Reward: 2.934. Training. ELO: 2063.571.

[INFO] Testml. Step: 6084000. Time Elapsed: 4877.643 s. Mean Reward: -0.357. Std of Reward: 4.422. Training. ELO: 2013.298.

[INFO] Testml. Step: 6096000. Time Elapsed: 4903.960 s. Mean Reward: -0.574. Std of Reward: 3.651. Training. ELO: 2002.208.

[INFO] Testml. Step: 6108000. Time Elapsed: 4921.213 s. Mean Reward: -0.912. Std of Reward: 2.195. Training. ELO: 1964.207.

[INFO] Testml. Step: 6120000. Time Elapsed: 4938.073 s. Mean Reward: -0.501. Std of Reward: 4.142. Training. ELO: 1937.655.

[INFO] Testml. Step: 6132000. Time Elapsed: 4964.355 s. Mean Reward: -0.652. Std of Reward: 3.069. Training. ELO: 1912.622.

[INFO] Testml. Step: 6144000. Time Elapsed: 4981.686 s. Mean Reward: 2.571. Std of Reward: 8.031. Training. ELO: 1908.104.

[INFO] Testml. Step: 6156000. Time Elapsed: 4998.676 s. Mean Reward: 19.496. Std of Reward: 3.652. Training. ELO: 1903.455.

[INFO] Testml. Step: 6168000. Time Elapsed: 5015.846 s. Mean Reward: 19.824. Std of Reward: 1.725. Training. ELO: 1935.670.

[INFO] Testml. Step: 6180000. Time Elapsed: 5042.291 s. Mean Reward: 19.532. Std of Reward: 3.539. Training. ELO: 1981.691.

[INFO] Testml. Step: 6192000. Time Elapsed: 5059.195 s. Mean Reward: 19.598. Std of Reward: 3.727. Training. ELO: 2021.116.

[INFO] Testml. Step: 6204000. Time Elapsed: 5076.245 s. Mean Reward: 19.505. Std of Reward: 3.446. Training. ELO: 2048.796.

[INFO] Testml. Step: 6216000. Time Elapsed: 5102.339 s. Mean Reward: 19.800. Std of Reward: 3.260. Training. ELO: 2074.456.

[INFO] Testml. Step: 6228000. Time Elapsed: 5119.350 s. Mean Reward: 19.285. Std of Reward: 3.895. Training. ELO: 2088.384.

[INFO] Testml. Step: 6240000. Time Elapsed: 5136.468 s. Mean Reward: 19.644. Std of Reward: 3.326. Training. ELO: 2119.259.

[INFO] Testml. Step: 6252000. Time Elapsed: 5163.471 s. Mean Reward: 3.667. Std of Reward: 9.242. Training. ELO: 2132.472.

[INFO] Testml. Step: 6264000. Time Elapsed: 5180.066 s. Mean Reward: -0.396. Std of Reward: 4.038. Training. ELO: 2092.814.

[INFO] Testml. Step: 6276000. Time Elapsed: 5196.797 s. Mean Reward: -0.143. Std of Reward: 4.732. Training. ELO: 2045.893.

[INFO] Testml. Step: 6288000. Time Elapsed: 5213.820 s. Mean Reward: -0.743. Std of Reward: 3.244. Training. ELO: 2001.831.

[INFO] Testml. Step: 6300000. Time Elapsed: 5240.126 s. Mean Reward: -0.422. Std of Reward: 3.807. Training. ELO: 1960.890.

[INFO] Testml. Step: 6312000. Time Elapsed: 5257.078 s. Mean Reward: -0.702. Std of Reward: 3.347. Training. ELO: 1931.506.

[INFO] Testml. Step: 6324000. Time Elapsed: 5274.118 s. Mean Reward: -0.655. Std of Reward: 3.404. Training. ELO: 1905.680.

[INFO] Testml. Step: 6336000. Time Elapsed: 5300.369 s. Mean Reward: -0.624. Std of Reward: 3.616. Training. ELO: 1883.198.

[INFO] Testml. Step: 6348000. Time Elapsed: 5317.349 s. Mean Reward: 8.257. Std of Reward: 10.666. Training. ELO: 1873.991.

[INFO] Testml. Step: 6360000. Time Elapsed: 5334.303 s. Mean Reward: 19.611. Std of Reward: 3.171. Training. ELO: 1928.386.

[INFO] Testml. Step: 6372000. Time Elapsed: 5351.428 s. Mean Reward: 19.685. Std of Reward: 3.012. Training. ELO: 1966.652.

[INFO] Testml. Step: 6384000. Time Elapsed: 5377.839 s. Mean Reward: 19.774. Std of Reward: 2.527. Training. ELO: 2009.313.

[INFO] Testml. Step: 6396000. Time Elapsed: 5395.049 s. Mean Reward: 19.403. Std of Reward: 4.261. Training. ELO: 2040.426.

[INFO] Testml. Step: 6408000. Time Elapsed: 5411.898 s. Mean Reward: 18.752. Std of Reward: 4.756. Training. ELO: 2067.793.

[INFO] Testml. Step: 6420000. Time Elapsed: 5438.348 s. Mean Reward: 19.810. Std of Reward: 2.595. Training. ELO: 2081.245.

[INFO] Testml. Step: 6432000. Time Elapsed: 5455.213 s. Mean Reward: 19.982. Std of Reward: 2.682. Training. ELO: 2112.888.

[INFO] Testml. Step: 6444000. Time Elapsed: 5472.459 s. Mean Reward: 16.815. Std of Reward: 7.456. Training. ELO: 2145.580.

[INFO] Testml. Step: 6456000. Time Elapsed: 5500.619 s. Mean Reward: -0.462. Std of Reward: 3.806. Training. ELO: 2121.253.

[INFO] Testml. Step: 6468000. Time Elapsed: 5515.663 s. Mean Reward: -0.930. Std of Reward: 2.442. Training. ELO: 2068.601.

[INFO] Testml. Step: 6480000. Time Elapsed: 5532.640 s. Mean Reward: -0.678. Std of Reward: 3.525. Training. ELO: 2038.167.

[INFO] Testml. Step: 6492000. Time Elapsed: 5549.464 s. Mean Reward: -0.265. Std of Reward: 4.271. Training. ELO: 2014.223.

[INFO] Exported results\test_30\Testml\Testml-6499982.onnx

[INFO] Testml. Step: 6504000. Time Elapsed: 5576.066 s. Mean Reward: -0.614. Std of Reward: 3.592. Training. ELO: 1985.775.

[INFO] Testml. Step: 6516000. Time Elapsed: 5593.312 s. Mean Reward: -0.474. Std of Reward: 3.781. Training. ELO: 1955.023.

[INFO] Testml. Step: 6528000. Time Elapsed: 5610.439 s. Mean Reward: -0.672. Std of Reward: 3.639. Training. ELO: 1937.617.

[INFO] Testml. Step: 6540000. Time Elapsed: 5636.708 s. Mean Reward: -0.298. Std of Reward: 4.104. Training. ELO: 1936.249.

[INFO] Testml. Step: 6552000. Time Elapsed: 5653.677 s. Mean Reward: 15.322. Std of Reward: 9.054. Training. ELO: 1941.479.

[INFO] Testml. Step: 6564000. Time Elapsed: 5670.729 s. Mean Reward: 19.662. Std of Reward: 3.460. Training. ELO: 1961.098.

[INFO] Testml. Step: 6576000. Time Elapsed: 5687.443 s. Mean Reward: 19.372. Std of Reward: 3.405. Training. ELO: 2001.224.

[INFO] Testml. Step: 6588000. Time Elapsed: 5713.691 s. Mean Reward: 19.428. Std of Reward: 3.933. Training. ELO: 2048.414.

[INFO] Testml. Step: 6600000. Time Elapsed: 5730.787 s. Mean Reward: 19.640. Std of Reward: 3.176. Training. ELO: 2081.513.

[INFO] Testml. Step: 6612000. Time Elapsed: 5747.839 s. Mean Reward: 19.622. Std of Reward: 3.599. Training. ELO: 2095.827.

[INFO] Testml. Step: 6624000. Time Elapsed: 5774.246 s. Mean Reward: 19.321. Std of Reward: 4.126. Training. ELO: 2104.569.

[INFO] Testml. Step: 6636000. Time Elapsed: 5791.191 s. Mean Reward: 20.070. Std of Reward: 0.818. Training. ELO: 2128.847.

[INFO] Testml. Step: 6648000. Time Elapsed: 5808.394 s. Mean Reward: 11.269. Std of Reward: 10.524. Training. ELO: 2152.515.

[INFO] Testml. Step: 6660000. Time Elapsed: 5825.359 s. Mean Reward: -0.419. Std of Reward: 4.009. Training. ELO: 2130.595.

[INFO] Testml. Step: 6672000. Time Elapsed: 5851.541 s. Mean Reward: -0.211. Std of Reward: 4.637. Training. ELO: 2093.317.

[INFO] Testml. Step: 6684000. Time Elapsed: 5868.689 s. Mean Reward: -0.141. Std of Reward: 4.351. Training. ELO: 2062.797.

[INFO] Testml. Step: 6696000. Time Elapsed: 5885.651 s. Mean Reward: -0.893. Std of Reward: 2.453. Training. ELO: 2027.985.

[INFO] Testml. Step: 6708000. Time Elapsed: 5911.934 s. Mean Reward: 0.280. Std of Reward: 5.442. Training. ELO: 2005.959.

[INFO] Testml. Step: 6720000. Time Elapsed: 5929.268 s. Mean Reward: 0.147. Std of Reward: 4.764. Training. ELO: 1972.486.

[INFO] Testml. Step: 6732000. Time Elapsed: 5946.107 s. Mean Reward: -0.874. Std of Reward: 2.503. Training. ELO: 1944.904.

[INFO] Testml. Step: 6744000. Time Elapsed: 5973.476 s. Mean Reward: 1.945. Std of Reward: 7.564. Training. ELO: 1913.028.

[INFO] Testml. Step: 6756000. Time Elapsed: 5989.957 s. Mean Reward: 19.517. Std of Reward: 3.416. Training. ELO: 1918.007.

[INFO] Testml. Step: 6768000. Time Elapsed: 6006.838 s. Mean Reward: 18.887. Std of Reward: 5.019. Training. ELO: 1963.178.

[INFO] Testml. Step: 6780000. Time Elapsed: 6023.874 s. Mean Reward: 19.042. Std of Reward: 4.524. Training. ELO: 2011.981.

[INFO] Testml. Step: 6792000. Time Elapsed: 6050.086 s. Mean Reward: 19.639. Std of Reward: 3.837. Training. ELO: 2049.894.

[INFO] Testml. Step: 6804000. Time Elapsed: 6067.228 s. Mean Reward: 18.739. Std of Reward: 4.917. Training. ELO: 2072.562.

[INFO] Testml. Step: 6816000. Time Elapsed: 6084.304 s. Mean Reward: 18.903. Std of Reward: 5.145. Training. ELO: 2101.272.

[INFO] Testml. Step: 6828000. Time Elapsed: 6110.790 s. Mean Reward: 19.389. Std of Reward: 3.506. Training. ELO: 2138.637.

[INFO] Testml. Step: 6840000. Time Elapsed: 6127.694 s. Mean Reward: 19.355. Std of Reward: 4.205. Training. ELO: 2163.649.

[INFO] Testml. Step: 6852000. Time Elapsed: 6145.159 s. Mean Reward: 4.745. Std of Reward: 9.344. Training. ELO: 2163.237.

[INFO] Testml. Step: 6864000. Time Elapsed: 6162.085 s. Mean Reward: -0.378. Std of Reward: 3.841. Training. ELO: 2138.498.

[INFO] Testml. Step: 6876000. Time Elapsed: 6188.464 s. Mean Reward: -0.646. Std of Reward: 3.132. Training. ELO: 2116.662.

[INFO] Testml. Step: 6888000. Time Elapsed: 6205.517 s. Mean Reward: -0.355. Std of Reward: 3.852. Training. ELO: 2084.571.

[INFO] Testml. Step: 6900000. Time Elapsed: 6222.412 s. Mean Reward: -0.501. Std of Reward: 3.729. Training. ELO: 2032.298.

[INFO] Testml. Step: 6912000. Time Elapsed: 6248.913 s. Mean Reward: -0.988. Std of Reward: 1.873. Training. ELO: 1989.225.

[INFO] Testml. Step: 6924000. Time Elapsed: 6265.954 s. Mean Reward: -0.203. Std of Reward: 3.956. Training. ELO: 1971.450.

[INFO] Testml. Step: 6936000. Time Elapsed: 6282.970 s. Mean Reward: -0.334. Std of Reward: 3.830. Training. ELO: 1949.441.

[INFO] Testml. Step: 6948000. Time Elapsed: 6311.727 s. Mean Reward: 8.414. Std of Reward: 10.375. Training. ELO: 1929.215.

[INFO] Testml. Step: 6960000. Time Elapsed: 6326.644 s. Mean Reward: 19.164. Std of Reward: 3.580. Training. ELO: 1943.102.

[INFO] Testml. Step: 6972000. Time Elapsed: 6343.889 s. Mean Reward: 19.983. Std of Reward: 3.368. Training. ELO: 1984.555.

[INFO] Testml. Step: 6984000. Time Elapsed: 6360.940 s. Mean Reward: 19.083. Std of Reward: 4.423. Training. ELO: 1997.062.

[INFO] Testml. Step: 6996000. Time Elapsed: 6387.116 s. Mean Reward: 19.189. Std of Reward: 4.438. Training. ELO: 2026.747.

[INFO] Exported results\test_30\Testml\Testml-6999968.onnx

[INFO] Testml. Step: 7008000. Time Elapsed: 6404.160 s. Mean Reward: 19.821. Std of Reward: 1.853. Training. ELO: 2078.318.

[INFO] Testml. Step: 7020000. Time Elapsed: 6421.295 s. Mean Reward: 19.331. Std of Reward: 3.529. Training. ELO: 2112.528.

[INFO] Testml. Step: 7032000. Time Elapsed: 6447.827 s. Mean Reward: 19.119. Std of Reward: 4.184. Training. ELO: 2138.540.

[INFO] Testml. Step: 7044000. Time Elapsed: 6465.026 s. Mean Reward: 17.768. Std of Reward: 6.547. Training. ELO: 2163.022.

[INFO] Testml. Step: 7056000. Time Elapsed: 6481.890 s. Mean Reward: -0.232. Std of Reward: 4.114. Training. ELO: 2156.939.

[INFO] Testml. Step: 7068000. Time Elapsed: 6499.141 s. Mean Reward: -0.501. Std of Reward: 3.357. Training. ELO: 2094.072.

[INFO] Testml. Step: 7080000. Time Elapsed: 6525.760 s. Mean Reward: -0.278. Std of Reward: 4.186. Training. ELO: 2066.102.

[INFO] Testml. Step: 7092000. Time Elapsed: 6542.592 s. Mean Reward: 0.045. Std of Reward: 4.512. Training. ELO: 2039.041.

[INFO] Testml. Step: 7104000. Time Elapsed: 6559.506 s. Mean Reward: 0.167. Std of Reward: 4.970. Training. ELO: 1999.564.

[INFO] Testml. Step: 7116000. Time Elapsed: 6585.868 s. Mean Reward: -0.874. Std of Reward: 2.443. Training. ELO: 1965.320.

[INFO] Testml. Step: 7128000. Time Elapsed: 6602.821 s. Mean Reward: -0.068. Std of Reward: 4.533. Training. ELO: 1951.104.

[INFO] Testml. Step: 7140000. Time Elapsed: 6619.823 s. Mean Reward: -0.281. Std of Reward: 3.932. Training. ELO: 1932.884.

[INFO] Testml. Step: 7152000. Time Elapsed: 6637.060 s. Mean Reward: 14.606. Std of Reward: 9.264. Training. ELO: 1942.139.

[INFO] Testml. Step: 7164000. Time Elapsed: 6663.584 s. Mean Reward: 19.135. Std of Reward: 4.149. Training. ELO: 1975.098.

[INFO] Testml. Step: 7176000. Time Elapsed: 6680.771 s. Mean Reward: 19.125. Std of Reward: 4.852. Training. ELO: 2026.478.

[INFO] Testml. Step: 7188000. Time Elapsed: 6697.749 s. Mean Reward: 19.392. Std of Reward: 3.632. Training. ELO: 2047.270.

[INFO] Testml. Step: 7200000. Time Elapsed: 6724.386 s. Mean Reward: 18.921. Std of Reward: 5.262. Training. ELO: 2079.082.

[INFO] Testml. Step: 7212000. Time Elapsed: 6741.324 s. Mean Reward: 19.275. Std of Reward: 3.714. Training. ELO: 2113.043.

[INFO] Testml. Step: 7224000. Time Elapsed: 6758.749 s. Mean Reward: 19.390. Std of Reward: 4.158. Training. ELO: 2139.331.

[INFO] Testml. Step: 7236000. Time Elapsed: 6785.753 s. Mean Reward: 19.164. Std of Reward: 3.847. Training. ELO: 2153.271.

[INFO] Testml. Step: 7248000. Time Elapsed: 6802.313 s. Mean Reward: 11.178. Std of Reward: 10.489. Training. ELO: 2164.830.

[INFO] Testml. Step: 7260000. Time Elapsed: 6819.427 s. Mean Reward: 0.350. Std of Reward: 5.206. Training. ELO: 2119.860.

[INFO] Testml. Step: 7272000. Time Elapsed: 6836.564 s. Mean Reward: 0.570. Std of Reward: 5.500. Training. ELO: 2096.443.

[INFO] Testml. Step: 7284000. Time Elapsed: 6862.787 s. Mean Reward: 0.181. Std of Reward: 4.784. Training. ELO: 2079.062.

[INFO] Testml. Step: 7296000. Time Elapsed: 6879.826 s. Mean Reward: 0.044. Std of Reward: 4.443. Training. ELO: 2074.535.

[INFO] Testml. Step: 7308000. Time Elapsed: 6896.856 s. Mean Reward: 0.008. Std of Reward: 4.934. Training. ELO: 2041.010.

[INFO] Testml. Step: 7320000. Time Elapsed: 6923.275 s. Mean Reward: 0.281. Std of Reward: 5.245. Training. ELO: 1983.074.

[INFO] Testml. Step: 7332000. Time Elapsed: 6940.217 s. Mean Reward: 1.019. Std of Reward: 6.365. Training. ELO: 1963.332.

[INFO] Testml. Step: 7344000. Time Elapsed: 6957.488 s. Mean Reward: 2.538. Std of Reward: 7.683. Training. ELO: 1945.455.

[INFO] Testml. Step: 7356000. Time Elapsed: 6974.381 s. Mean Reward: 18.656. Std of Reward: 5.621. Training. ELO: 1974.786.

[INFO] Testml. Step: 7368000. Time Elapsed: 7000.800 s. Mean Reward: 18.548. Std of Reward: 5.516. Training. ELO: 2028.667.

[INFO] Testml. Step: 7380000. Time Elapsed: 7017.825 s. Mean Reward: 17.911. Std of Reward: 6.368. Training. ELO: 2053.199.

[INFO] Testml. Step: 7392000. Time Elapsed: 7035.096 s. Mean Reward: 18.004. Std of Reward: 6.491. Training. ELO: 2097.889.

[INFO] Testml. Step: 7404000. Time Elapsed: 7061.344 s. Mean Reward: 18.011. Std of Reward: 6.716. Training. ELO: 2123.227.

[INFO] Testml. Step: 7416000. Time Elapsed: 7078.331 s. Mean Reward: 18.634. Std of Reward: 5.577. Training. ELO: 2128.516.

[INFO] Testml. Step: 7428000. Time Elapsed: 7095.238 s. Mean Reward: 18.191. Std of Reward: 6.182. Training. ELO: 2148.139.

[INFO] Testml. Step: 7440000. Time Elapsed: 7123.590 s. Mean Reward: 18.658. Std of Reward: 4.636. Training. ELO: 2173.475.

[INFO] Testml. Step: 7452000. Time Elapsed: 7138.296 s. Mean Reward: 4.596. Std of Reward: 9.448. Training. ELO: 2157.975.

[INFO] Testml. Step: 7464000. Time Elapsed: 7155.429 s. Mean Reward: 0.061. Std of Reward: 4.676. Training. ELO: 2132.681.

[INFO] Testml. Step: 7476000. Time Elapsed: 7172.480 s. Mean Reward: 0.226. Std of Reward: 5.164. Training. ELO: 2079.914.

[INFO] Testml. Step: 7488000. Time Elapsed: 7198.627 s. Mean Reward: 0.906. Std of Reward: 5.974. Training. ELO: 2039.016.

[INFO] Testml. Step: 7500000. Time Elapsed: 7215.709 s. Mean Reward: 1.302. Std of Reward: 6.195. Training. ELO: 2012.551.

[INFO] Exported results\test_30\Testml\Testml-7499960.onnx

[INFO] Testml. Step: 7512000. Time Elapsed: 7233.084 s. Mean Reward: 1.694. Std of Reward: 6.807. Training. ELO: 2002.850.

[INFO] Testml. Step: 7524000. Time Elapsed: 7259.652 s. Mean Reward: 1.577. Std of Reward: 6.737. Training. ELO: 1993.118.

[INFO] Testml. Step: 7536000. Time Elapsed: 7276.564 s. Mean Reward: 0.948. Std of Reward: 5.891. Training. ELO: 1982.496.

[INFO] Testml. Step: 7548000. Time Elapsed: 7293.568 s. Mean Reward: 8.058. Std of Reward: 10.406. Training. ELO: 1975.321.

[INFO] Testml. Step: 7560000. Time Elapsed: 7310.897 s. Mean Reward: 17.775. Std of Reward: 6.851. Training. ELO: 2001.532.

[INFO] Testml. Step: 7572000. Time Elapsed: 7337.010 s. Mean Reward: 16.434. Std of Reward: 8.177. Training. ELO: 2022.193.

[INFO] Testml. Step: 7584000. Time Elapsed: 7354.190 s. Mean Reward: 16.706. Std of Reward: 7.854. Training. ELO: 2038.385.

[INFO] Testml. Step: 7596000. Time Elapsed: 7371.319 s. Mean Reward: 16.745. Std of Reward: 7.843. Training. ELO: 2065.966.

[INFO] Testml. Step: 7608000. Time Elapsed: 7397.533 s. Mean Reward: 18.132. Std of Reward: 6.267. Training. ELO: 2096.664.

[INFO] Testml. Step: 7620000. Time Elapsed: 7414.358 s. Mean Reward: 18.057. Std of Reward: 6.264. Training. ELO: 2130.422.

[INFO] Testml. Step: 7632000. Time Elapsed: 7431.684 s. Mean Reward: 17.667. Std of Reward: 7.379. Training. ELO: 2141.992.

[INFO] Testml. Step: 7644000. Time Elapsed: 7448.804 s. Mean Reward: 16.309. Std of Reward: 8.336. Training. ELO: 2156.021.

[INFO] Testml. Step: 7656000. Time Elapsed: 7475.062 s. Mean Reward: 2.358. Std of Reward: 7.473. Training. ELO: 2139.530.

[INFO] Testml. Step: 7668000. Time Elapsed: 7492.040 s. Mean Reward: 1.893. Std of Reward: 6.870. Training. ELO: 2111.475.

[INFO] Testml. Step: 7680000. Time Elapsed: 7509.060 s. Mean Reward: 2.286. Std of Reward: 7.444. Training. ELO: 2063.508.

[INFO] Testml. Step: 7692000. Time Elapsed: 7535.648 s. Mean Reward: 1.997. Std of Reward: 6.795. Training. ELO: 2022.180.

[INFO] Testml. Step: 7704000. Time Elapsed: 7552.636 s. Mean Reward: 1.548. Std of Reward: 6.442. Training. ELO: 2005.907.

[INFO] Testml. Step: 7716000. Time Elapsed: 7569.625 s. Mean Reward: 1.349. Std of Reward: 6.280. Training. ELO: 1996.947.

[INFO] Testml. Step: 7728000. Time Elapsed: 7596.282 s. Mean Reward: 2.654. Std of Reward: 7.840. Training. ELO: 1983.203.

[INFO] Testml. Step: 7740000. Time Elapsed: 7612.761 s. Mean Reward: 2.512. Std of Reward: 7.312. Training. ELO: 1968.888.

[INFO] Testml. Step: 7752000. Time Elapsed: 7629.768 s. Mean Reward: 12.002. Std of Reward: 10.561. Training. ELO: 1960.969.

[INFO] Testml. Step: 7764000. Time Elapsed: 7646.806 s. Mean Reward: 16.750. Std of Reward: 7.849. Training. ELO: 1970.813.

[INFO] Testml. Step: 7776000. Time Elapsed: 7673.338 s. Mean Reward: 16.520. Std of Reward: 8.062. Training. ELO: 2018.755.

[INFO] Testml. Step: 7788000. Time Elapsed: 7690.432 s. Mean Reward: 17.145. Std of Reward: 7.363. Training. ELO: 2056.324.

[INFO] Testml. Step: 7800000. Time Elapsed: 7707.379 s. Mean Reward: 16.220. Std of Reward: 8.248. Training. ELO: 2096.462.

[INFO] Testml. Step: 7812000. Time Elapsed: 7733.910 s. Mean Reward: 16.214. Std of Reward: 8.441. Training. ELO: 2109.755.

[INFO] Testml. Step: 7824000. Time Elapsed: 7750.709 s. Mean Reward: 16.837. Std of Reward: 7.906. Training. ELO: 2129.723.

[INFO] Testml. Step: 7836000. Time Elapsed: 7768.151 s. Mean Reward: 18.249. Std of Reward: 6.143. Training. ELO: 2161.117.

[INFO] Testml. Step: 7848000. Time Elapsed: 7785.485 s. Mean Reward: 11.194. Std of Reward: 10.387. Training. ELO: 2189.433.

[INFO] Testml. Step: 7860000. Time Elapsed: 7812.052 s. Mean Reward: 2.237. Std of Reward: 6.848. Training. ELO: 2143.814.

[INFO] Testml. Step: 7872000. Time Elapsed: 7828.969 s. Mean Reward: 3.739. Std of Reward: 8.231. Training. ELO: 2103.716.

[INFO] Testml. Step: 7884000. Time Elapsed: 7846.049 s. Mean Reward: 3.190. Std of Reward: 7.941. Training. ELO: 2081.600.

[INFO] Testml. Step: 7896000. Time Elapsed: 7872.272 s. Mean Reward: 2.793. Std of Reward: 7.652. Training. ELO: 2067.876.

[INFO] Testml. Step: 7908000. Time Elapsed: 7889.252 s. Mean Reward: 3.373. Std of Reward: 7.962. Training. ELO: 2049.413.

[INFO] Testml. Step: 7920000. Time Elapsed: 7906.629 s. Mean Reward: 3.348. Std of Reward: 8.147. Training. ELO: 2034.347.

[INFO] Testml. Step: 7932000. Time Elapsed: 7934.772 s. Mean Reward: 2.736. Std of Reward: 7.529. Training. ELO: 2015.265.

[INFO] Testml. Step: 7944000. Time Elapsed: 7950.269 s. Mean Reward: 4.063. Std of Reward: 8.491. Training. ELO: 2005.902.

[INFO] Testml. Step: 7956000. Time Elapsed: 7967.135 s. Mean Reward: 16.981. Std of Reward: 7.806. Training. ELO: 2026.817.

[INFO] Testml. Step: 7968000. Time Elapsed: 7984.289 s. Mean Reward: 16.394. Std of Reward: 8.154. Training. ELO: 2075.783.

[INFO] Testml. Step: 7980000. Time Elapsed: 8010.617 s. Mean Reward: 14.545. Std of Reward: 9.371. Training. ELO: 2110.188.

[INFO] Testml. Step: 7992000. Time Elapsed: 8027.849 s. Mean Reward: 15.734. Std of Reward: 8.615. Training. ELO: 2124.202.

[INFO] Exported results\test_30\Testml\Testml-7999960.onnx

[INFO] Testml. Step: 8004000. Time Elapsed: 8044.940 s. Mean Reward: 15.640. Std of Reward: 8.877. Training. ELO: 2142.638.

[INFO] Testml. Step: 8016000. Time Elapsed: 8071.437 s. Mean Reward: 16.610. Std of Reward: 8.085. Training. ELO: 2156.562.

[INFO] Testml. Step: 8028000. Time Elapsed: 8088.533 s. Mean Reward: 13.699. Std of Reward: 10.172. Training. ELO: 2170.945.

[INFO] Testml. Step: 8040000. Time Elapsed: 8105.465 s. Mean Reward: 16.092. Std of Reward: 8.274. Training. ELO: 2174.719.

[INFO] Testml. Step: 8052000. Time Elapsed: 8122.772 s. Mean Reward: 7.698. Std of Reward: 10.072. Training. ELO: 2173.122.

[INFO] Testml. Step: 8064000. Time Elapsed: 8149.233 s. Mean Reward: 4.178. Std of Reward: 8.380. Training. ELO: 2149.650.

[INFO] Testml. Step: 8076000. Time Elapsed: 8166.331 s. Mean Reward: 6.132. Std of Reward: 9.348. Training. ELO: 2129.747.

[INFO] Testml. Step: 8088000. Time Elapsed: 8183.338 s. Mean Reward: 3.135. Std of Reward: 7.552. Training. ELO: 2096.361.

[INFO] Testml. Step: 8100000. Time Elapsed: 8209.376 s. Mean Reward: 3.867. Std of Reward: 8.130. Training. ELO: 2069.588.

[INFO] Testml. Step: 8112000. Time Elapsed: 8226.370 s. Mean Reward: 4.765. Std of Reward: 8.568. Training. ELO: 2057.449.

[INFO] Testml. Step: 8124000. Time Elapsed: 8243.343 s. Mean Reward: 4.997. Std of Reward: 9.134. Training. ELO: 2045.404.

[INFO] Testml. Step: 8136000. Time Elapsed: 8260.342 s. Mean Reward: 5.161. Std of Reward: 8.713. Training. ELO: 2037.692.

[INFO] Testml. Step: 8148000. Time Elapsed: 8286.952 s. Mean Reward: 9.284. Std of Reward: 10.348. Training. ELO: 2037.784.

[INFO] Testml. Step: 8160000. Time Elapsed: 8304.060 s. Mean Reward: 13.717. Std of Reward: 10.182. Training. ELO: 2057.057.

[INFO] Testml. Step: 8172000. Time Elapsed: 8321.208 s. Mean Reward: 14.065. Std of Reward: 9.794. Training. ELO: 2086.544.

[INFO] Testml. Step: 8184000. Time Elapsed: 8348.077 s. Mean Reward: 13.872. Std of Reward: 9.997. Training. ELO: 2103.799.

[INFO] Testml. Step: 8196000. Time Elapsed: 8365.145 s. Mean Reward: 14.992. Std of Reward: 9.431. Training. ELO: 2128.865.

[INFO] Testml. Step: 8208000. Time Elapsed: 8382.124 s. Mean Reward: 14.331. Std of Reward: 9.964. Training. ELO: 2144.268.

[INFO] Testml. Step: 8220000. Time Elapsed: 8409.452 s. Mean Reward: 13.599. Std of Reward: 10.044. Training. ELO: 2154.407.

[INFO] Testml. Step: 8232000. Time Elapsed: 8425.769 s. Mean Reward: 14.127. Std of Reward: 9.748. Training. ELO: 2163.975.

[INFO] Testml. Step: 8244000. Time Elapsed: 8442.929 s. Mean Reward: 13.764. Std of Reward: 9.874. Training. ELO: 2169.799.

[INFO] Testml. Step: 8256000. Time Elapsed: 8459.804 s. Mean Reward: 5.453. Std of Reward: 9.264. Training. ELO: 2150.514.

[INFO] Testml. Step: 8268000. Time Elapsed: 8486.589 s. Mean Reward: 4.772. Std of Reward: 8.647. Training. ELO: 2134.342.

[INFO] Testml. Step: 8280000. Time Elapsed: 8503.786 s. Mean Reward: 5.030. Std of Reward: 8.893. Training. ELO: 2112.134.

[INFO] Testml. Step: 8292000. Time Elapsed: 8520.694 s. Mean Reward: 5.046. Std of Reward: 8.714. Training. ELO: 2101.564.

[INFO] Testml. Step: 8304000. Time Elapsed: 8547.422 s. Mean Reward: 5.416. Std of Reward: 9.028. Training. ELO: 2085.904.

[INFO] Testml. Step: 8316000. Time Elapsed: 8564.198 s. Mean Reward: 5.098. Std of Reward: 8.695. Training. ELO: 2072.560.

[INFO] Testml. Step: 8328000. Time Elapsed: 8581.140 s. Mean Reward: 4.938. Std of Reward: 8.798. Training. ELO: 2064.232.

[INFO] Testml. Step: 8340000. Time Elapsed: 8598.371 s. Mean Reward: 5.799. Std of Reward: 9.147. Training. ELO: 2057.978.

[INFO] Testml. Step: 8352000. Time Elapsed: 8624.874 s. Mean Reward: 10.821. Std of Reward: 10.823. Training. ELO: 2058.566.

[INFO] Testml. Step: 8364000. Time Elapsed: 8641.833 s. Mean Reward: 14.477. Std of Reward: 9.672. Training. ELO: 2085.350.

[INFO] Testml. Step: 8376000. Time Elapsed: 8658.911 s. Mean Reward: 14.431. Std of Reward: 9.697. Training. ELO: 2113.627.

[INFO] Testml. Step: 8388000. Time Elapsed: 8685.566 s. Mean Reward: 13.798. Std of Reward: 9.982. Training. ELO: 2137.014.

[INFO] Testml. Step: 8400000. Time Elapsed: 8702.692 s. Mean Reward: 13.488. Std of Reward: 10.367. Training. ELO: 2152.878.

[INFO] Testml. Step: 8412000. Time Elapsed: 8719.812 s. Mean Reward: 13.652. Std of Reward: 10.369. Training. ELO: 2165.164.

[INFO] Testml. Step: 8424000. Time Elapsed: 8740.011 s. Mean Reward: 14.333. Std of Reward: 9.696. Training. ELO: 2186.220.

[INFO] Testml. Step: 8436000. Time Elapsed: 8771.111 s. Mean Reward: 14.326. Std of Reward: 9.867. Training. ELO: 2205.304.

[INFO] Testml. Step: 8448000. Time Elapsed: 8791.327 s. Mean Reward: 10.630. Std of Reward: 10.472. Training. ELO: 2206.433.

[INFO] Testml. Step: 8460000. Time Elapsed: 8811.847 s. Mean Reward: 4.562. Std of Reward: 8.586. Training. ELO: 2190.311.

[INFO] Testml. Step: 8472000. Time Elapsed: 8842.401 s. Mean Reward: 4.291. Std of Reward: 8.078. Training. ELO: 2161.415.

[INFO] Testml. Step: 8484000. Time Elapsed: 8862.771 s. Mean Reward: 4.820. Std of Reward: 8.625. Training. ELO: 2147.070.

[INFO] Testml. Step: 8496000. Time Elapsed: 8883.141 s. Mean Reward: 4.228. Std of Reward: 8.337. Training. ELO: 2124.833.

[INFO] Exported results\test_30\Testml\Testml-8499971.onnx

[INFO] Testml. Step: 8508000. Time Elapsed: 8913.624 s. Mean Reward: 5.385. Std of Reward: 9.030. Training. ELO: 2113.839.

[INFO] Testml. Step: 8520000. Time Elapsed: 8934.031 s. Mean Reward: 4.267. Std of Reward: 8.128. Training. ELO: 2097.483.

[INFO] Testml. Step: 8532000. Time Elapsed: 8954.355 s. Mean Reward: 5.137. Std of Reward: 8.602. Training. ELO: 2089.795.

[INFO] Testml. Step: 8544000. Time Elapsed: 8975.040 s. Mean Reward: 6.783. Std of Reward: 9.416. Training. ELO: 2082.432.

[INFO] Testml. Step: 8556000. Time Elapsed: 9005.261 s. Mean Reward: 13.203. Std of Reward: 10.502. Training. ELO: 2079.160.

[INFO] Testml. Step: 8568000. Time Elapsed: 9023.486 s. Mean Reward: 14.140. Std of Reward: 9.772. Training. ELO: 2096.900.

[INFO] Testml. Step: 8580000. Time Elapsed: 9042.531 s. Mean Reward: 13.792. Std of Reward: 9.845. Training. ELO: 2114.408.

[INFO] Testml. Step: 8592000. Time Elapsed: 9075.861 s. Mean Reward: 14.029. Std of Reward: 10.110. Training. ELO: 2134.874.

[INFO] Testml. Step: 8604000. Time Elapsed: 9099.913 s. Mean Reward: 14.985. Std of Reward: 9.466. Training. ELO: 2159.666.

[INFO] Testml. Step: 8616000. Time Elapsed: 9123.399 s. Mean Reward: 13.432. Std of Reward: 10.110. Training. ELO: 2171.370.

[INFO] Testml. Step: 8628000. Time Elapsed: 9145.906 s. Mean Reward: 13.588. Std of Reward: 10.057. Training. ELO: 2176.078.

[INFO] Testml. Step: 8640000. Time Elapsed: 9179.196 s. Mean Reward: 12.808. Std of Reward: 10.544. Training. ELO: 2189.131.

[INFO] Testml. Step: 8652000. Time Elapsed: 9201.906 s. Mean Reward: 9.359. Std of Reward: 10.029. Training. ELO: 2192.947.

[INFO] Testml. Step: 8664000. Time Elapsed: 9224.709 s. Mean Reward: 5.790. Std of Reward: 8.895. Training. ELO: 2170.963.

[INFO] Testml. Step: 8676000. Time Elapsed: 9257.939 s. Mean Reward: 4.716. Std of Reward: 8.755. Training. ELO: 2153.567.

[INFO] Testml. Step: 8688000. Time Elapsed: 9280.787 s. Mean Reward: 5.277. Std of Reward: 8.849. Training. ELO: 2134.947.

[INFO] Testml. Step: 8700000. Time Elapsed: 9303.400 s. Mean Reward: 7.020. Std of Reward: 9.805. Training. ELO: 2121.773.

[INFO] Testml. Step: 8712000. Time Elapsed: 9337.833 s. Mean Reward: 4.127. Std of Reward: 8.418. Training. ELO: 2106.284.

[INFO] Testml. Step: 8724000. Time Elapsed: 9359.601 s. Mean Reward: 5.192. Std of Reward: 8.989. Training. ELO: 2092.380.

[INFO] Testml. Step: 8736000. Time Elapsed: 9382.036 s. Mean Reward: 6.125. Std of Reward: 9.236. Training. ELO: 2090.435.

[INFO] Testml. Step: 8748000. Time Elapsed: 9405.452 s. Mean Reward: 7.747. Std of Reward: 10.034. Training. ELO: 2081.378.

[INFO] Testml. Step: 8760000. Time Elapsed: 9436.894 s. Mean Reward: 13.514. Std of Reward: 10.139. Training. ELO: 2101.502.

[INFO] Testml. Step: 8772000. Time Elapsed: 9459.558 s. Mean Reward: 13.253. Std of Reward: 10.293. Training. ELO: 2112.360.

[INFO] Testml. Step: 8784000. Time Elapsed: 9480.983 s. Mean Reward: 13.416. Std of Reward: 10.267. Training. ELO: 2131.949.

[INFO] Testml. Step: 8796000. Time Elapsed: 9511.443 s. Mean Reward: 12.385. Std of Reward: 11.040. Training. ELO: 2155.819.

[INFO] Testml. Step: 8808000. Time Elapsed: 9532.195 s. Mean Reward: 13.251. Std of Reward: 10.143. Training. ELO: 2169.622.

[INFO] Testml. Step: 8820000. Time Elapsed: 9554.716 s. Mean Reward: 14.162. Std of Reward: 9.964. Training. ELO: 2186.111.

[INFO] Testml. Step: 8832000. Time Elapsed: 9577.604 s. Mean Reward: 12.875. Std of Reward: 10.290. Training. ELO: 2197.271.

[INFO] Testml. Step: 8844000. Time Elapsed: 9608.990 s. Mean Reward: 14.548. Std of Reward: 9.467. Training. ELO: 2201.528.

[INFO] Testml. Step: 8856000. Time Elapsed: 9628.249 s. Mean Reward: 6.659. Std of Reward: 9.401. Training. ELO: 2194.691.

[INFO] Testml. Step: 8868000. Time Elapsed: 9647.286 s. Mean Reward: 5.706. Std of Reward: 8.972. Training. ELO: 2181.434.

[INFO] Testml. Step: 8880000. Time Elapsed: 9676.326 s. Mean Reward: 6.066. Std of Reward: 9.190. Training. ELO: 2167.571.

[INFO] Testml. Step: 8892000. Time Elapsed: 9695.550 s. Mean Reward: 4.698. Std of Reward: 8.635. Training. ELO: 2141.177.

[INFO] Testml. Step: 8904000. Time Elapsed: 9714.705 s. Mean Reward: 6.323. Std of Reward: 9.237. Training. ELO: 2123.526.

[INFO] Testml. Step: 8916000. Time Elapsed: 9733.815 s. Mean Reward: 5.781. Std of Reward: 9.180. Training. ELO: 2108.675.

[INFO] Testml. Step: 8928000. Time Elapsed: 9762.434 s. Mean Reward: 5.056. Std of Reward: 8.706. Training. ELO: 2096.866.

[INFO] Testml. Step: 8940000. Time Elapsed: 9781.676 s. Mean Reward: 6.570. Std of Reward: 9.212. Training. ELO: 2090.734.

[INFO] Testml. Step: 8952000. Time Elapsed: 9800.922 s. Mean Reward: 10.358. Std of Reward: 10.567. Training. ELO: 2084.948.

[INFO] Testml. Step: 8964000. Time Elapsed: 9829.644 s. Mean Reward: 11.712. Std of Reward: 10.702. Training. ELO: 2094.888.

[INFO] Testml. Step: 8976000. Time Elapsed: 9848.814 s. Mean Reward: 12.772. Std of Reward: 10.466. Training. ELO: 2102.634.

[INFO] Testml. Step: 8988000. Time Elapsed: 9870.193 s. Mean Reward: 12.222. Std of Reward: 10.485. Training. ELO: 2118.315.

[INFO] Testml. Step: 9000000. Time Elapsed: 9904.336 s. Mean Reward: 12.342. Std of Reward: 10.625. Training. ELO: 2133.404.

[INFO] Exported results\test_30\Testml\Testml-8999914.onnx

[INFO] Testml. Step: 9012000. Time Elapsed: 9926.981 s. Mean Reward: 12.824. Std of Reward: 10.476. Training. ELO: 2151.836.

[INFO] Testml. Step: 9024000. Time Elapsed: 9949.844 s. Mean Reward: 13.285. Std of Reward: 10.292. Training. ELO: 2166.618.

[INFO] Testml. Step: 9036000. Time Elapsed: 9972.790 s. Mean Reward: 12.282. Std of Reward: 10.365. Training. ELO: 2178.996.

[INFO] Testml. Step: 9048000. Time Elapsed: 10007.150 s. Mean Reward: 10.977. Std of Reward: 10.442. Training. ELO: 2186.912.

[INFO] Testml. Step: 9060000. Time Elapsed: 10030.516 s. Mean Reward: 4.644. Std of Reward: 8.592. Training. ELO: 2179.037.

[INFO] Testml. Step: 9072000. Time Elapsed: 10053.529 s. Mean Reward: 5.613. Std of Reward: 9.069. Training. ELO: 2145.755.

[INFO] Testml. Step: 9084000. Time Elapsed: 10085.325 s. Mean Reward: 6.547. Std of Reward: 9.280. Training. ELO: 2135.252.

[INFO] Testml. Step: 9096000. Time Elapsed: 10108.506 s. Mean Reward: 4.883. Std of Reward: 8.811. Training. ELO: 2123.461.

[INFO] Testml. Step: 9108000. Time Elapsed: 10137.067 s. Mean Reward: 4.850. Std of Reward: 8.507. Training. ELO: 2106.761.

[INFO] Testml. Step: 9120000. Time Elapsed: 10166.146 s. Mean Reward: 6.616. Std of Reward: 9.434. Training. ELO: 2089.330.

[INFO] Testml. Step: 9132000. Time Elapsed: 10209.452 s. Mean Reward: 5.093. Std of Reward: 8.860. Training. ELO: 2083.950.

[INFO] Testml. Step: 9144000. Time Elapsed: 10240.697 s. Mean Reward: 6.458. Std of Reward: 9.291. Training. ELO: 2082.095.

[INFO] Testml. Step: 9156000. Time Elapsed: 10271.672 s. Mean Reward: 12.840. Std of Reward: 10.437. Training. ELO: 2094.965.

[INFO] Testml. Step: 9168000. Time Elapsed: 10315.762 s. Mean Reward: 12.875. Std of Reward: 10.058. Training. ELO: 2110.044.

[INFO] Testml. Step: 9180000. Time Elapsed: 10346.591 s. Mean Reward: 13.068. Std of Reward: 10.219. Training. ELO: 2134.401.

[INFO] Testml. Step: 9192000. Time Elapsed: 10377.714 s. Mean Reward: 13.325. Std of Reward: 10.210. Training. ELO: 2158.925.

[INFO] Testml. Step: 9204000. Time Elapsed: 10421.197 s. Mean Reward: 12.547. Std of Reward: 10.349. Training. ELO: 2175.436.

[INFO] Testml. Step: 9216000. Time Elapsed: 10450.589 s. Mean Reward: 13.806. Std of Reward: 9.642. Training. ELO: 2187.788.

[INFO] Testml. Step: 9228000. Time Elapsed: 10480.932 s. Mean Reward: 14.042. Std of Reward: 9.450. Training. ELO: 2203.798.

[INFO] Testml. Step: 9240000. Time Elapsed: 10511.622 s. Mean Reward: 14.149. Std of Reward: 9.411. Training. ELO: 2220.426.

[INFO] Testml. Step: 9252000. Time Elapsed: 10555.752 s. Mean Reward: 7.978. Std of Reward: 9.999. Training. ELO: 2221.917.

[INFO] Testml. Step: 9264000. Time Elapsed: 10586.466 s. Mean Reward: 5.551. Std of Reward: 9.015. Training. ELO: 2191.630.

[INFO] Testml. Step: 9276000. Time Elapsed: 10615.093 s. Mean Reward: 5.352. Std of Reward: 8.659. Training. ELO: 2170.330.

[INFO] Testml. Step: 9288000. Time Elapsed: 10658.369 s. Mean Reward: 5.674. Std of Reward: 8.977. Training. ELO: 2151.110.

[INFO] Testml. Step: 9300000. Time Elapsed: 10689.212 s. Mean Reward: 4.728. Std of Reward: 8.474. Training. ELO: 2134.800.

[INFO] Testml. Step: 9312000. Time Elapsed: 10719.939 s. Mean Reward: 4.161. Std of Reward: 8.156. Training. ELO: 2123.303.

[INFO] Testml. Step: 9324000. Time Elapsed: 10750.954 s. Mean Reward: 4.915. Std of Reward: 8.469. Training. ELO: 2115.031.

[INFO] Testml. Step: 9336000. Time Elapsed: 10794.446 s. Mean Reward: 6.018. Std of Reward: 9.077. Training. ELO: 2103.075.

[INFO] Testml. Step: 9348000. Time Elapsed: 10825.764 s. Mean Reward: 9.112. Std of Reward: 10.247. Training. ELO: 2101.571.

[INFO] Testml. Step: 9360000. Time Elapsed: 10854.178 s. Mean Reward: 13.791. Std of Reward: 9.963. Training. ELO: 2125.438.

[INFO] Testml. Step: 9372000. Time Elapsed: 10897.248 s. Mean Reward: 13.902. Std of Reward: 9.797. Training. ELO: 2146.832.

[INFO] Testml. Step: 9384000. Time Elapsed: 10927.748 s. Mean Reward: 12.765. Std of Reward: 10.303. Training. ELO: 2162.488.

[INFO] Testml. Step: 9396000. Time Elapsed: 10958.355 s. Mean Reward: 13.404. Std of Reward: 10.036. Training. ELO: 2168.949.

[INFO] Testml. Step: 9408000. Time Elapsed: 11005.374 s. Mean Reward: 12.351. Std of Reward: 10.426. Training. ELO: 2174.716.

[INFO] Testml. Step: 9420000. Time Elapsed: 11031.266 s. Mean Reward: 12.036. Std of Reward: 10.545. Training. ELO: 2184.442.

[INFO] Testml. Step: 9432000. Time Elapsed: 11060.569 s. Mean Reward: 13.021. Std of Reward: 9.980. Training. ELO: 2191.540.

[INFO] Testml. Step: 9444000. Time Elapsed: 11092.298 s. Mean Reward: 13.276. Std of Reward: 10.210. Training. ELO: 2202.673.

[INFO] Testml. Step: 9456000. Time Elapsed: 11134.887 s. Mean Reward: 5.901. Std of Reward: 9.123. Training. ELO: 2207.225.

[INFO] Testml. Step: 9468000. Time Elapsed: 11162.778 s. Mean Reward: 6.388. Std of Reward: 9.444. Training. ELO: 2202.237.

[INFO] Testml. Step: 9480000. Time Elapsed: 11193.708 s. Mean Reward: 5.681. Std of Reward: 9.001. Training. ELO: 2184.839.

[INFO] Testml. Step: 9492000. Time Elapsed: 11236.587 s. Mean Reward: 6.105. Std of Reward: 9.192. Training. ELO: 2176.916.

[INFO] Exported results\test_30\Testml\Testml-9499960.onnx

[INFO] Testml. Step: 9504000. Time Elapsed: 11267.025 s. Mean Reward: 5.785. Std of Reward: 9.044. Training. ELO: 2160.552.

[INFO] Testml. Step: 9516000. Time Elapsed: 11297.716 s. Mean Reward: 6.022. Std of Reward: 9.006. Training. ELO: 2152.034.

[INFO] Testml. Step: 9528000. Time Elapsed: 11328.349 s. Mean Reward: 4.888. Std of Reward: 8.566. Training. ELO: 2136.833.

[INFO] Testml. Step: 9540000. Time Elapsed: 11371.911 s. Mean Reward: 4.614. Std of Reward: 8.494. Training. ELO: 2124.458.

[INFO] Testml. Step: 9552000. Time Elapsed: 11403.078 s. Mean Reward: 10.154. Std of Reward: 10.435. Training. ELO: 2121.607.

[INFO] Testml. Step: 9564000. Time Elapsed: 11432.590 s. Mean Reward: 13.049. Std of Reward: 9.941. Training. ELO: 2139.080.

[INFO] Testml. Step: 9576000. Time Elapsed: 11475.815 s. Mean Reward: 12.440. Std of Reward: 10.221. Training. ELO: 2155.484.

[INFO] Testml. Step: 9588000. Time Elapsed: 11507.150 s. Mean Reward: 13.778. Std of Reward: 9.898. Training. ELO: 2171.957.

[INFO] Testml. Step: 9600000. Time Elapsed: 11537.599 s. Mean Reward: 13.127. Std of Reward: 9.988. Training. ELO: 2190.747.

[INFO] Testml. Step: 9612000. Time Elapsed: 11568.345 s. Mean Reward: 13.988. Std of Reward: 9.623. Training. ELO: 2197.140.

[INFO] Testml. Step: 9624000. Time Elapsed: 11611.530 s. Mean Reward: 13.981. Std of Reward: 9.636. Training. ELO: 2209.535.

[INFO] Testml. Step: 9636000. Time Elapsed: 11640.430 s. Mean Reward: 13.936. Std of Reward: 9.683. Training. ELO: 2227.258.

[INFO] Testml. Step: 9648000. Time Elapsed: 11671.009 s. Mean Reward: 11.143. Std of Reward: 10.317. Training. ELO: 2240.484.

[INFO] Testml. Step: 9660000. Time Elapsed: 11702.911 s. Mean Reward: 4.889. Std of Reward: 8.613. Training. ELO: 2217.637.

[INFO] Testml. Step: 9672000. Time Elapsed: 11721.887 s. Mean Reward: 5.819. Std of Reward: 8.927. Training. ELO: 2198.452.

[INFO] Testml. Step: 9684000. Time Elapsed: 11740.815 s. Mean Reward: 5.382. Std of Reward: 8.960. Training. ELO: 2181.477.

[INFO] Testml. Step: 9696000. Time Elapsed: 11768.901 s. Mean Reward: 5.223. Std of Reward: 8.963. Training. ELO: 2163.498.

[INFO] Testml. Step: 9708000. Time Elapsed: 11785.803 s. Mean Reward: 5.278. Std of Reward: 9.065. Training. ELO: 2153.564.

[INFO] Testml. Step: 9720000. Time Elapsed: 11804.136 s. Mean Reward: 6.085. Std of Reward: 9.125. Training. ELO: 2144.664.

[INFO] Testml. Step: 9732000. Time Elapsed: 11823.261 s. Mean Reward: 4.895. Std of Reward: 8.779. Training. ELO: 2126.224.

[INFO] Testml. Step: 9744000. Time Elapsed: 11850.705 s. Mean Reward: 5.158. Std of Reward: 8.729. Training. ELO: 2110.971.

[INFO] Testml. Step: 9756000. Time Elapsed: 11867.890 s. Mean Reward: 11.927. Std of Reward: 10.799. Training. ELO: 2120.759.

[INFO] Testml. Step: 9768000. Time Elapsed: 11884.674 s. Mean Reward: 12.951. Std of Reward: 10.180. Training. ELO: 2135.102.

[INFO] Testml. Step: 9780000. Time Elapsed: 11909.010 s. Mean Reward: 13.676. Std of Reward: 9.789. Training. ELO: 2145.344.

[INFO] Testml. Step: 9792000. Time Elapsed: 11925.973 s. Mean Reward: 14.227. Std of Reward: 9.350. Training. ELO: 2163.960.

[INFO] Testml. Step: 9804000. Time Elapsed: 11942.833 s. Mean Reward: 12.518. Std of Reward: 10.094. Training. ELO: 2176.944.

[INFO] Testml. Step: 9816000. Time Elapsed: 11959.632 s. Mean Reward: 13.702. Std of Reward: 9.832. Training. ELO: 2195.081.

[INFO] Testml. Step: 9828000. Time Elapsed: 11983.966 s. Mean Reward: 13.200. Std of Reward: 9.882. Training. ELO: 2206.077.

[INFO] Testml. Step: 9840000. Time Elapsed: 12000.879 s. Mean Reward: 14.077. Std of Reward: 9.553. Training. ELO: 2215.056.

[INFO] Testml. Step: 9852000. Time Elapsed: 12017.825 s. Mean Reward: 9.459. Std of Reward: 10.226. Training. ELO: 2227.446.

[INFO] Testml. Step: 9864000. Time Elapsed: 12042.314 s. Mean Reward: 3.841. Std of Reward: 8.195. Training. ELO: 2190.216.

[INFO] Testml. Step: 9876000. Time Elapsed: 12058.980 s. Mean Reward: 4.310. Std of Reward: 8.516. Training. ELO: 2157.900.

[INFO] Testml. Step: 9888000. Time Elapsed: 12075.830 s. Mean Reward: 5.779. Std of Reward: 9.244. Training. ELO: 2142.355.

[INFO] Testml. Step: 9900000. Time Elapsed: 12092.674 s. Mean Reward: 4.548. Std of Reward: 8.521. Training. ELO: 2130.908.

[INFO] Testml. Step: 9912000. Time Elapsed: 12116.980 s. Mean Reward: 5.840. Std of Reward: 9.125. Training. ELO: 2120.827.

[INFO] Testml. Step: 9924000. Time Elapsed: 12133.798 s. Mean Reward: 4.327. Std of Reward: 8.369. Training. ELO: 2103.939.

[INFO] Testml. Step: 9936000. Time Elapsed: 12151.747 s. Mean Reward: 5.388. Std of Reward: 8.899. Training. ELO: 2094.815.

[INFO] Testml. Step: 9948000. Time Elapsed: 12176.281 s. Mean Reward: 8.542. Std of Reward: 10.169. Training. ELO: 2095.832.

[INFO] Testml. Step: 9960000. Time Elapsed: 12193.132 s. Mean Reward: 13.644. Std of Reward: 9.977. Training. ELO: 2126.587.

[INFO] Testml. Step: 9972000. Time Elapsed: 12209.802 s. Mean Reward: 14.024. Std of Reward: 9.739. Training. ELO: 2151.220.

[INFO] Testml. Step: 9984000. Time Elapsed: 12234.406 s. Mean Reward: 13.782. Std of Reward: 9.650. Training. ELO: 2168.086.

[INFO] Testml. Step: 9996000. Time Elapsed: 12251.274 s. Mean Reward: 13.566. Std of Reward: 9.749. Training. ELO: 2187.170.